Keep 社区

内容表达与互动反馈分析

哪些内容获得反馈，评论又如何形成往来？

陈霖 · 董依心

研究背景、问题与预期

健身社区里，什么内容受到关注，人们又怎样交流？

Keep 既承载训练与打卡，也包含经验和生活分享。点赞是可见反馈，
评论则记录了谁在留言、谁在接话；理解反馈需要把内容和参与者一起看。

三个具体问题	对应预期：可能出现的结果
RQ1　样本主要呈现什么内容，点赞怎样分布？	媒体反馈可能不同，高赞帖可能拉高均值； 正文也可能同时包含运动与生活分享。
RQ2　文字线索与主题是否与点赞有关？	自律、积极表达或提问可能对应较高点赞； 调整作者与情境后，这些差异也可能减弱。
RQ3　评论说什么，谁回应谁，参与面多广？	读者可能更多鼓励，帖主更多回应； 高评论量也可能来自少数人的反复往来。

预期是待检验的可能解释，后文按相同 RQ 编号逐项回答。

数据来源与清洗

9,532

帖子 · 100 位作者

11,595

去重后评论

1,323

有采集到评论的帖子

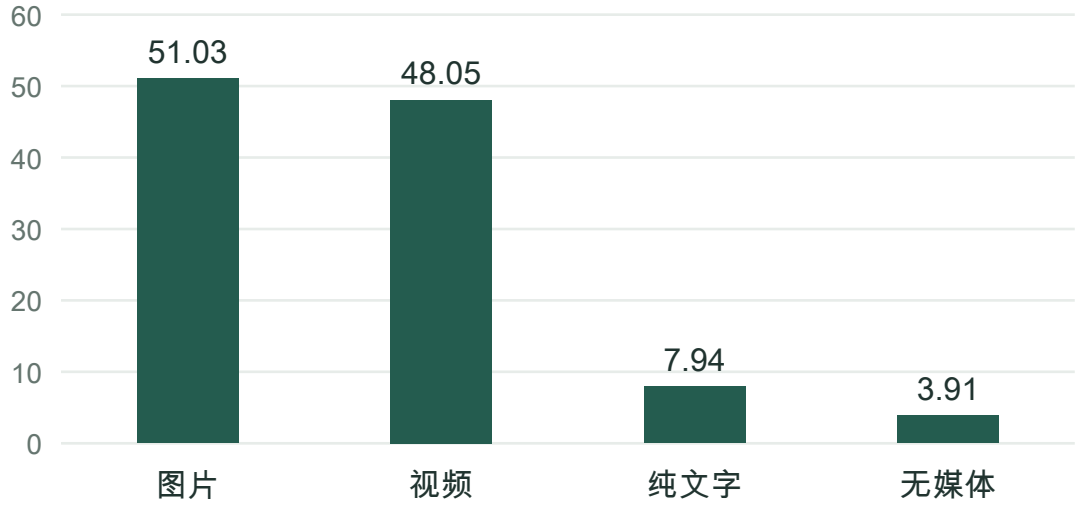
核查发现	处理方式	分析含义
1,916 行重复评论	按评论 ID 去重，无字段冲突	避免同一发言被重复计入
3,984 帖缺可用正文	保留；文字计数设 0 并另作标记	不能把缺失当作真实无文字
8,286 帖点赞高于记录浏览数	使用累计点赞，不计算点赞率	不解释为曝光转化效率

正文覆盖随媒体和作者而不同。主题结果仅代表 2,470 条有效正文、 86 位作者，不能当作全部 9,532 帖的内容比例；没有采到，也不等于没有发生。

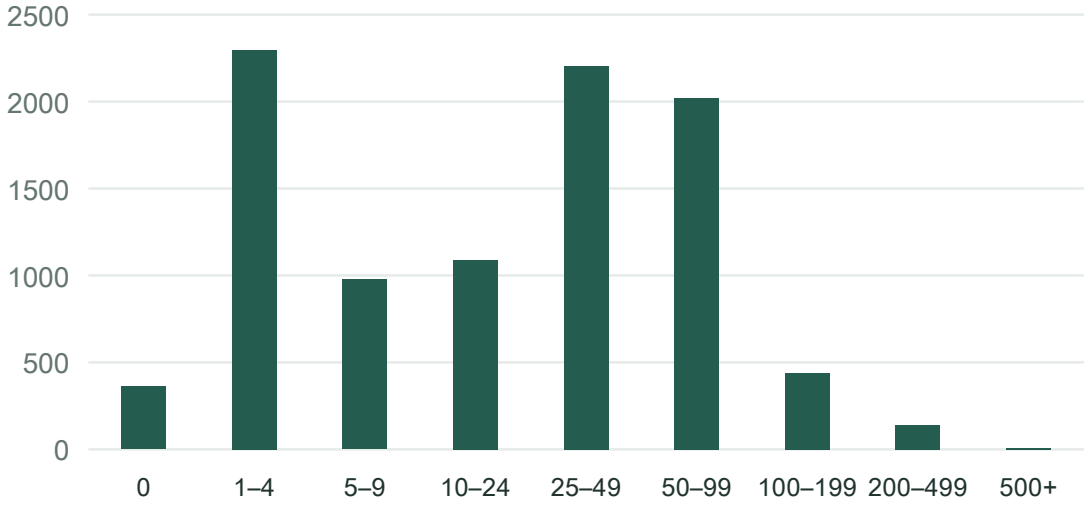
课程 100 位作者样本；帖子发表于 2020 年 11—12 月（ UTC ），评论最晚至 2021 年 8 月。

图片和视频帖点赞更高，整体分布同时存在长尾

不同媒体的平均点赞



点赞区间中的帖子数



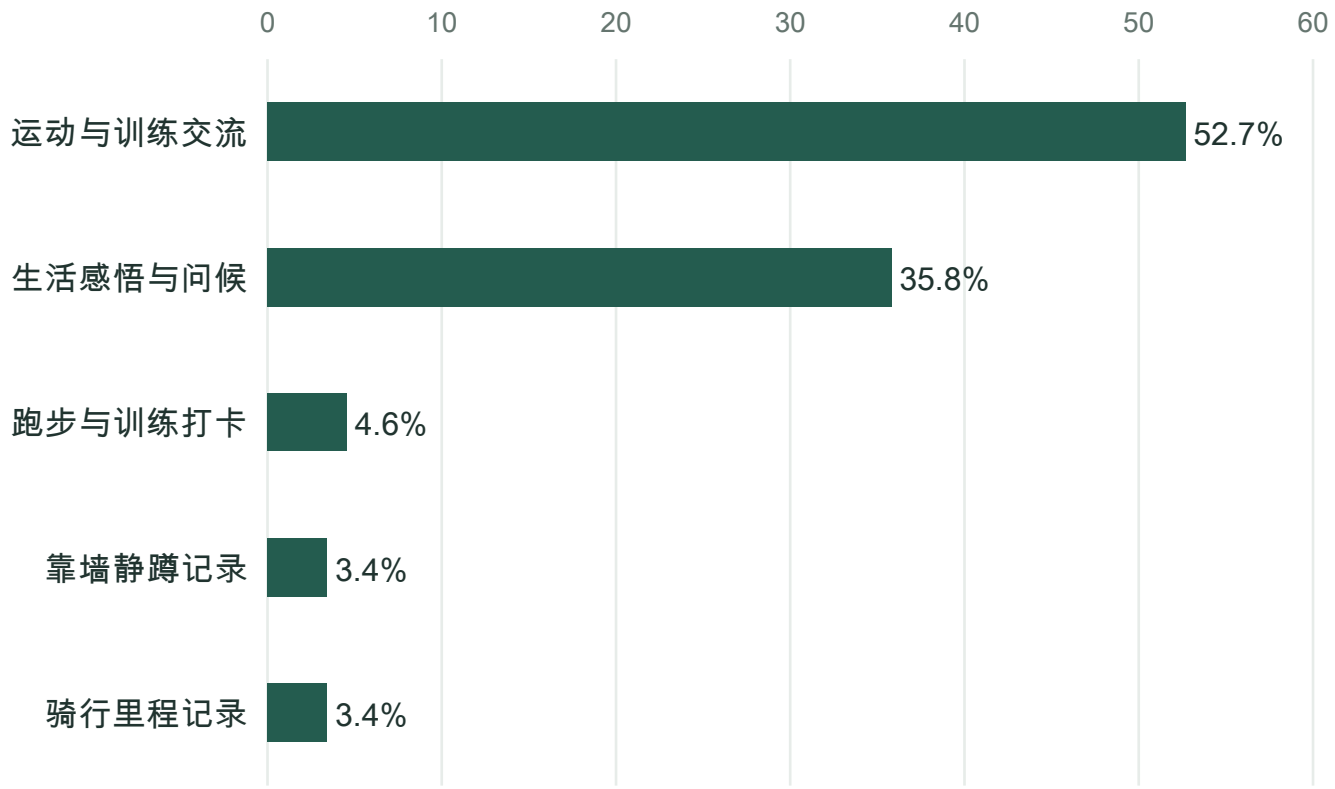
均值 37.05 · 中位数 25 · 95% 分位 109.45 · 最高 5,126

少量高赞帖拉高平均数，均值不能代表普通帖；媒体均值也相差约一个数量级。

媒体形式和点赞分布说明了反馈的基本差异；接着看有正文的帖子主要在写什么。

两图为原始描述；右图显示各点赞区间的帖子数，区间宽度不同，不表示概率密度。

帖子正文主题主要包括运动和生活



2,470 帖 · 86 位作者

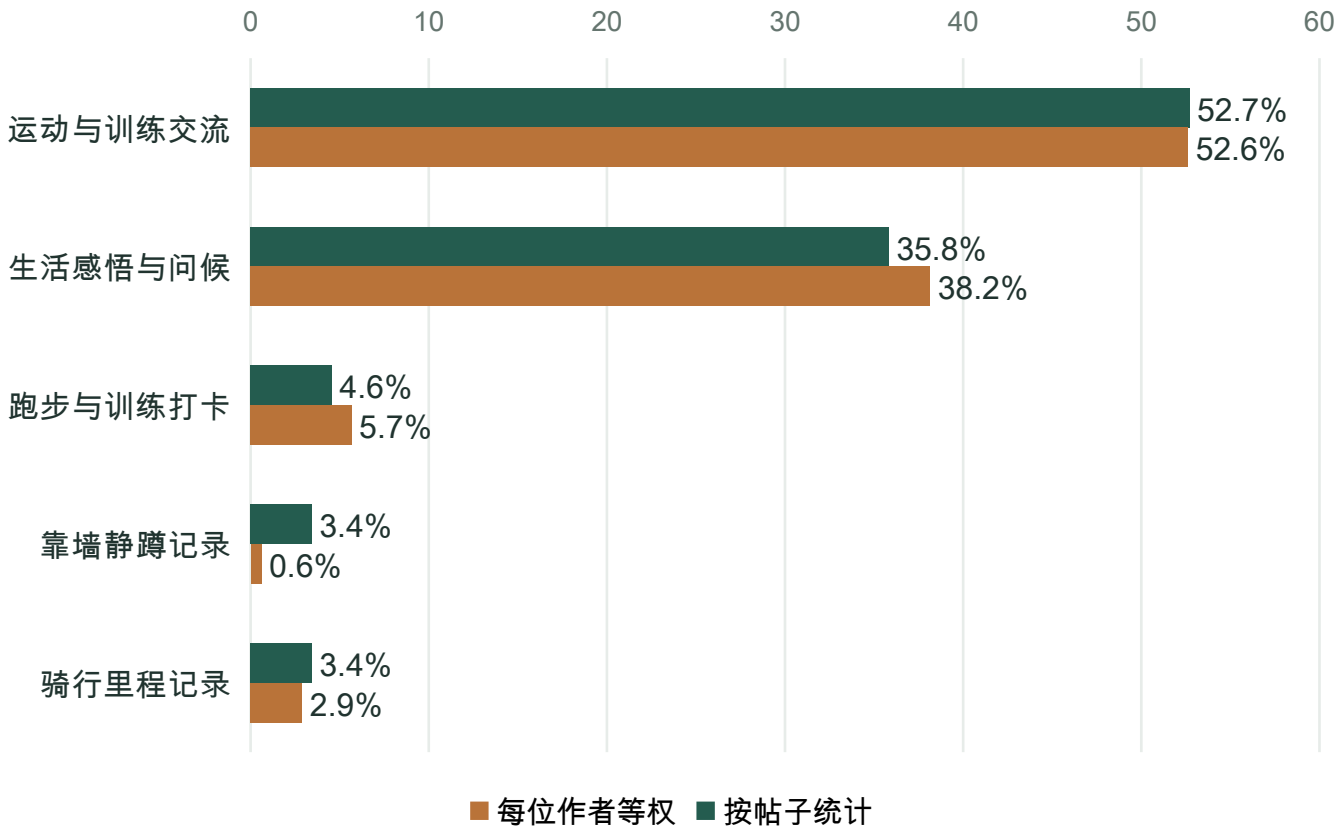
训练交流：运动、减脂、训练、拉伸
生活问候：人生、生活、早安、美好

前两类合计 88.5% 。这批有效正文不仅讨论如何训练，也经常写感受、生活和问候，不能把健身社区里的文字都当成运动成绩记录。

占比按每帖权重最大的主题归类。同一作者可写多个主题，内容量大也可能是某些人写得多。

TF-IDF + NMF ，主题数预先固定为 5 ；名称依据词项与正文确定，不参考点赞。

常见内容，也可能是少数人的高频记录



静蹲：3.4% → 0.6%

85 条主导文档中，78 条来自同一作者。按帖看是在统计这种记录出现了多少次；作者等权后，才减少了高产作者的重复贡献。

训练 52.7% → 52.6% ，生活 35.8% → 38.2% 。两条主要内容线仍在，变化集中在部分小主题。

训练和生活是两条主要内容线；部分小主题的份额，则会被少数作者的持续记录放大。

两组沿用同一主题分类；作者等权先计算每人的主题比例，再对 86 位作者平均。

RQ1 的回答：这批帖子的内容和点赞怎样分布

媒体不同，收到的点赞并不均匀。

图片和视频帖平均约 51 、 48 赞，文字与无媒体约 8 、 4 赞。整体均值 37.05 高于中位数 25 ，少量高赞把分布拉出长尾；单用平均数会高估普通帖子的反馈水平。

正文同时包含训练交流和生活分享，篇幅也受作者影响。

训练交流 52.7% 、生活问候 35.8% ，作者等权后仍是两条主线。静蹲却由 3.4% 降至 0.6% ，其中 85 帖有 78 帖来自一人：这种记录出现多，不等于很多作者都在写。

RQ2 接着问：把媒体、作者与日期一起纳入比较后，文字或主题与点赞还有多大关联？

范围： 9,532 帖；主题比例仅代表 2,470 条有效正文、 86 位作者。

怎样把文字表达放进点赞比较

五项文字变量	定义与例子
正文长度 L	ln(1+ 清理后字符数)
自律 / 目标 D	坚持、自律、目标、第 N 天等词表或模式
社交 / 互助 S	大家、小伙伴、谢谢、一起等词表
积极表达 P	开心、快乐、喜欢、哈哈等词表
问号 Q	全角或半角问号，出现记 1

除长度外，命中记 1 ；一帖可同时命中多个词类。

比较什么结果？

点赞分布有长尾，因此模型采用 ln(1+ 点赞数) ，减少少量极端高赞对比较的影响。

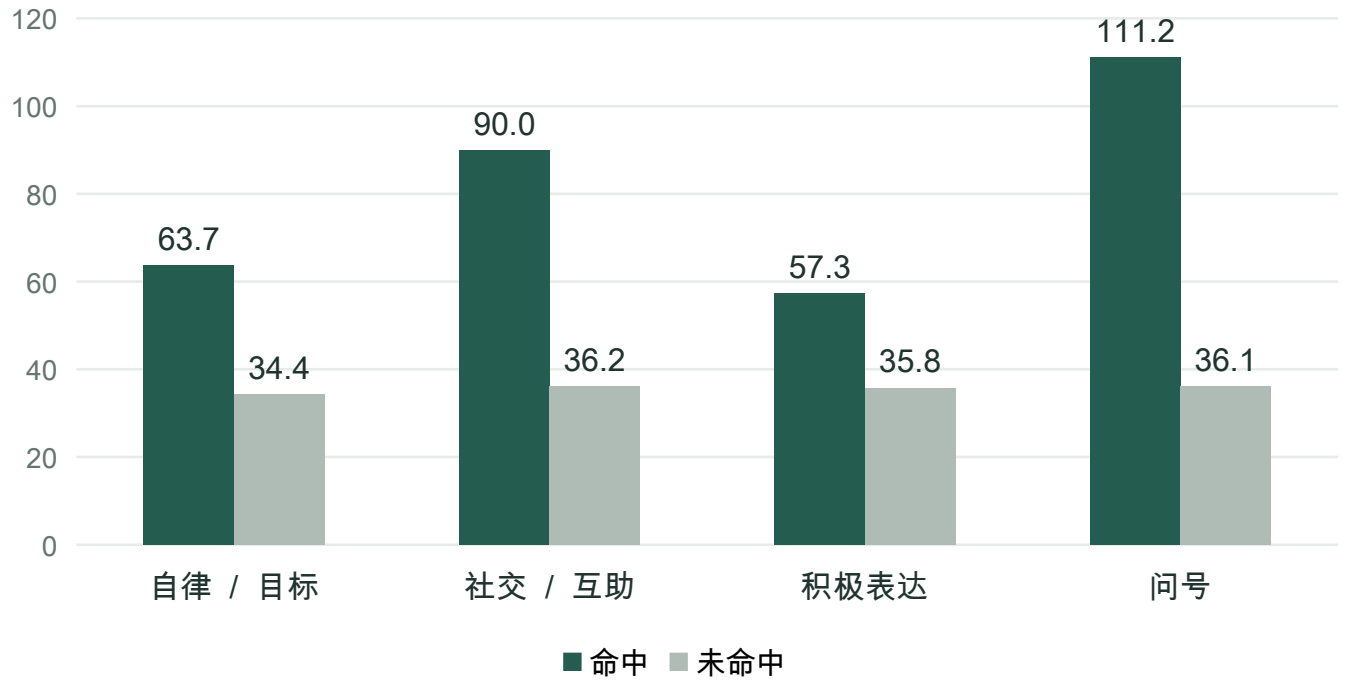
怎样判断文字的额外关联？

先看命中与未命中的均值及媒体构成，再同时调整作者、日期和发布情境，检查原始差异是否保留。

用词检验之后，再加入 RQ1 已经识别的主题权重，检查整篇内容是否补充点赞关联。

文字词表只识别字面线索，不是情绪量表；特征可重叠。

分组均值较高，但文字与媒体构成混在一起



积极表达组的进一步比较

组别	帖数	图片 / 视频
命中	574	94.9%
未命中	8,958	69.1%

57.29 vs 35.76 个赞，
同时伴随媒体构成差异。
命中组分布于 64 位作者，
未命中组覆盖 100 位作者。

下一步：同时控制媒体、作者和日期，比较这些用词是否仍有额外关联。

变量已在第 8 页定义；组别与特征可重叠，分组均值尚未调整作者和发布情境。

用作者与日期固定效应，进一步改善比较

$$M3：\ln(1 + 点赞数) = \beta' X + \gamma' C + \alpha_{作者} + \delta_{日期} + \varepsilon$$

X ：长度、自律、社交、积极、问号。 C ：正文可用、话题、表情数、课程分享，以及媒体、业务类型、时段。

模型	调整范围	R^2	积极表达系数 / 原始 p
M1	X + C + 已记录作者属性	0.563	−0.050 / 0.285
M2	X + C + 作者固定效应	0.685	−0.087 / 0.016
M3 主模型	X + C + 作者、日期固定效应	0.688	−0.086 / 0.016

加入作者固定效应后拟合度提高，提示作者差异值得考虑；积极表达在 M1 中就已为负。

这里比较的是调整后的对数结果，不能把与原始均值的差别单独归因于某一个控制项。

主分析为 OLS ； N=9,532 、 100 位作者，标准误按作者聚类，五项核心系数采用 BH 校正。

M3 没有保留原始用词优势，单项线索也需要校正

文字特征	系数 β	原始 95% 区间	p	BH q
长度 ln(1+ 字数)	0.028	[−0.008, 0.064]	0.130	0.293
自律 / 目标	−0.119	[−0.293, 0.054]	0.176	0.293
社交 / 互助	−0.004	[−0.131, 0.122]	0.946	0.946
积极表达	−0.086	[−0.155, −0.016]	0.016	0.079
问号	0.108	[−0.100, 0.316]	0.307	0.383

积极表达： β = −0.086

原始 p = 0.016
BH q = 0.079

单项区间不跨 0 ，
但五项一起校正后，
证据未达到 5% 标准。

五项文字线索仅增加 0.065 个百分点 R^2 ，联合检验 p = 0.130 。

原始均值优势没有在调整后的比较中保留；这不足以推出“积极用词降低点赞”。

还要核查：负向方向是否依赖缺失正文、极端高赞帖或某一位作者？

表中为 M3 的作者聚类推断； 95% 区间与 p 为原始值， BH q 同时考虑五项核心检验。

换样本和模型后，积极表达的方向是否改变？

设定	N	系数	原始 95% 区间	p
M3 主模型	9,532	−0.086	[−0.155, −0.016]	0.016
仅可见正文	5,548	−0.090	[−0.164, −0.015]	0.019
去最高 1% 点赞	9,436	−0.082	[−0.152, −0.012]	0.022
作者等权	9,532	−0.128	[−0.219, −0.036]	0.007
PPML 计数模型	9,532	−0.135	[−0.299, 0.028]	0.103

方向不依赖一种样本处理

可见正文、去高赞、作者等权后均为负；100 次逐作者剔除也全部为负。

计数尺度上仍不精确

PPML 区间跨 0 ，不能把方向一致升级成已验证的稳定负效应。

逐作者剔除系数范围： [−0.100, −0.074] 。 PPML 拟合 E[点赞 | 条件] = exp(线性项) 。

沿用 RQ1 已经识别的主题权重，检验它们能否补充指定用词以外的点赞关联。

聚焦积极表达；区间和 p 为各设定原始值，不代替 M3 的 BH 主分析结论。

主题权重能否补充用词以外的点赞关联？

主题模型： M3 原有线性项 $+\Sigma\,\theta_k w_k$（省去“运动与训练交流”权重作为参照）

相对训练交流的主题权重	系数 θ	原始 95% 区间	p	BH q
靠墙静蹲记录	−0.315	[−0.636, 0.005]	0.054	0.107
骑行里程记录	0.018	[−0.523, 0.558]	0.948	0.948
跑步与训练打卡	−0.471	[−1.048, 0.105]	0.108	0.144
生活感悟与问候	−0.144	[−0.278, −0.010]	0.035	0.107

生活问候权重相对训练交流增加 10 个百分点时，“1+ 点赞”的条件几何均值点估计约低 1.4% 。

但其原始 p = 0.035 、 BH q = 0.107 ；四项主题联合 p = 0.166 ，尚不能把点估计当成稳定的主题反馈排序。

权重范围 0–1 ，系数按 100 个百分点计；区间未计入主题估计本身的不确定性。

同一子样本 N=2,470 、 86 位作者；按作者聚类。回归使用连续主题权重，不是主导主题虚拟变量。

RQ2 的回答：用词和主题与点赞的关联有多稳

原始用词差异同时带着媒体与作者差异。

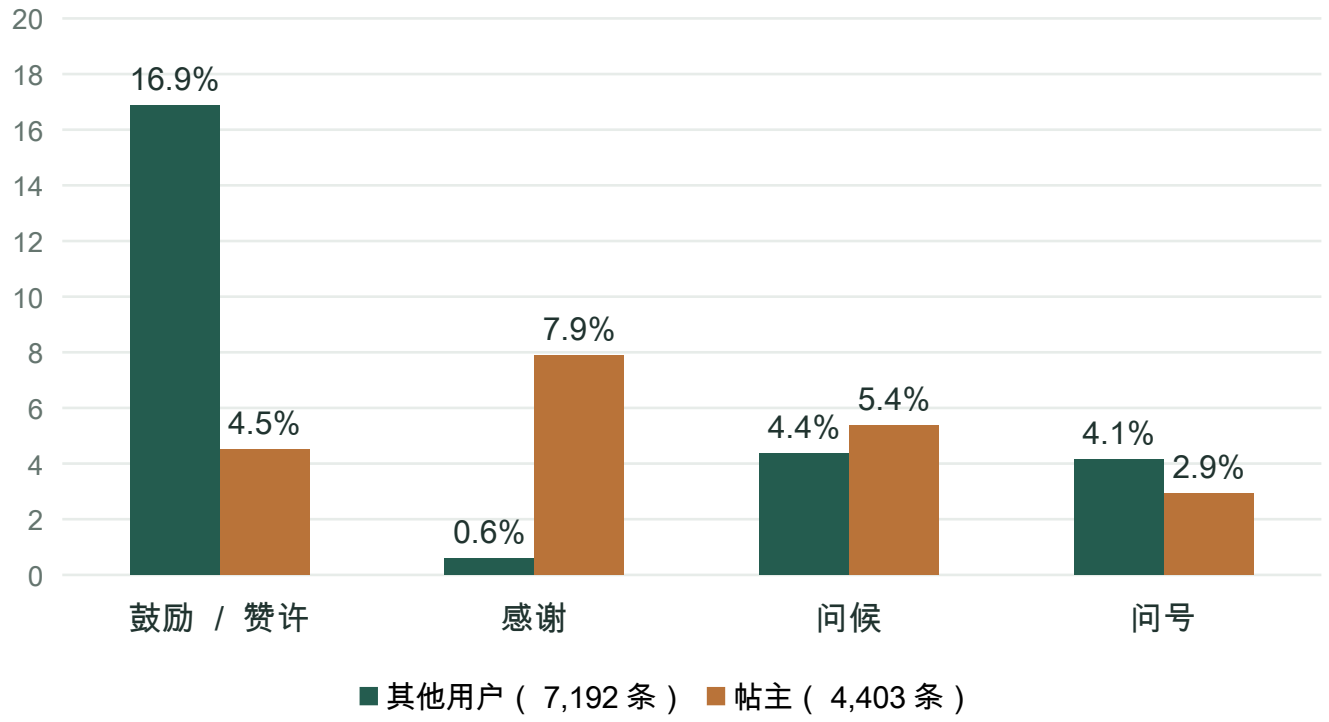
积极表达命中组的图片 / 视频占比 94.9% ，未命中组 69.1% 。 M3 调整后积极表达系数为− 0.086 、BH q=0.079 ；五项文字线索仅新增 0.065 个百分点 R^2 ，联合 p=0.130 。

换样本后的方向较一致，主题也没有补出稳定优势。

积极表达在多种处理下均为负，但 PPML 区间跨 0 ；主题权重联合 p=0.166 。现有记录对这些用词和主题的额外点赞关联，仍缺少足够稳定的证据；这不等于证明文字内容普遍无效。

RQ3 转向另一种反馈：评论里，用户说了什么，留言怎样被回应，又由多少人参与？

评论长度、词频与发言者角色



评论长度中位数： 6 字符

“加油” 612 条 / 431 人
“谢谢” 359 条 / 53 人

“加油”的使用面更广，“谢谢”的重复使用更集中。再按角色看，读者更常赞许，帖主更常感谢；只看词频，会把参与广度和重复回话混在一起。

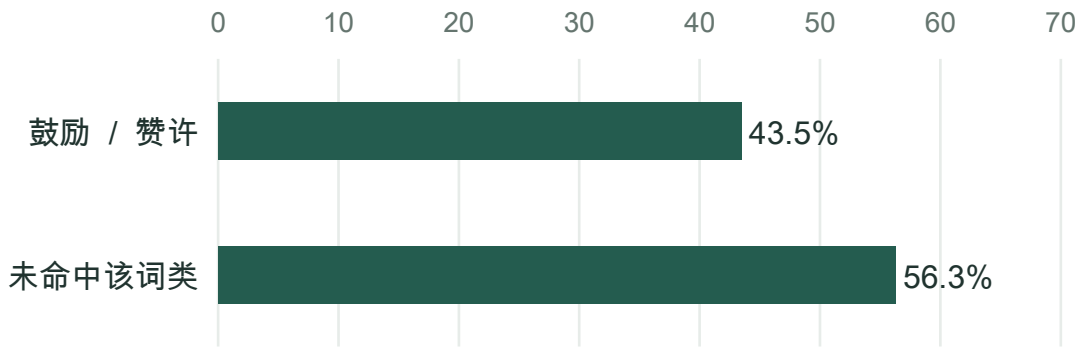
所以下一步把根评论与帖主回复配对：鼓励是否更易被回复，回复里又怎样表达？

词类命中率以各角色全部发言为分母，可重叠；角色按所在帖子确定。

鼓励留言是否更容易得到回应？感谢与回复覆盖不同

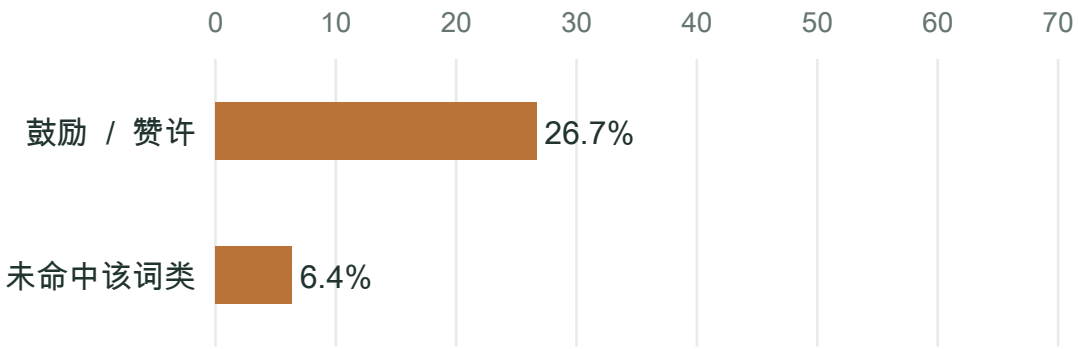
配对规则： 6,609 条外来根评论；从留言发出起 7 天内，查找明确指向该条留言的帖主直接回复。
根评论指直接发在帖子下、未指定回复对象的留言；有回复时，只取最早一条。

多少留言观察到 7 天内直接回复？



分母：各组全部外来根评论
513 / 1,180 ； 3,055 / 5,429

已回复记录中，最早回复多少含感谢？



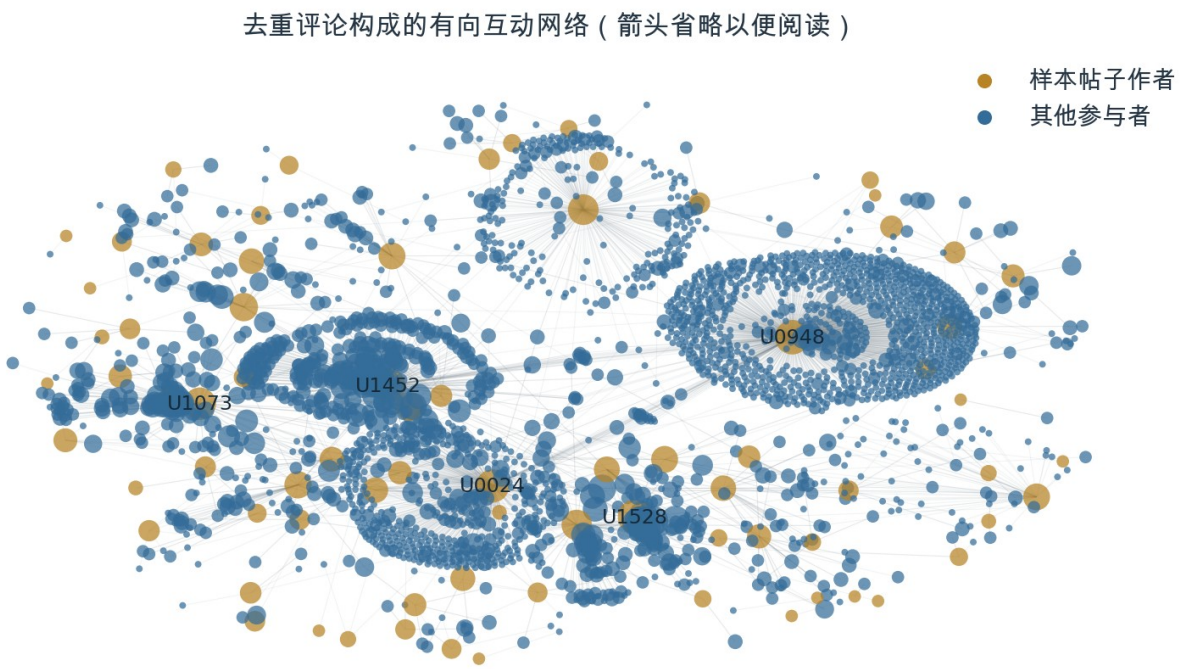
分母：已观察到直接回复的记录
137 / 513 ； 195 / 3,055

鼓励组的观测回复覆盖低 12.8 个百分点；但在已回复记录中，感谢词占比高 20.3 个百分点。

回复时更常致谢，不等于鼓励更容易被回。作者和留言情境可能不同；接下来看看谁在接话。

描述性对照，未作显著性或因果检验；未观察到回复，不等于实际没有回复。

评论关系网络：间接相连广，直接联系仍稀疏



2,932 个有边账号 · 4,069 条有向边

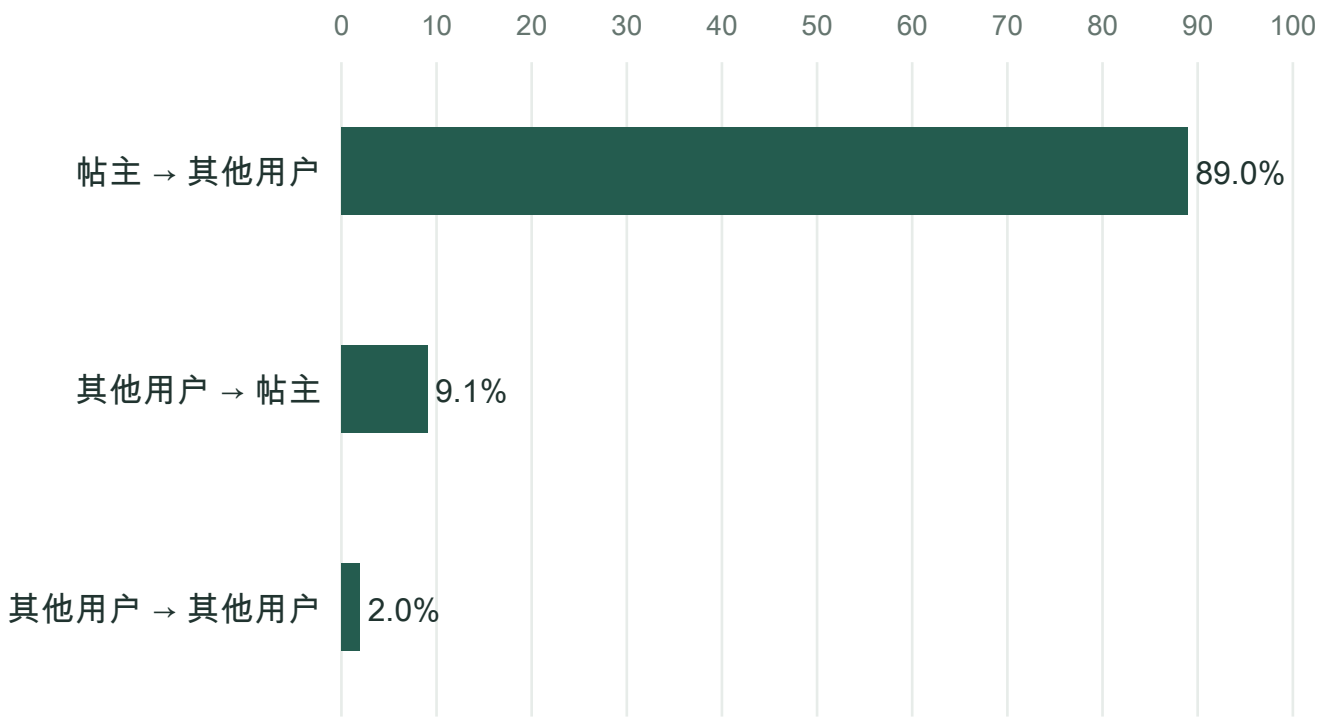
排除 84 次自我互动后，11,511 次事件合并成有向边；图中省略箭头，金色为样本帖作者。

共同面向帖主留言，就能把许多账号间接连起。忽略方向后，94.4% 处于最大连通部分；密度 0.0473% ，直接往来仍局限于少量账号配对。

这张图回答了账号怎样被连起来。谁在回复谁，下一页再把明确回复单独取出比较。

节点为账号；根评论者→帖主，明确回复者→被回复用户；同向多次互动累加为边权。

回话主要围绕帖主展开，用户彼此回复较少



4,361 次 · 89.0%

读者面向帖主留言后，明确回话大多由帖主发出。其他用户彼此回复只有 97 次，占 2.0% 。

因此，这批评论更常表现为“向帖主留言—帖主回应”，其他参与者相互回复的份额很小。

还需要分清：围绕一个账号有很多发言，究竟来自更多人，还是已有发送者反复出现？

分母为 4,902 次非自我明确回复，排除 6,609 条根评论； 89% 不是全部评论的回复率。

高互动量可能来自接触面广，或少数人反复往来

前 10 位账号接收了 54.0% 的互动。判断这种集中意味着什么，需把次数和人数放在一起。

匿名账号	样本帖作者	接收事件次数	不同发送者	这段记录中的突出形态
U1528	是	1,378	53	已有发送者反复留言
U0948	是	1,275	1,091	收到更多不同账号的留言
U0112	否	180	4	与极少数账号集中往来

U1528 与 U0948 接收次数接近，前者只有 53 位发送者，后者有 1,091 位。相同“声量”背后，可以是很不一样的参与范围。

U0112 的 180 次只来自 4 人。看评论区有多热闹，不能只数留言，还要看有多少人在参与。

次数为收到的非自我互动事件，人数为不同发送者；“非样本帖作者”不等于从不发帖。

RQ3 的回答：评论主要怎样形成往来

读者更常鼓励，帖主更常感谢；逐条配对后，含义更清楚。

直接配对进一步说明：鼓励组已回复记录中的感谢占比更高，但观测回复覆盖反而较低。回复怎样表达，与多少留言得到回应，需要分开判断。

这些发言主要围绕帖主组织，热闹的来源也不一样。

89% 的明确回复由帖主发给其他用户，用户相互回复仅 2% 。接收次数接近的账号，可以来自 53 人或 1,091 人；所以留言量既可能反映广泛参与，也可能是已有发送者反复出现。

看评论区是否热闹，既要看留言有没有得到回应，也要看这些往来涉及多少人。

研究局限：哪些判断还不能由这批记录回答

限制	它怎样影响结论	下一步需要什么
100 位作者，抽样机制不明	不能把样本内容比例和回复结构直接推广到全 Keep	更清楚的抽样框与作者覆盖
正文、评论覆盖不全	主题与网络代表不同子样本；未采到不等于未发生	补齐正文、评论、图像和视频内容
曝光、粉丝与采集时点缺失	累计点赞仍受未观测差异影响，固定效应不等于因果识别	统一发帖后 7 天，并记录实际曝光
词典与主题只是内容的部分表征	不能据用词判断情绪；主题区间未计入模型估计不确定性	语义复核、重复抽样与独立验证

后续先统一观察窗口，完整记录内容、参与人数和实际回复，再检验具体做法能否改变反馈。

成员分工 / Credit

陈霖

问题的提出
数据清洗
RQ1 ：内容与点赞的分布

董依心（ dyx ）

RQ2 ：文字、主题与点赞的关联
RQ3 ：评论中的回应与参与