Keep 社区
内容表达与互动反馈分析

哪些内容获得更多点赞反馈，评论又如何互动？

陈霖 · 董依心

研究背景、问题与预期

健身社区里，什么内容受到关注，人们又怎样交流？

- 健身社区既是用户记录运动的空间，也是分享感受、交流经验和获得同伴反馈的场所。
- 点赞是平台内最容易观察的反馈信号，评论则记录了用户之间如何交谈、谁在回应谁。对创作者来说，了解什么样的分享更容易获得反馈，有助于判断内容投入的方向；对平台来说，了解互动如何分配，有助于发现容易被忽视的用户，并评估是否需要设计新的互动支持。

三个具体问题	对应预期：可能出现的结果
RQ1 样本主要呈现什么内容，点赞怎样分布？	不同媒体的点赞反馈可能不同，高赞帖可能拉高均值；正文内容可能包含运动、生活分享等等各种内容。
RQ2 文本表达与主题是否与点赞有关？	自律、积极表达或提问可能对应较高点赞；调整作者与情境后，这些差异可能发生变化。
RQ3 评论的内容是什么，互动形成了什么样的网络？	读者和帖主之间、读者之间可能出现互动；评论量可能来自大范围互动或少数人的反复往来。

预期是待检验的可能解释，后文按相同RQ编号逐项回答。

数据来源与清洗

9,532

帖子 · 100位作者

11,595

去重后评论

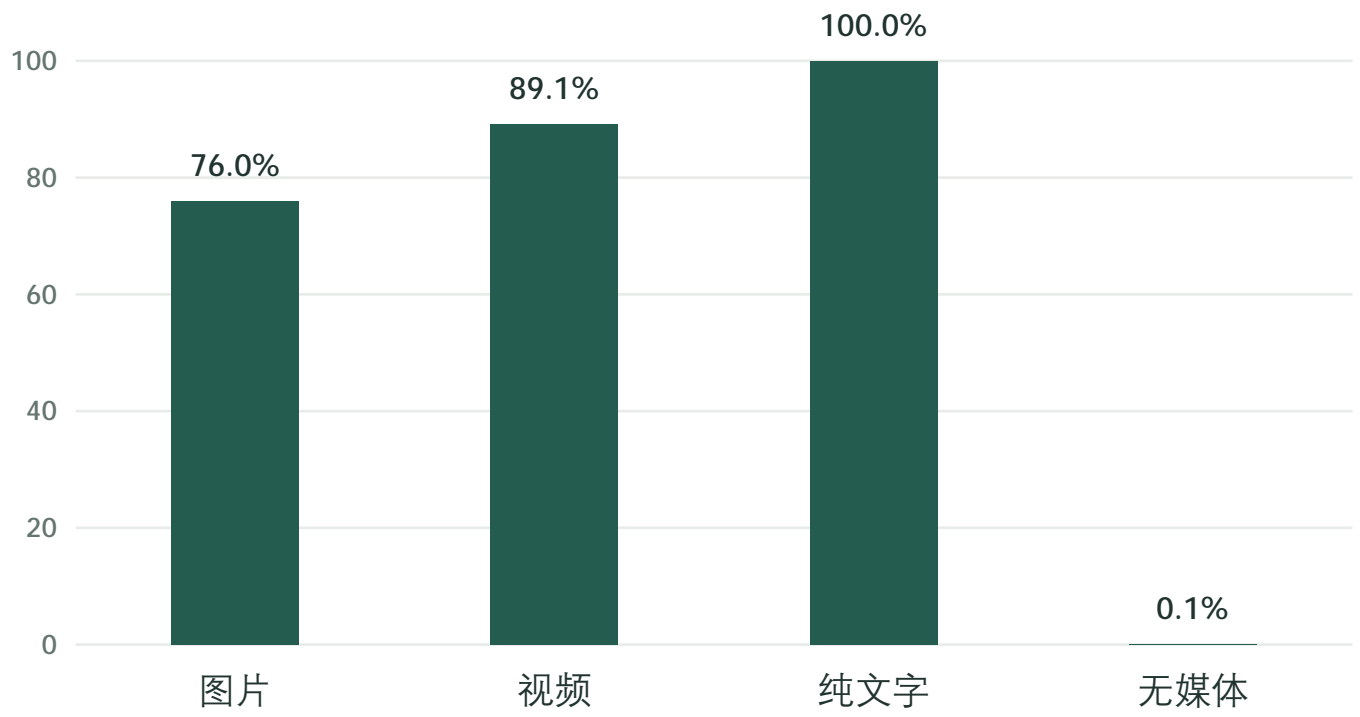
1,323

采集到评论的帖子

核查发现	处理方式	分析含义
1,916行重复评论	按评论ID去重，无字段冲突	避免同一发言被重复计入
3,984帖缺可用正文	保留；文字计数设0并另作标记	不能把缺失当作真实无文字
8,286帖点赞高于记录浏览数	使用累计点赞，不计算点赞率	不解释为曝光转化效率
仅1,323 帖有已采集评论	其余帖子的评论覆盖记为未知	不做评论数的全样本回归
原时间字段按UTC解析	发帖日期与时段统一转换为北京时间	转为国内用户统一日期

课程100位作者样本；帖子发表于2020年11—12月（UTC），评论最晚至2021年8月。

不同帖子/作者发布文字内容的比例



文本分析覆盖的记录数量

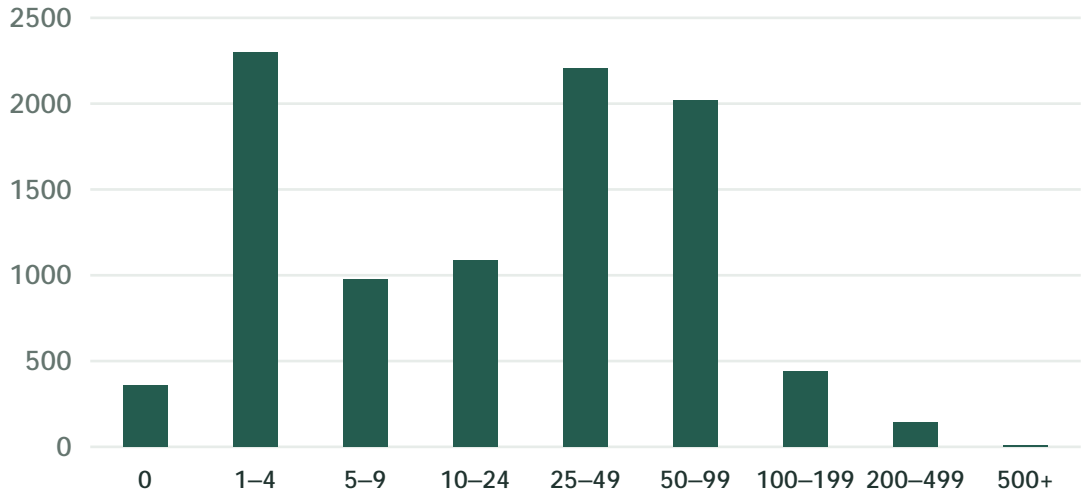
5,414帖有非空正文

不同作者的正文覆盖不均

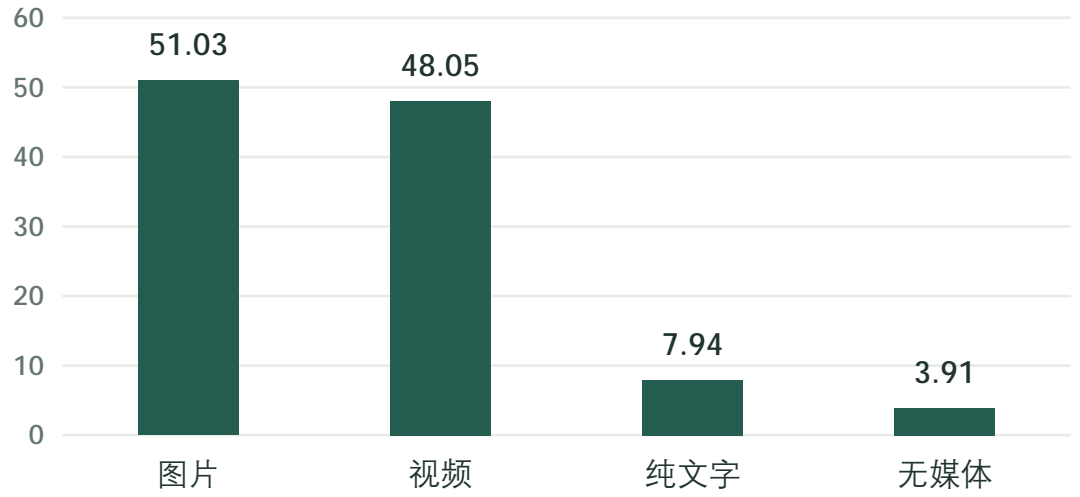
作者正文覆盖率中位数84.3%，5位作者完全没有可见正文；
主题结果主要代表正文记录较完整的作者。

图片和视频帖点赞更高，点赞量整体分布存在长尾

各点赞区间中的帖子数



不同媒体的平均点赞数

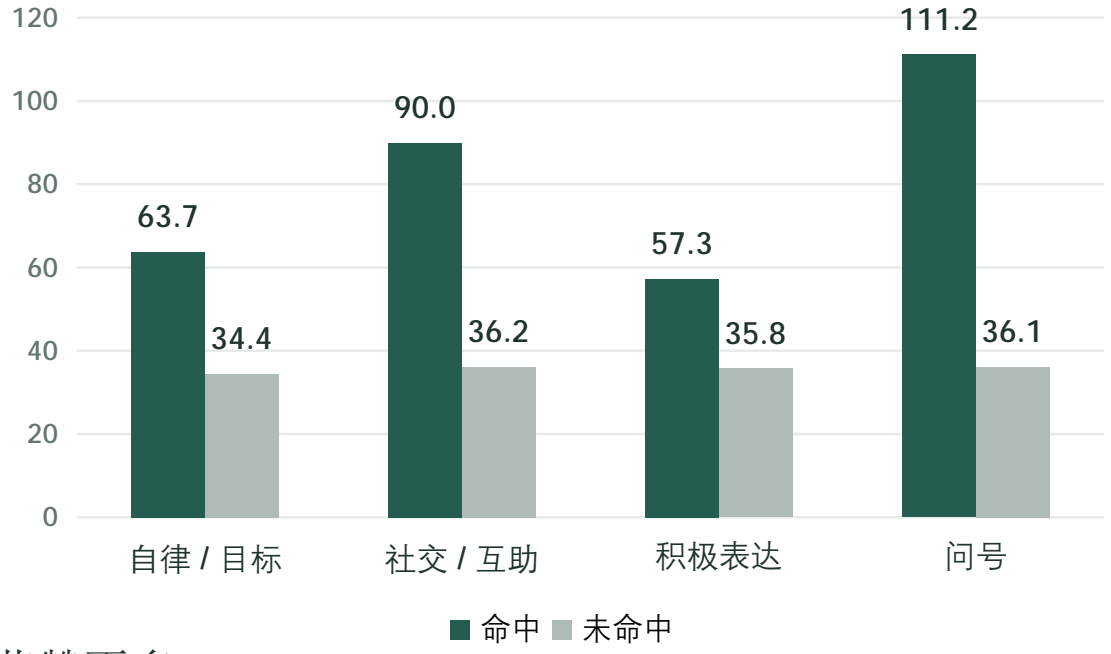


均值37.05 · 中位数25 · 95%分位109.45 · 最高5,126

少量高赞帖拉高均值，在回归分析中需对点赞数取对数处理；不同媒体均值也相差约一个数量级。

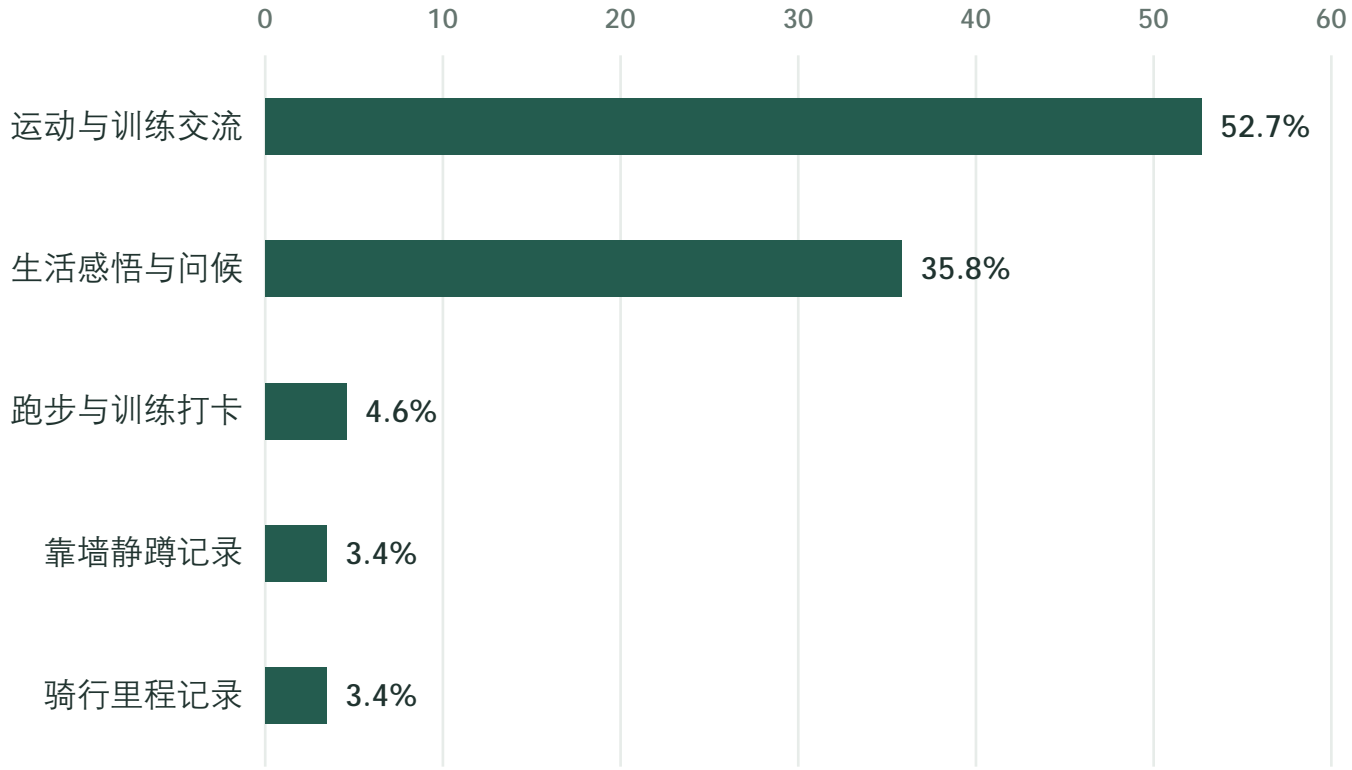
不同的文字表达内容对应的点赞情况

文字变量	定义
自律 / 目标 D	坚持、自律、目标、第N天等词表或模式
社交 / 互助 S	大家、小伙伴、谢谢、一起等词表
积极表达 P	开心、快乐、喜欢、哈哈等词表
问号 Q	全角或半角问号，出现记1



命中自律、社交、积极表达、问号四类表达内容的文本内容获赞更多。

帖子正文主题主要包括运动和生活



采用非负矩阵分解（NMF）划分主题

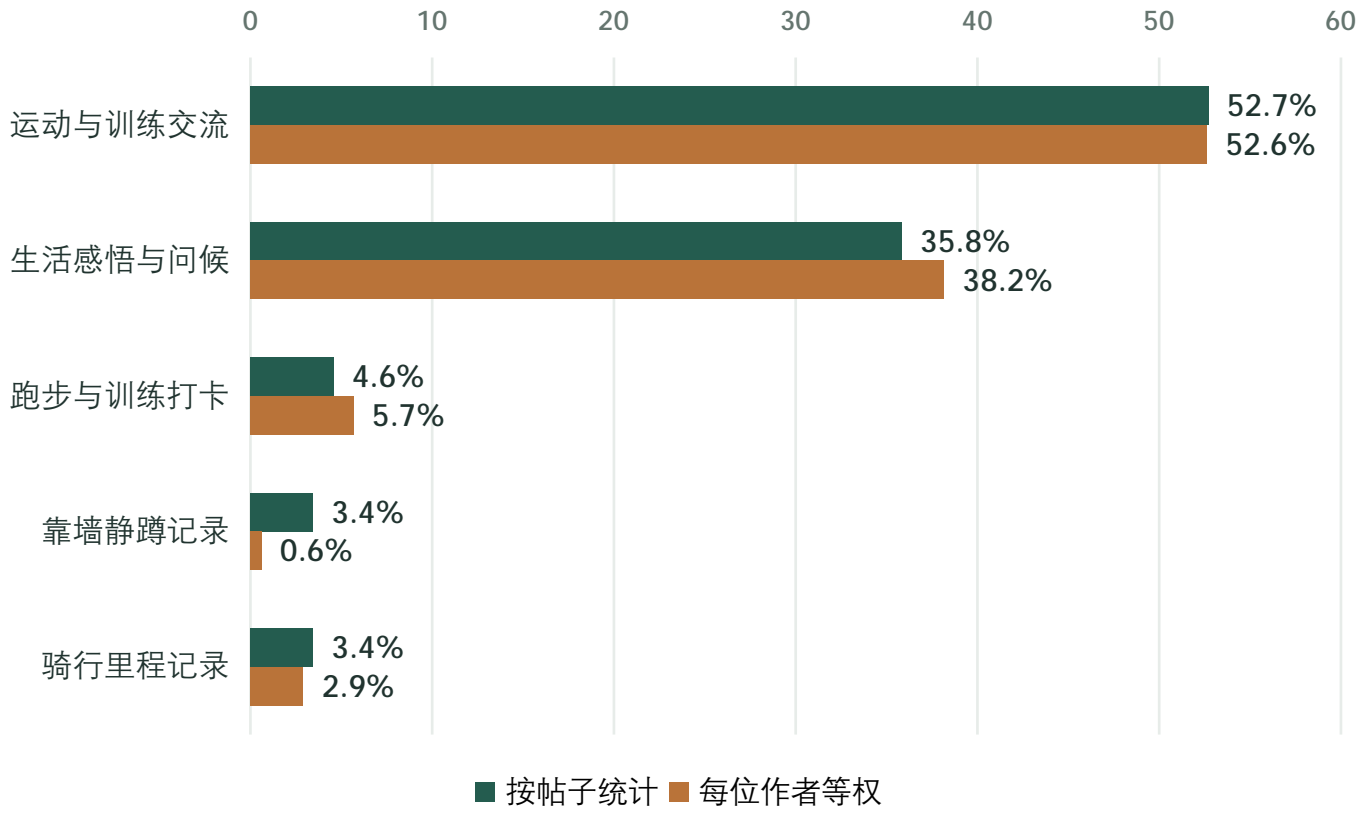
获取可分类的2,470帖，来自86位作者

训练交流：运动、减脂、训练、拉伸
生活问候：人生、生活、早安、美好

前两类合计**88.5%**。有效正文不仅讨论如何训练，也经常写感受、生活和问候，不能把健身社区里的文字都当成运动成绩记录。

TF-IDF + NMF，主题数预先固定为5；名称依据词项与正文确定，不参考点赞。

常见主题vs.少数人的高频记录



进行作者等权分析
“静蹲”来自少数作者高频记录

静蹲主题的85条主导文档中，78条来自同一作者；作者等权方法可以排除高产作者的重复贡献。

运动与训练交流、生活感悟与问候两大类仍是内容的主线，部分小主题的份额则会被少数作者的持续记录放大。

两组沿用同一主题分类；作者等权先计算每人的主题比例，再对86位作者平均。

RQ1的回答：样本主要呈现什么内容，点赞怎样分布？

点赞数分布存在长尾；图片和视频贴收到的点赞多于纯文字帖

图片和视频帖平均51赞、48赞，纯文字与无媒体平均8赞、4赞；命中自律、社交、积极表达、问号四类表达内容的文本内容获赞更多；整体点赞均值37.05高于中位数25，少量高赞把分布拉出长尾；需要对点赞数取对数后再做回归分析。

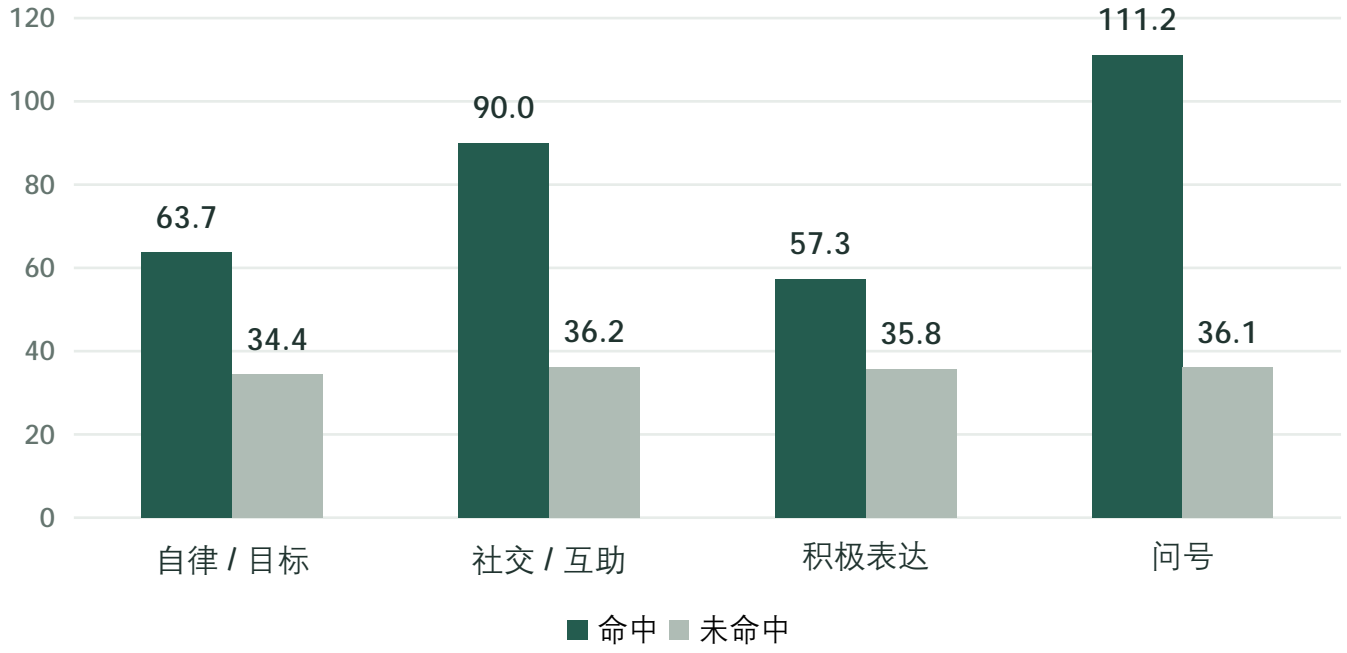
正文内容主要包含运动交流和生活分享；部分主题来自个别作者的高频贡献

运动交流52.7%、生活问候35.8%在作者等权处理后仍是占比最高的主题。静蹲主题占比由3.4%降至0.6%，其中85帖有78帖来自一人，覆盖面窄、个别作者贡献多。

RQ2：把媒体形式、作者与日期等其他因素一起纳入比较后，文字表达或主题与点赞还有多大关联？

范围：9,532帖；主题比例仅代表2,470条有效正文、86位作者。

文字表达与点赞情况间的联系受媒体形态等其他因素影响



积极表达组的进一步比较

组别	帖数	图片/视频
命中	574	94.9%
未命中	8,958	69.1%

命中/不命中组的媒体分布构成差异

文字词表只识别字面线索，不是情绪量表；特征可重叠。

用作者与日期固定效应，进一步改善比较

主模型 M3：$\ln(1 + \text{点赞数}) = \beta'X + \gamma'C + \alpha_{\text{作者}} + \delta_{\text{日期}} + \varepsilon$

X：文本长度（对数）、自律、社交、积极、问号。C：正文可用、话题、表情数、课程分享，以及媒体、业务类型、时段。

模型	调整范围	R^2	积极表达系数 / 原始p
M1	X + C + 已记录作者属性	0.563	−0.050 / 0.285
M2	X + C + 作者固定效应	0.685	−0.087 / 0.016
M3 主模型	X + C + 作者、日期固定效应	0.688	−0.086 / 0.016

加入作者固定效应后拟合度提高，提示作者差异值得考虑；积极表达在M1中就已为负。

M3没有保留特定文本表达的优势

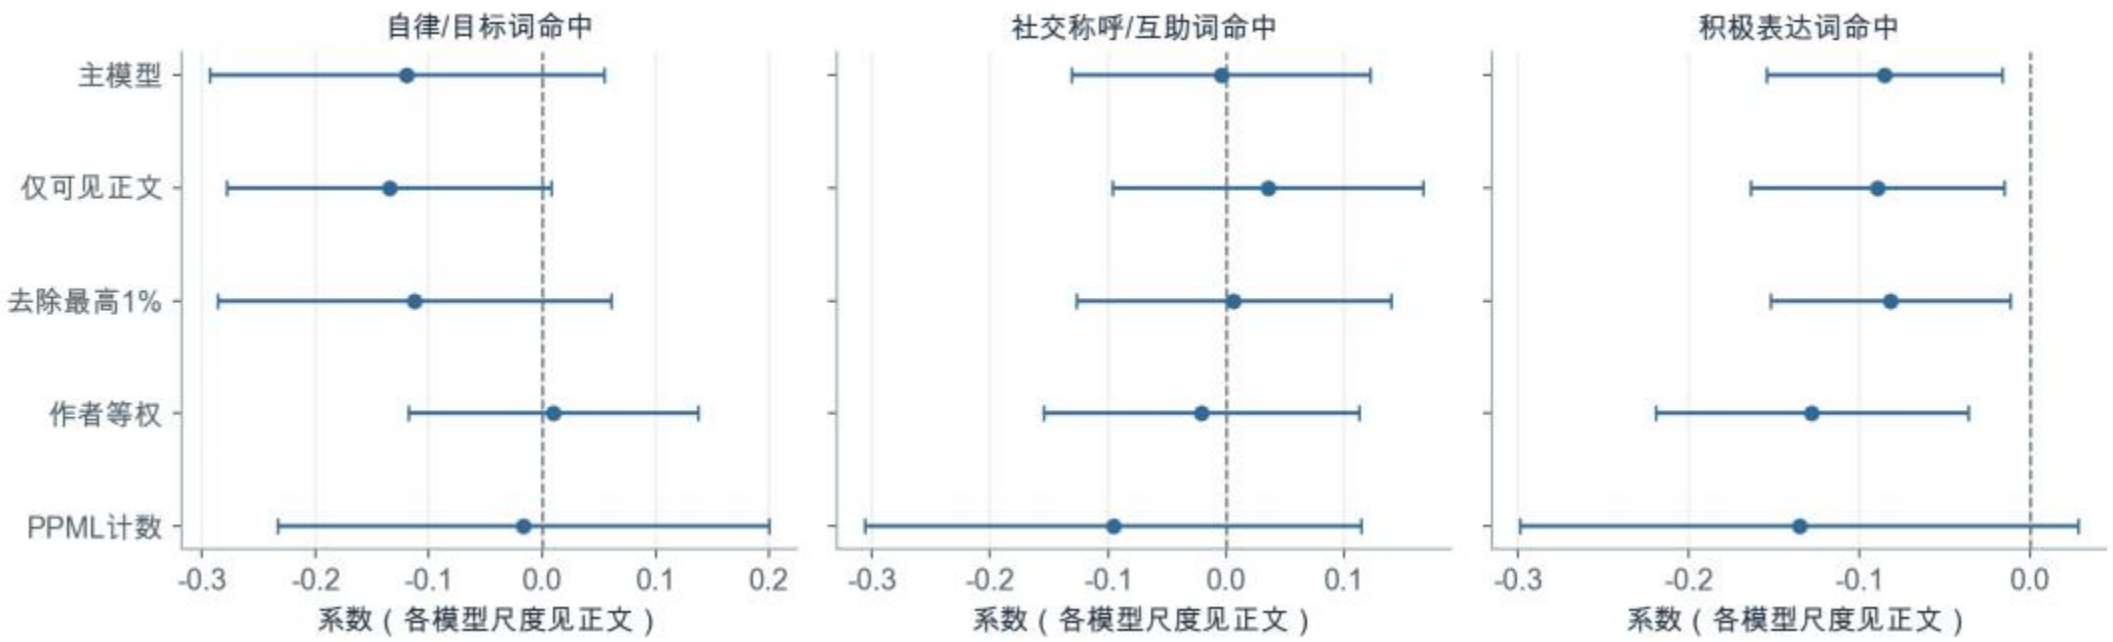
文字特征	系数β	原始95%区间	p	BH q
长度 ln(1+字数)	0.028	[−0.008, 0.064]	0.130	0.293
自律 / 目标	−0.119	[−0.293, 0.054]	0.176	0.293
社交 / 互助	−0.004	[−0.131, 0.122]	0.946	0.946
积极表达	−0.086	[−0.155, −0.016]	0.016	0.079
问号	0.108	[−0.100, 0.316]	0.307	0.383

以积极表达为例：β = −0.086

原始p = 0.016
BH q = 0.079

多重检验校正后，所有文字特征证据均未达到5%标准，不足以推出“特定用词能提升、减少点赞”的结论

敏感性分析



敏感性分析可见结果与主模型相近。以积极表达为例，筛选可见正文、去高赞、作者等权后系数均为负；100次逐作者剔除也全部为负；PPML仍不显著。

主题权重能否补充文本表达以外的点赞关联？

主题模型：M3原有线性项 + $\Sigma\ \theta_k\ w_k$ （省去“运动与训练交流”权重作为参照）

相对训练交流的主题权重	系数θ	原始95%区间	p	BH q
靠墙静蹲记录	−0.315	[−0.636, 0.005]	0.054	0.107
骑行里程记录	0.018	[−0.523, 0.558]	0.948	0.948
跑步与训练打卡	−0.471	[−1.048, 0.105]	0.108	0.144
生活感悟与问候	−0.144	[−0.278, −0.010]	0.035	0.107

生活问候权重相对训练交流获得的点赞数更少，但其原始p = 0.035、BH q = 0.107，尚无足够明确的证据。

RQ2的回答：文本表达与主题是否与点赞有关？

文本表达与点赞量间的相关性受媒体与作者差异的影响

以积极表达为例，命中组的图片/视频占比94.9%，未命中组69.1%，媒体形态分布存在差异。回归主模型M3调整后积极表达项的系数为−0.086、BH q=0.079，其他各主要变量结果均不显著。敏感性分析结果与主模型一致。

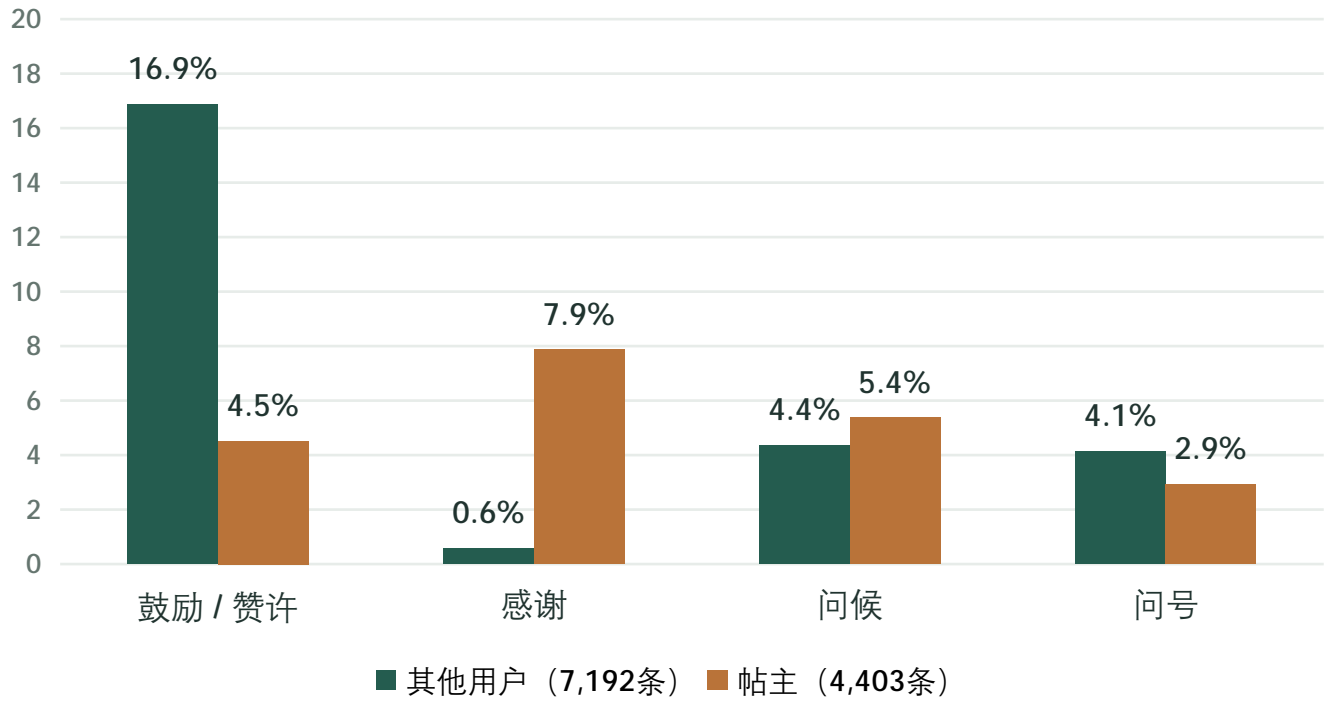
主题分析显示，文本主题对点赞量不贡献显著影响。

主题权重联合p=0.166，现有记录中主题与点赞的关联性仍缺少足够稳定的证据。

RQ3：评论的内容是什么，互动形成了什么样的网络？

结果为观察性关联；词典与主题只覆盖部分文字信息，缺少真实曝光等条件。

评论长度、词频与发言者角色



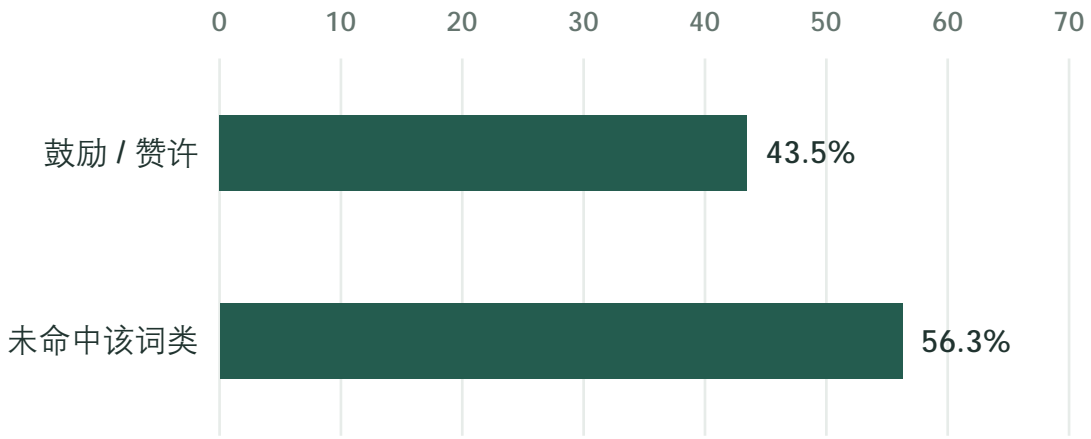
评论较短
长度中位数：6字符

“加油”612条 / 431人
“谢谢”359条 / 53人

- “加油”的使用面更广，“谢谢”的重复使用更集中。
- 按角色看，读者更常赞许，帖主更常感谢。

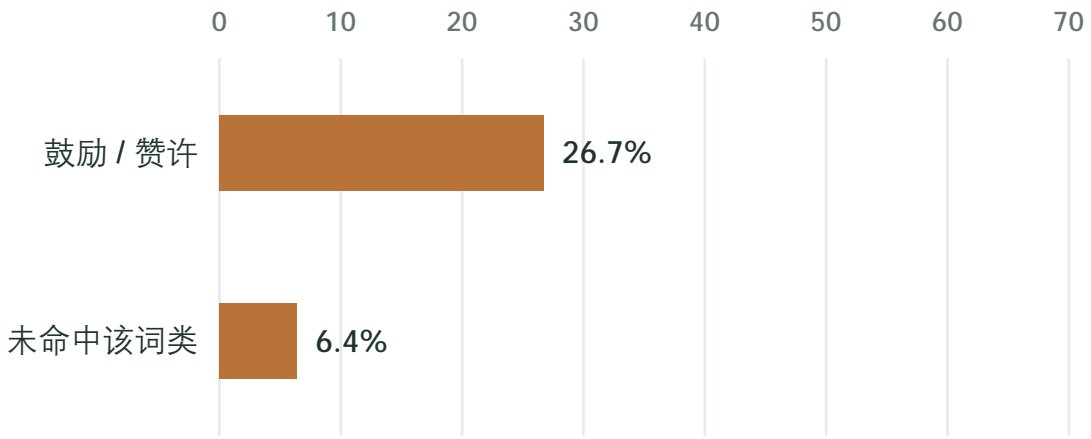
鼓励性留言是否更容易得到回应？

7天内直接回复



分母：全部根评论
513 / 1,180；3,055 / 5,429

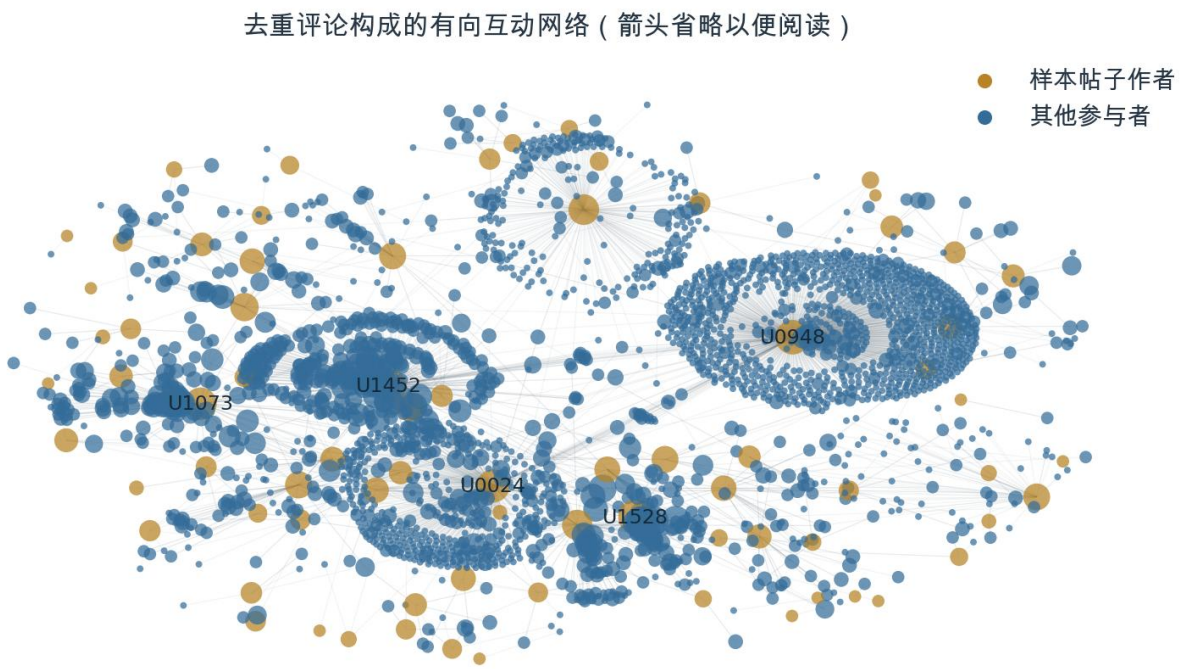
最早回复包含感谢的比例



分母：已观察到直接回复的记录
137 / 513；195 / 3,055

鼓励组的观测回复覆盖低12.8个百分点；但在已回复记录中，感谢词占比高20.3个百分点。
总体而言，鼓励组根评论收到了更多感谢类评论，呈现出鼓励-感谢的互动模式

评论关系网络：间接相连广，直接联系仍稀疏

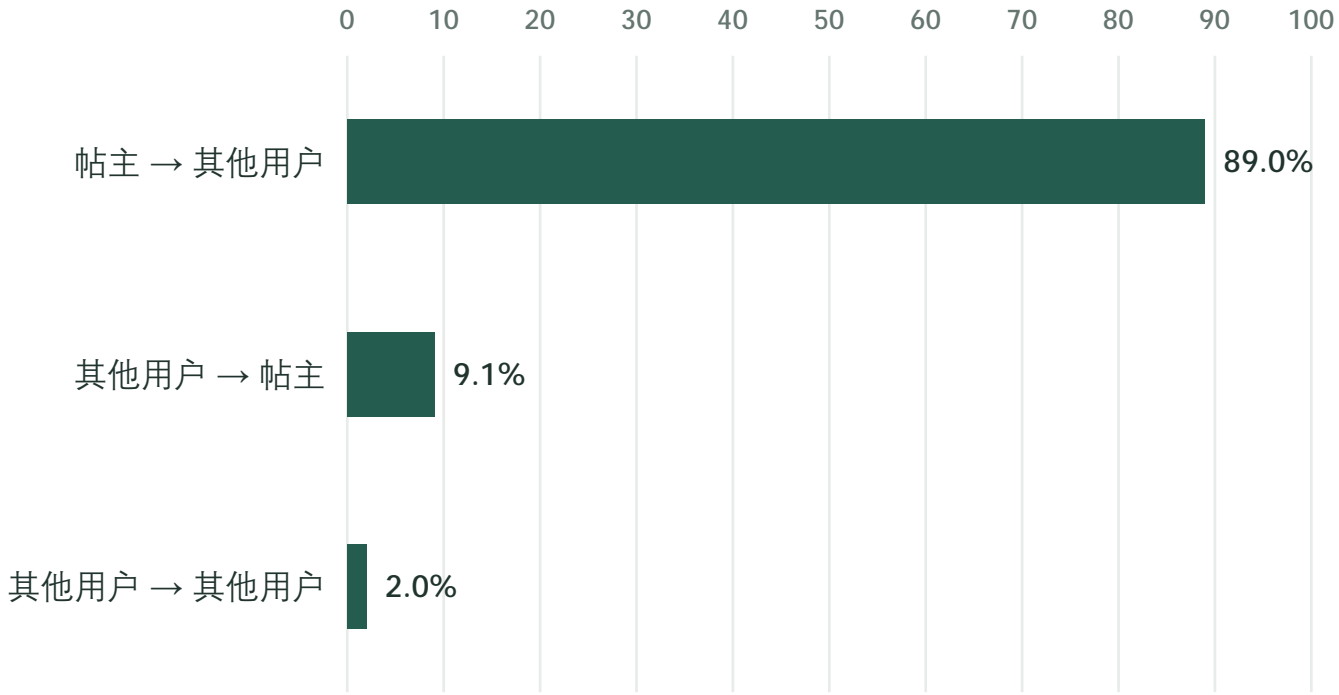


2,932个有边账号 · 4,069条有向边

排除84次自我互动后，11,511次事件合并成有向边；图中省略箭头，金色为样本帖作者。

许多账号间的间接连接来自于共同面向帖主留言。忽略方向后，94.4%处于最大连通部分；密度0.0473%，直接往来仍局限于少量账号配对。

回话主要围绕帖主展开，用户彼此回复较少



读者面向帖主留言后，明确回话大多由帖主发出（**4361**次，**89.0%**）。其他用户彼此回复只有**97**次，占**2.0%**。

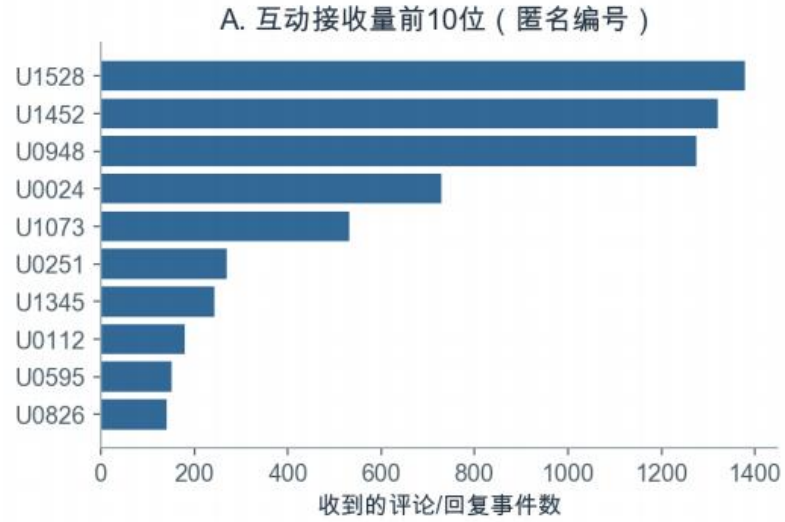
因此，这批评论更常表现为“向帖主留言—帖主回应”，其他参与者相互回复的份额很小。

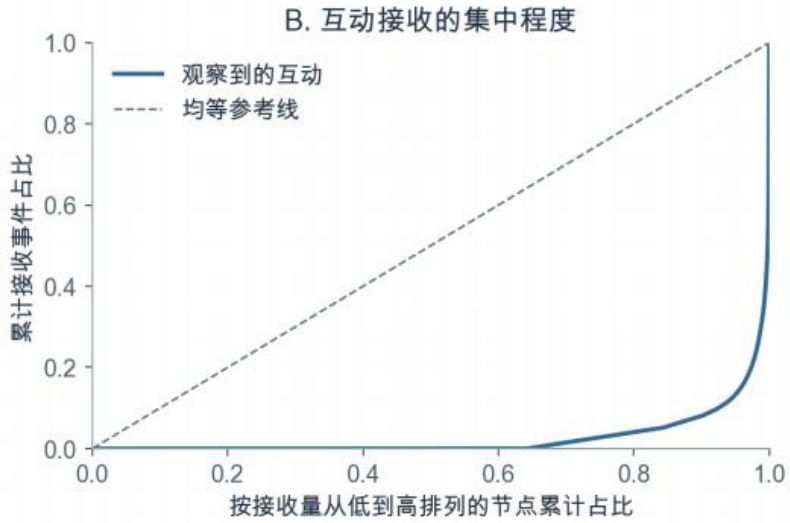
高互动量可能来自接触面广，或少数人反复往来

前10位账号接收了54.0%的互动。

匿名账号	帖作者	接收次数	发送者	突出形态
U1528	是	1,378	53	已有发送者反复留言
U0948	是	1,275	1,091	收到更多不同账号的留言
U0112	否	180	4	与极少数账号集中往来

U1528与U0948接收次数接近，前者只有53位发送者，后者有1,091位。相同“声量”背后是很不同的互动范围。





次数为收到的非自我互动事件，人数为不同发送者；“非样本帖作者”不等于从不发帖。

双向往来体现留言与回话，首周关系较为互惠

- 全部互动网络的互惠率为**49.6%**，表示近一半有向连接同时存在反方向的连接。例如，用户给帖主留言，帖主又回话给该用户，这对账号便形成双向连接。指标按账号之间是否存在双向关系计量，每条连接贡献相同权重，概括了关系层面的往来。
- 只保留明确回复后，互惠率为**29.9%**。限定为明确回复后，去除了双向互动中根评论的部分，两项互惠率的差异，使“留言加回话”这一主要往来形式在结构上更加清楚。

观察窗口	非自我事件数	有边账号数	有向边数	互惠率	前10 位接收占比
全部已采集互动	11,511	2,932	4,069	49.6%	54.0%
发帖后7 天内	9,451	1,376	2,278	74.1%	48.3%

- 首周记录呈现更多双向连接、较分散的事件接收；纳入较晚的账号和评论后，整体构成随之变化。

RQ3的回答：评论的内容是什么，互动形成了什么样的网络？

读者更常鼓励，帖主更常感谢；存在读者评论-帖主回复的典型模式

鼓励组根评论收到了更多感谢类评论，呈现出鼓励-感谢的互动模式。

这些发言主要围绕帖主组织，发言覆盖范围不同。

读者面向帖主留言后，明确回话大多由帖主发出。接收到相近回复数的用户，其覆盖的互动范围不同。首周记录呈现更多双向连接、较分散的事件接收；“留言加回话” 形式在结构清晰。

研究局限：哪些判断还不能由这批记录回答

限制	它怎样影响结论	下一步需要什么
100位作者，抽样机制不明	不能把样本内容比例和回复结构直接推广到全Keep	更清楚的抽样框与作者覆盖
正文、评论覆盖不全	主题与网络代表不同子样本	补齐正文、评论、图像和视频内容
曝光、粉丝与采集时点缺失	累计点赞仍受未观测差异影响，固定效应不等于因果识别	统一发帖后7天，并记录实际曝光
词典与主题只是内容的部分表征	不能据用词判断情绪；主题区间未计入模型估计不确定性	语义复核、重复抽样与独立验证

改进方式：统一观察窗口，完整记录内容、参与人数和实际回复，再检验具体做法能否改变反馈。

成员分工 / Credit

陈霖

问题提出
数据清洗
RQ1：内容与点赞的分布

董依心、

RQ2：文字、主题与点赞的关联
RQ3：评论中的回应与参与