PRIVATE GEOMETRY PREVIEW - NOT OFFICE RENDER - revised page 1

Keep 社区

内容表达与互动反馈分析

哪些内容获得更多点赞反馈，评论又如何互动？

老师意见修订版 · 正文口径与测量效度复核

陈霖 · 董依心

PRIVATE GEOMETRY PREVIEW - NOT OFFICE RENDER - revised page 2

研究背景、问题与预期

健身社区里，什么内容受到关注，人们又怎样交流？

Keep既记录运动，也承载经验、感受与生活分享。点赞体现可见反馈，评论记录谁在接话。
创作者关心什么内容得到关注；平台则关心互动是否集中在少数账号、是否有更多人参与。

三个具体问题	对应预期：可能出现的结果
RQ1 样本覆盖、媒体与点赞怎样分布？	媒体反馈可能不同，高赞帖可能拉高均值； 正文也可能同时包含运动与生活分享。
RQ2 可观测文字线索与成分是否与点赞相关？	指定字面线索可能对应点赞差异； 需检查测量、正文覆盖与作者内比较。
RQ3 评论说什么，形成怎样的互动网络？	读者与帖主、读者彼此都可能互动； 评论量可能来自广泛参与或少数人反复往来。

预期是待检验的可能解释，后文按相同RQ编号逐项回答。

PRIVATE GEOMETRY PREVIEW - NOT OFFICE RENDER - revised page 3

数据来源与清洗

9,532

帖子 · 100位作者

11,595

去重后评论

1,323

采集到评论的帖子

核查发现	处理方式	分析含义
1,916行重复评论	按评论ID去重，无字段冲突	避免同一发言被重复计入
3,984帖缺可用正文	保留；文字计数设0并另作标记	不能把缺失当作真实无文字
8,286帖点赞高于记录浏览数	使用累计点赞，不计算点赞率	不解释为曝光转化效率
仅1,323帖有已采集评论	其余帖子的评论覆盖记为未知	不作评论数的全样本回归
原始时间字段按UTC解析	模型日期与时段统一为北京时间	便于按国内用户的发布情境比较

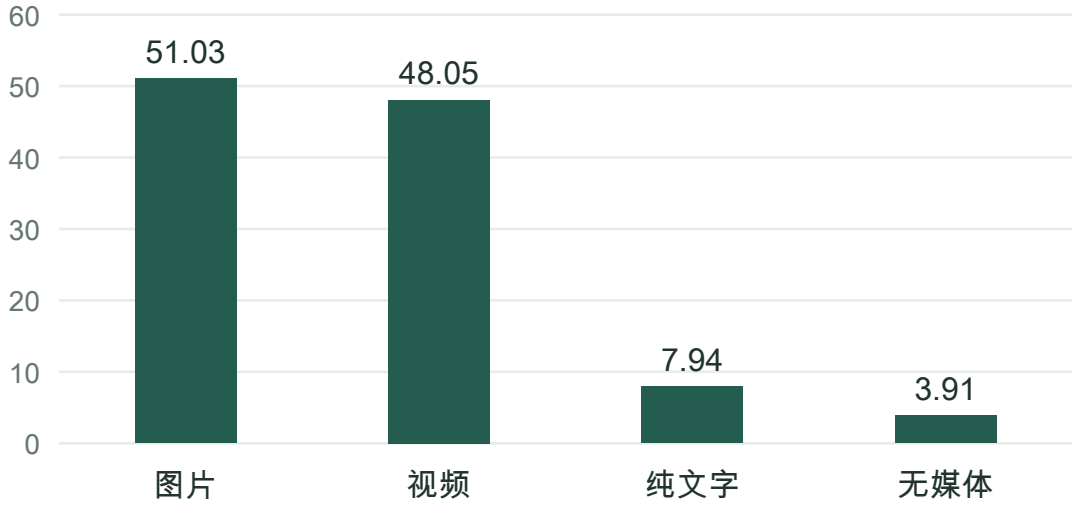
原始正文可见5,548帖；清理后非空5,414帖；NMF权重另有2,470帖、86位作者。
三种口径回答不同范围的问题；缺失标记不能恢复未记录的文字。

课程100位作者样本；帖子发表于2020年11—12月（UTC），评论最晚至2021年8月。

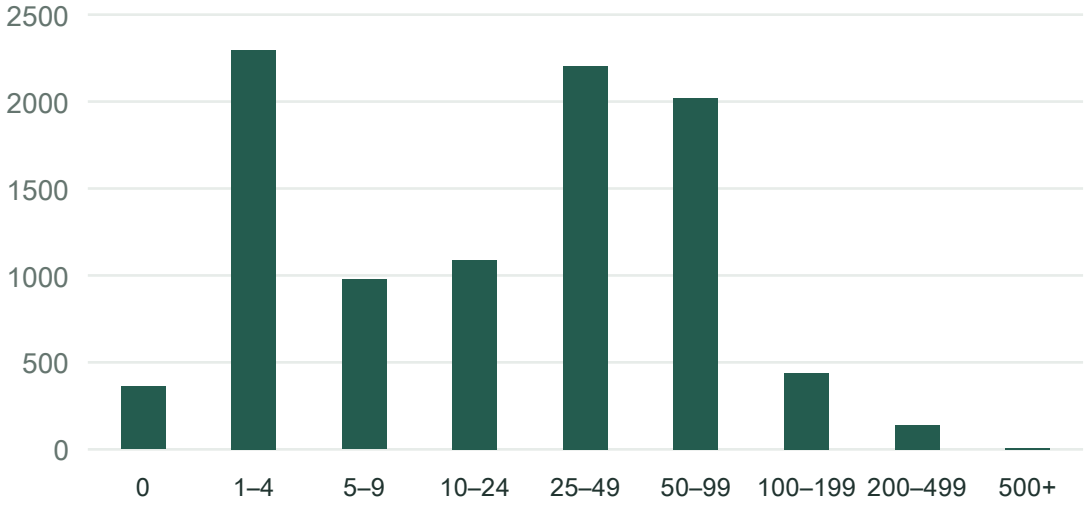
PRIVATE GEOMETRY PREVIEW - NOT OFFICE RENDER - revised page 4

图片和视频帖点赞更高，整体分布同时存在长尾

不同媒体的平均点赞



点赞区间中的帖子数



均值37.05 · 中位数25 · 95%分位109.45 · 最高5,126

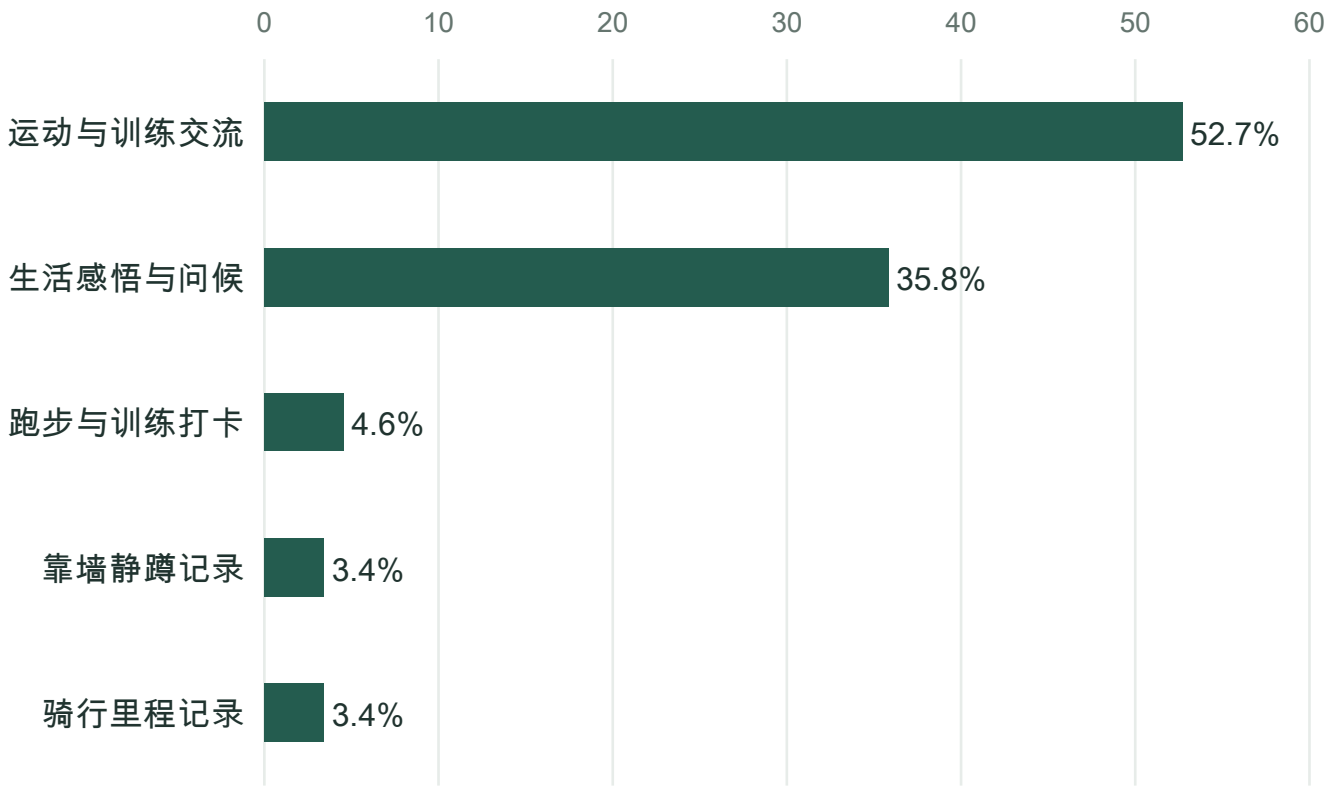
少量高赞帖拉高平均数，均值不能代表普通帖；媒体均值也相差约一个数量级。

媒体形式和点赞分布说明了反馈的基本差异；接着看有正文的帖子主要在写什么。

两图为原始描述；右图显示各点赞区间的帖子数，区间宽度不同，不表示概率密度。

PRIVATE GEOMETRY PREVIEW - NOT OFFICE RENDER - revised page 5

NMF成分占比：不等于真实内容分类



2,470帖 · 86位作者

TF-IDF + NMF，固定提取5个成分

训练交流：运动、减脂、训练、拉伸
生活问候：人生、生活、早安、美好

前两个主导成分合计88.5%，只是旧模型的数值分配；不能据此认定88.5%的正文在语义上确实属于这两类。

每帖取最高权重，仅用于这张描述图；原回归使用连续权重，同帖可有多个成分。

沿用原成分名称便于核对，尚未经语义效度验证；占比是主导成分份额。

PRIVATE GEOMETRY PREVIEW - NOT OFFICE RENDER - revised page 6

分类覆盖与语义：五成分不能当作完整分类

全样本中的三种记录状态

Native chart: geometry placeholder

语义与结构都需要复核

60条筛查	帖数
支持原名称	40
仅部分支持	6
不支持所分名称	12
信息不足	2

静蹲类中有山河感悟、口罩提醒；
跑步类中有绘画、出行和学期感受。

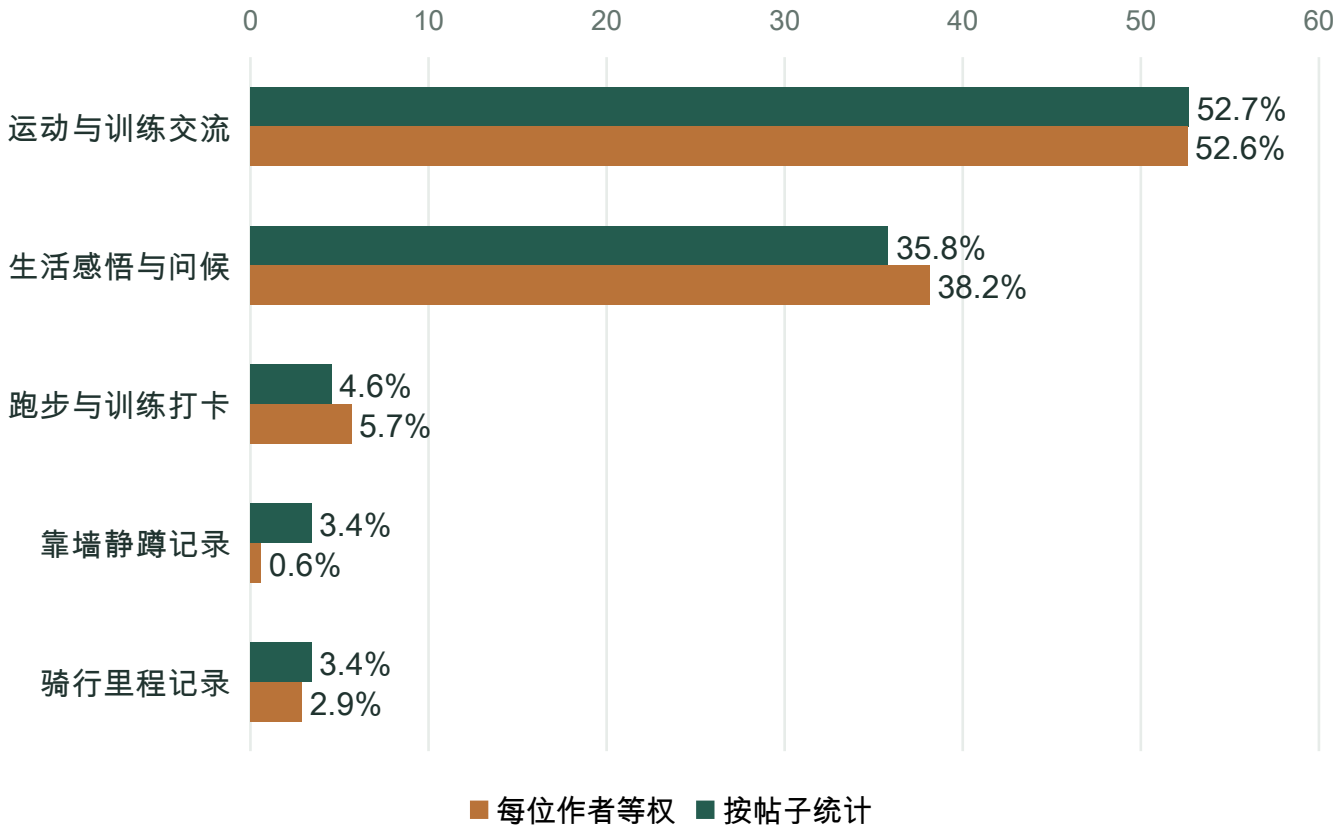
2,470 / 5,414 = 45.6%

删重后静蹲不再单列，出现含
早餐、咖啡等词的新成分；新成分同样待验证。

未入模 ≠ 没有主题；无正文 ≠ 无图像 / 视频内容。

PRIVATE GEOMETRY PREVIEW - NOT OFFICE RENDER - revised page 7

成分份额也受到高产作者与重复记录影响



静蹲：3.4% → 0.6%

85条主导文档中，78条来自同一作者。作者等权汇总减少了这类重复贡献，但没有修复拟合阶段的模板影响。

原训练成分52.7% → 52.6%，生活成分35.8% → 38.2%。这些仍是成分份额，不能代替语义验证。

作者等权调整的是成分描述份额，不修复拟合过程及名称的语义问题。

两组沿用冻结成分；作者等权描述只改变汇总权重，不改变原NMF拟合。

PRIVATE GEOMETRY PREVIEW - NOT OFFICE RENDER - revised page 8

RQ1的回答：这批帖子的内容和点赞怎样分布

媒体不同，收到的点赞并不均匀。

图片和视频帖平均约51、48赞，文字与无媒体约8、4赞。整体均值37.05高于中位数25，少量高赞把分布拉出长尾；单用平均数会高估普通帖子的反馈水平。

正文内容还不能用五个旧名称完整概括。

2,470帖进入NMF，只占非空正文45.6%。语义抽查和删重诊断提示错配与结构依赖；旧名称只能作为探索性成分索引。

RQ2接着问：在可观测正文范围内，指定文字线索与点赞的条件关联有多稳？

PRIVATE GEOMETRY PREVIEW - NOT OFFICE RENDER - revised page 9

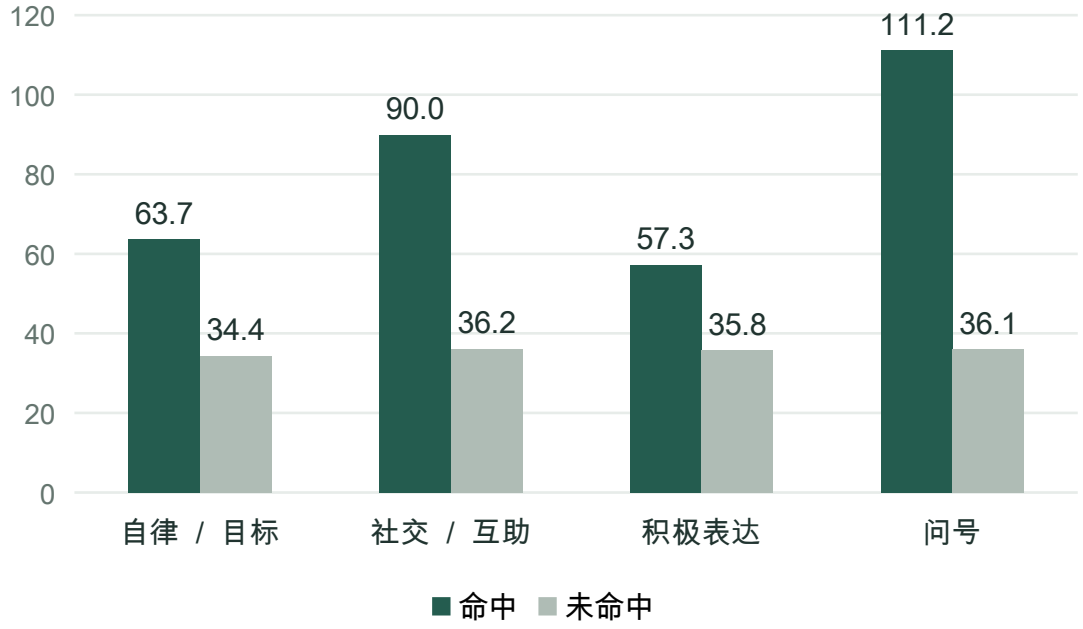
不同文字表达的原始点赞有差异

五项文字变量	定义与例子
正文长度 L	ln(1+清理后字符数)
自律 / 目标 D	坚持、自律、目标、第N天等
社交 / 互助 S	大家、小伙伴、谢谢、一起等
积极表达 P	开心、快乐、喜欢、哈哈等
问号 Q	全角或半角问号，出现记1

三类词汇规则 + 问号；除长度外，命中记1，可同时命中。

回归结果变量：ln(1+点赞数)，
用于处理RQ1看到的点赞长尾。

各词类的原始平均点赞



四类命中组的原始均值都较高。
下一步检查：媒体和作者构成是否也不同？

词表识别字面线索，不是情绪量表；各词类可重叠，图中原始均值未作调整。

PRIVATE GEOMETRY PREVIEW - NOT OFFICE RENDER - revised page 10

三类词汇 + 问号：为什么区分，分别观察什么

变量	分类依据 / 例词	不能据此推出
自律 / 目标词	目标和行动进度：坚持、目标、打卡、完成	真实自律人格或训练完成情况
社交 / 互助词	面向他人：大家、一起、谢谢、请教	已经发生互助或关系更强
积极表达词	积极感受或赞许：开心、喜欢、棒、哈哈	已经准确判断情绪；未处理反讽否定
问号	正文出现？或 ？：句式标点线索	确实在求助；反问也会命中

3,891 / 5,414 = 71.9% 的非空正文未命中任何规则；词典只覆盖局部表达。

PRIVATE GEOMETRY PREVIEW - NOT OFFICE RENDER - revised page 11

语义允许交叉，但现有变量未显示明显数值共线性



完整M3：182 / 182 满秩

最大两两相关 0.119
作者内最大相关 0.085

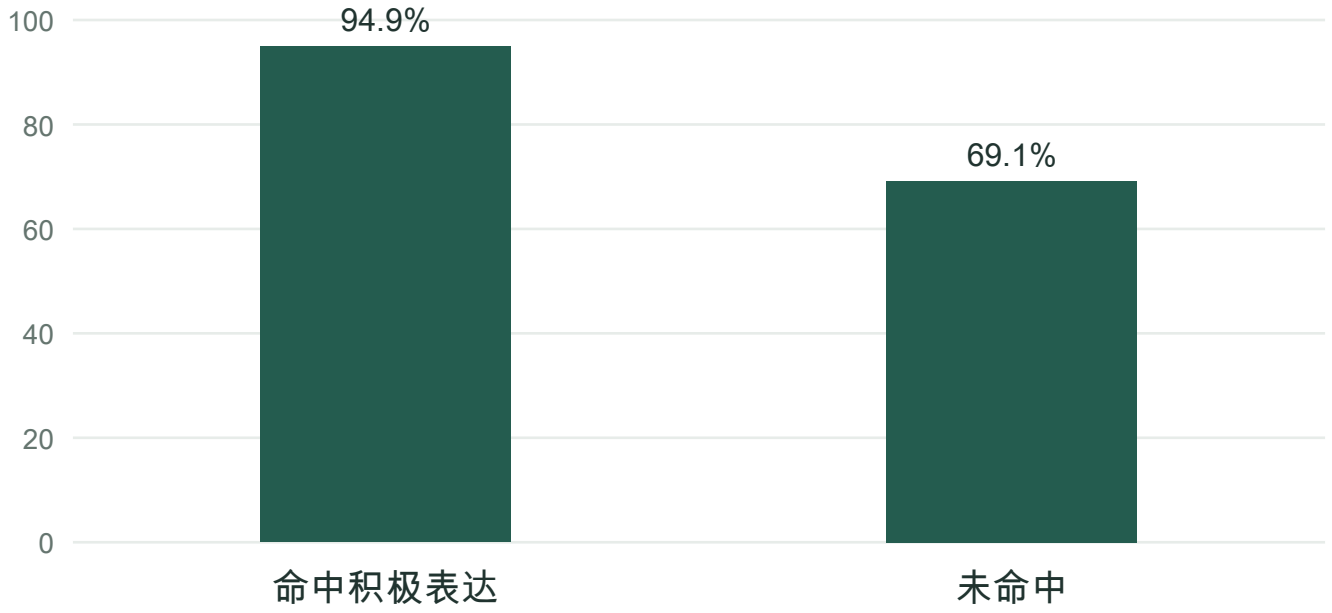
182帖同时命中≥2项
共现可以保留，语义仍要验证。

目前不需要仅因“特征可能类似”就合并；更重要的是准确解释每个规则测到了什么。

PRIVATE GEOMETRY PREVIEW - NOT OFFICE RENDER - revised page 12

文字与点赞的原始差异，也伴随媒体构成差异

积极表达两组的图片 / 视频帖占比



组别	帖数	涉及作者
命中	574	64
未命中	8,958	100

平均点赞：57.29 vs 35.76

两组的媒体和作者构成都不同，
不能把原始差异直接归给措辞。

下一步：同时纳入媒体、作者和日期，比较文字线索是否仍有额外关联。

变量已在第9页定义；图示为各组图片或视频帖占比，尚未调整作者与发布情境。

PRIVATE GEOMETRY PREVIEW - NOT OFFICE RENDER - revised page 13

用作者与日期固定效应，进一步改善比较

历史基线 M3：$\ln(1 + \text{点赞数}) = \beta'X + \gamma'C + \alpha_{\text{作者}} + \delta_{\text{日期}} + \varepsilon$

X：文本长度（对数）、自律、社交、积极、问号。C：原始正文可见、有无话题标签、表情、课程分享、媒体、业务类型与时段。

模型	调整范围	R^2	积极表达系数 / 原始p
M1	X + C + 已记录作者属性	0.563	−0.050 / 0.285
M2	X + C + 作者固定效应	0.685	−0.087 / 0.016
M3 历史基线	X + C + 作者、日期固定效应	0.688	−0.086 / 0.016

加入作者固定效应后拟合度提高，提示作者差异值得考虑；积极表达在M1中就已为负。

这里比较的是调整后的对数结果，不能把与原始均值的差别单独归因于某一个控制项。

历史M3：N=9,532、100位作者；作者聚类推断，五项核心系数BH校正；正文口径另行对照。

PRIVATE GEOMETRY PREVIEW - NOT OFFICE RENDER - revised page 14

历史M3：全样本的指定字面线索关联

文字特征	系数β	原始95%区间	p	BH q
长度 ln(1+字数)	0.028	[−0.008, 0.064]	0.130	0.293
自律 / 目标	−0.119	[−0.293, 0.054]	0.176	0.293
社交 / 互助	−0.004	[−0.131, 0.122]	0.946	0.946
积极表达	−0.086	[−0.155, −0.016]	0.016	0.079
问号	0.108	[−0.100, 0.316]	0.307	0.383

积极表达：β = −0.086

原始p = 0.016
BH q = 0.079

在这个全样本M3中，
五项BH q均未到5%；
不能概括其他正文口径。

五项文字线索仅增加0.065个百分点R^2，联合检验 p = 0.130。

原始均值优势没有在调整后的比较中保留；这不足以推出“积极用词降低点赞”。

下一页并列三种正文口径；全样本不显著不等于所有设定都不显著。

表中为M3的作者聚类推断；95%区间与p为原始值，BH q同时考虑五项核心检验。

PRIVATE GEOMETRY PREVIEW - NOT OFFICE RENDER - revised page 15

正文口径会改变统计判断：需要并列报告

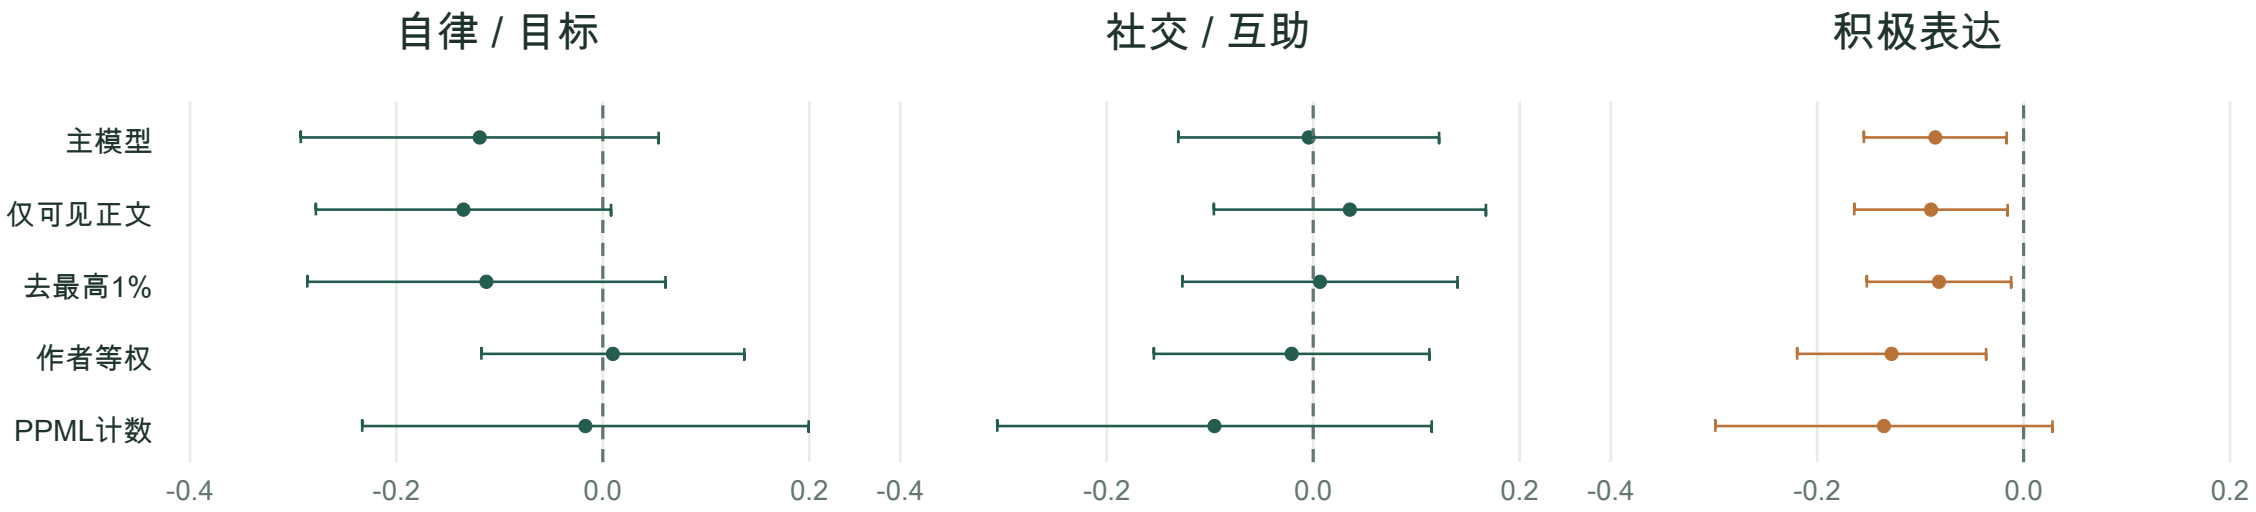
正文范围	N	作者	五项联合p	长度BH q	积极BH q
历史全样本 + 标记	9,532	100	0.130	0.293	0.079
原始正文可见	5,548	95	0.067	0.106	0.093
清理后正文非空	5,414	95	0.040	0.048	0.048

“全部设定都不显著”不成立；“选更显著模型作答案”也不成立。

修订分析对象：实际可观测的非空正文；旧M3保留历史对照。
筛选改变了比较人群，仍不能恢复缺失文字或建立用词因果作用。

PRIVATE GEOMETRY PREVIEW - NOT OFFICE RENDER - revised page 16

敏感性分析：三类表达的方向与区间



积极表达	M3主模型	仅可见正文	去最高1%	作者等权	PPML
系数β	−0.086	−0.090	−0.082	−0.128	−0.135
原始95%区间	[−0.155, −0.016]	[−0.164, −0.015]	[−0.152, −0.012]	[−0.219, −0.036]	[−0.299, 0.028]
原始p	0.016	0.019	0.022	0.007	0.103
N	9,532	5,548	9,436	9,532	9,532

积极表达方向较一致，但PPML区间跨0；100次逐作者剔除均为负，范围[−0.100, −0.074]。

横线为原始95%区间；M3/R1—R3解释ln(1+点赞)，PPML拟合点赞均值，两者尺度不同。

PRIVATE GEOMETRY PREVIEW - NOT OFFICE RENDER - revised page 17

少帖作者：主回归与主题子样本分别检查

主样本：100人，2名单帖，中位66帖。
主题子样本：86人，10名单帖，中位14帖。

作者门槛	主模型 N / 作者	五项联合p	成分模型 N / 作者	成分联合p
原样本	9,532 / 100	0.130	2,470 / 86	0.166
至少5帖	9,524 / 95	0.131	2,423 / 64	0.179
至少10帖	9,462 / 87	0.130	2,309 / 48	0.266

主样本作者内变化人数：自律76、社交42、积极64、问号32。

少帖剔除未改变主判断；它不能解决缺失选择、曝光差异或标签语义问题。

作者次数指本课程样本内次数；共同斜率依赖作者内变化，单帖作者不提供该变化。

PRIVATE GEOMETRY PREVIEW - NOT OFFICE RENDER - revised page 18

原模型已有标签有无控制；tag内容另作对照

5,209帖有tag · 269种 · 1,517帖缺正文但有tag

模型设定	五项联合p	积极β / BH q	所回答的问题
历史M3	0.130	-0.086 / 0.079	正文编码 + has_tag
加9个tag身份	0.102	-0.083 / 0.088	正文范围不变
正文 + tag重编码	0.173	-0.070 / 0.167	被测文字范围改变

拼接后：自律命中 877 → 3,342；问号 125 → 354。

平台话题措辞不等于正文表达；tag身份是元数据，不是人工分类的标准答案。

9个标签按≥30帖且≥5位作者选择，不参考点赞；拼接tag是改变测量范围的补充分析。

PRIVATE GEOMETRY PREVIEW - NOT OFFICE RENDER - revised page 19

原NMF成分与点赞：仅作探索性核查

旧成分模型：M3原有线性项 + Σ θ_k w_k（五项和为1，省去一项权重作参照）

相对参照成分的权重	系数θ	原始95%区间	p	BH q
靠墙静蹲记录	−0.315	[−0.636, 0.005]	0.054	0.107
骑行里程记录	0.018	[−0.523, 0.558]	0.948	0.948
跑步与训练打卡	−0.471	[−1.048, 0.105]	0.108	0.144
生活感悟与问候	−0.144	[−0.278, −0.010]	0.035	0.107

沿用旧命名，生活成分相对训练成分权重增加10个百分点，对应“1+点赞”点估计约低1.4%。

原始p = 0.035、BH q = 0.107；成分联合p = 0.166。名称未经语义验证，不能据此做真实主题反馈排序。

权重范围0–1，系数按100个百分点计；区间未计入主题估计本身的不确定性。

PRIVATE GEOMETRY PREVIEW - NOT OFFICE RENDER - revised page 20

连续权重、主导归类与0–1多标签是三种对象

对象	定义	互斥 / 回归含义
原连续权重	每帖5项权重，合计1	语义可共存；带截距省一权重避免完全共线
主导成分描述	argmax，最高权重归一类	仅描述图互斥，不能当真实分类精度
补充0–1多标签	w_k ≥ 0.20记1；允许多个1	5项全入模满秩171 / 171；不是单一基准类比较

阈值	多标记帖 / 2,470	联合p	最小BH q
0.15	1,331	0.289	0.205
0.20	1,088	0.286	0.296
0.25	835	0.517	0.479

0.20阈值：
1,088帖有≥2标记
比例合计145.9%

PRIVATE GEOMETRY PREVIEW - NOT OFFICE RENDER - revised page 21

RQ2的回答：证据对正文范围和测量方式敏感

局部字面线索与点赞的证据依赖比较范围。

历史全样本联合p=0.130；原始正文可见样本p=0.067；清理后非空正文p=0.040，长度与积极表达的模型内BH q约0.048。不能笼统称为“各种设定都不显著”。

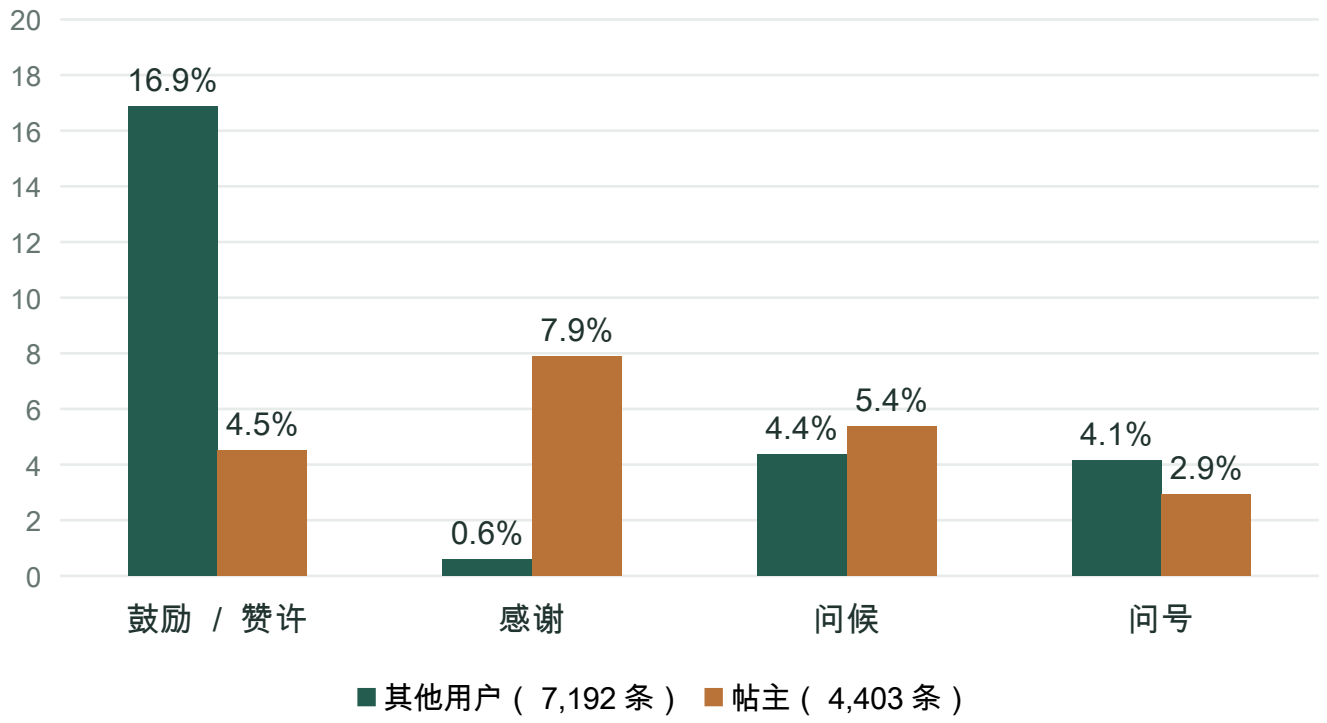
成分编码能复现，不代表内容分类已得到验证。

少帖作者与标签身份对照未改变全样本的主要判断，但不能修复缺失选择或语义测量。主题多标签仍继承旧成分问题，现阶段不作真实内容类型的稳定点赞排序。

RQ3转向另一种反馈：评论里，用户说了什么，留言怎样被回应，又由多少人参与？

PRIVATE GEOMETRY PREVIEW - NOT OFFICE RENDER - revised page 22

评论长度、词频与发言者角色



评论较短：中位数6字符

“加油”612条 / 431人
“谢谢”359条 / 53人

“加油”的使用面更广，
“谢谢”的重复使用更集中。

按角色看：读者更常赞许，
帖主更常感谢。

所以下一步把根评论与帖主回复配对：鼓励是否更易被回复，回复里又怎样表达？

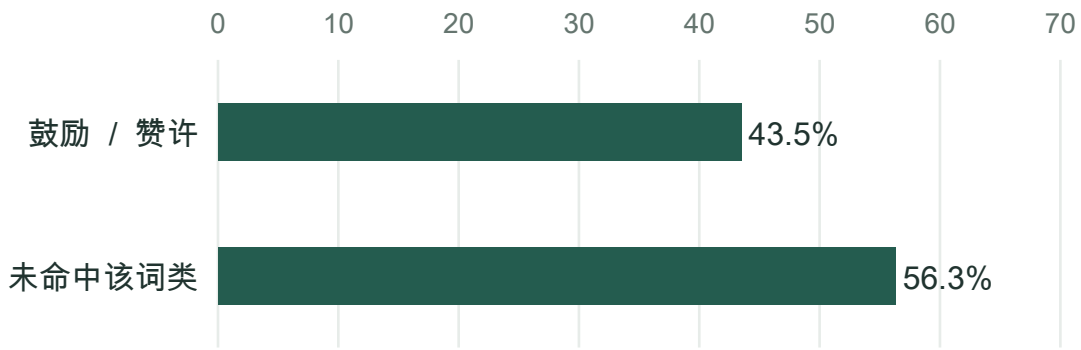
词类命中率以各角色全部发言为分母，可重叠；角色按所在帖子确定。

PRIVATE GEOMETRY PREVIEW - NOT OFFICE RENDER - revised page 23

鼓励留言是否更容易得到回应？感谢与回复覆盖不同

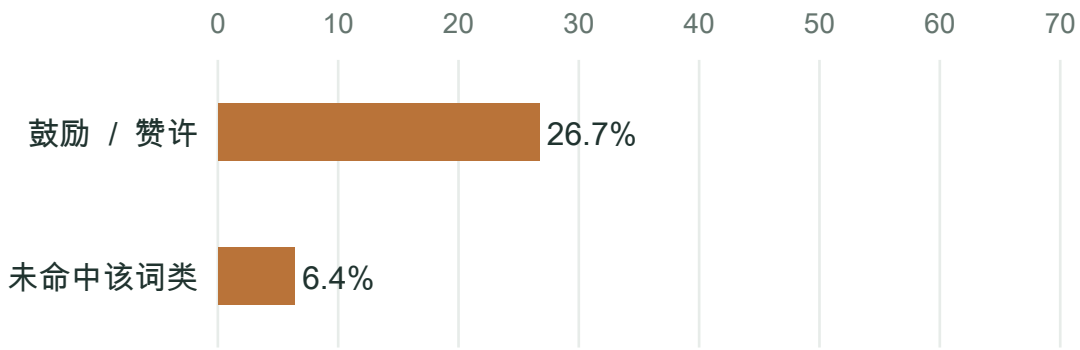
配对规则：6,609条外来根评论；从留言发出起7天内，查找明确指向该条留言的帖主直接回复。
根评论指直接发在帖子下、未指定回复对象的留言；有回复时，只取最早一条。

多少留言观察到7天内直接回复？



分母：各组全部外来根评论
513 / 1,180；3,055 / 5,429

已回复记录中，最早回复多少含感谢？



分母：已观察到直接回复的记录
137 / 513；195 / 3,055

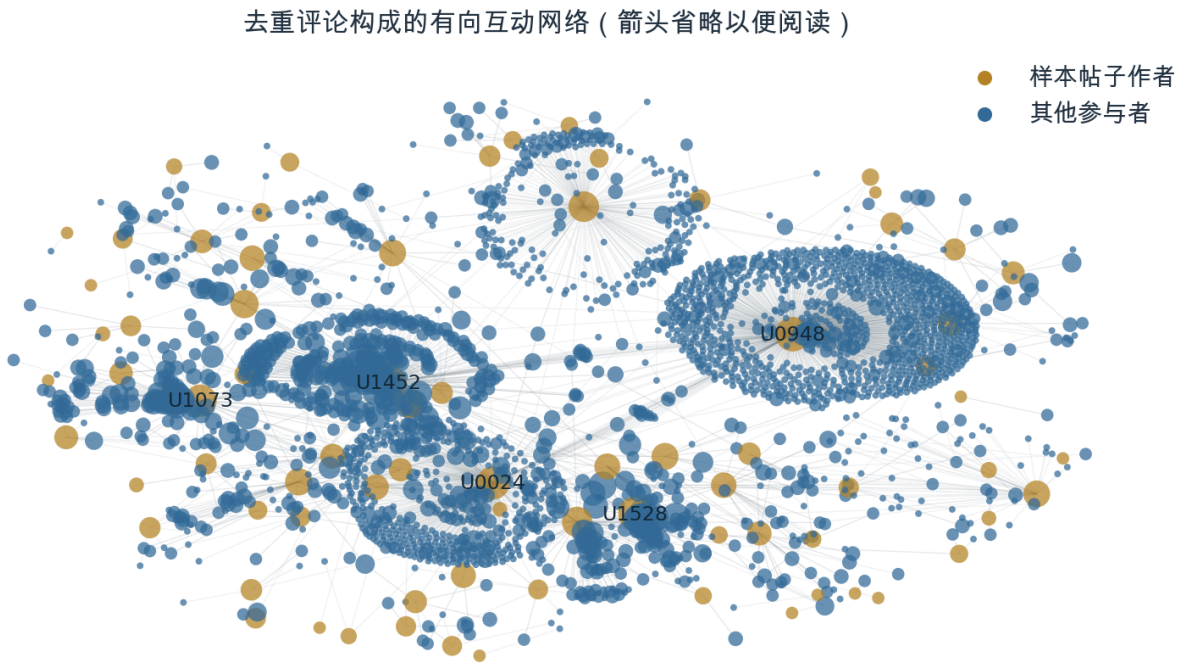
鼓励组的观测回复覆盖低12.8个百分点；但在已回复记录中，感谢词占比高20.3个百分点。

回复时更常致谢，不等于鼓励更容易被回。作者和留言情境可能不同；接下来看看谁在接话。

描述性对照，未作显著性或因果检验；未观察到回复，不等于实际没有回复。

PRIVATE GEOMETRY PREVIEW - NOT OFFICE RENDER - revised page 24

评论关系网络：间接相连广，直接联系仍稀疏



2,932个有边账号 · 4,069条有向边

排除84次自我互动后，11,511次事件合并成有向边；图中省略箭头，金色为样本帖作者。

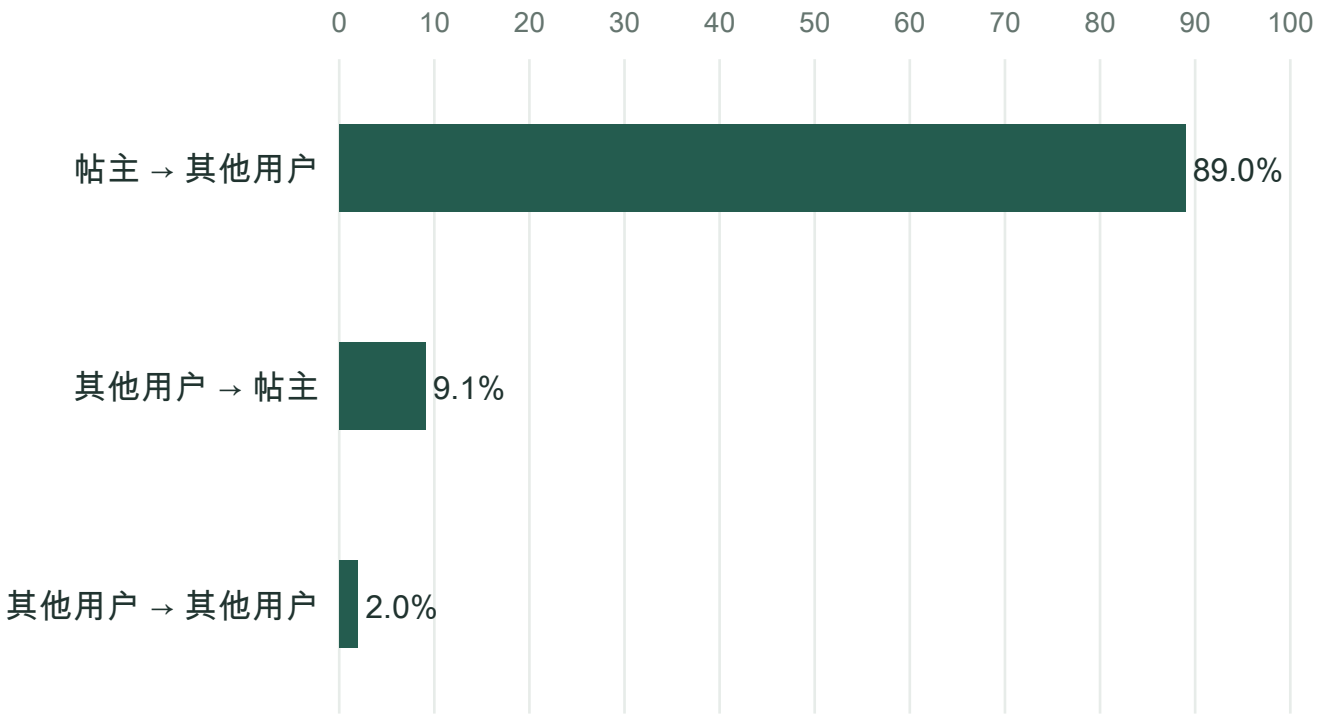
共同面向帖主留言，就能把许多账号间接连起。忽略方向后，94.4%处于最大连通部分；密度0.0473%，直接往来仍局限于少量账号配对。

这张图回答了账号怎样被连起来。谁在回复谁，下一页再把明确回复单独取出比较。

节点为账号；根评论者→帖主，明确回复者→被回复用户；同向多次互动累加为边权。

PRIVATE GEOMETRY PREVIEW - NOT OFFICE RENDER - revised page 25

回话主要围绕帖主展开，用户彼此回复较少



4,361次 · 89.0%

读者面向帖主留言后，明确回话大多由帖主发出。其他用户彼此回复只有97次，占2.0%。

因此，这批评论更常表现为“向帖主留言—帖主回应”，其他参与者相互回复的份额很小。

读者留言、帖主回话，会不会在账号之间形成双向连接？接着比较不同建边规则与观察窗口。

分母为4,902次非自我明确回复，排除6,609条根评论；89%不是全部评论的回复率。

PRIVATE GEOMETRY PREVIEW - NOT OFFICE RENDER - revised page 26

留言与回话形成双向连接，互惠率随观察范围变化

全部互动 49.6% → 仅明确回复 29.9%

读者向帖主留言，帖主再回话给同一用户，就会形成双向连接。
去掉根评论后互惠率降低，“留言 + 回话”是这些双向往来的重要组成。

观察窗口	非自我事件	有边账号	有向边	互惠率	前10位接收占比
全部已采集互动	11,511	2,932	4,069	49.6%	54.0%
各帖发布后7天内	9,451	1,376	2,278	74.1%	48.3%

首周的双向连接占比更高，事件接收也略分散；但窗口内的账号和边同时改变，
不能把差异解释为同一批关系后来变淡。首周从每条帖子的发布时间起算7天。

互惠率按有向边计：有反向连接的边数 / 全部有向边数；每边等权，排除自我互动。

PRIVATE GEOMETRY PREVIEW - NOT OFFICE RENDER - revised page 27

高互动量可能来自接触面广，或少数人反复往来

前10位账号接收了54.0%的互动。判断这种集中意味着什么，需把次数和人数放在一起。

匿名账号	样本帖作者	接收事件次数	不同发送者	这段记录中的突出形态
U1528	是	1,378	53	已有发送者反复留言
U0948	是	1,275	1,091	收到更多不同账号的留言
U0112	否	180	4	与极少数账号集中往来

U1528与U0948接收次数接近，前者只有53位发送者，后者有1,091位。相同“声量”背后，可以是很不一样的参与范围。

U0112的180次只来自4人。看评论区有多热闹，不能只数留言，还要看有多少人在参与。

次数为收到的非自我互动事件，人数为不同发送者；“非样本帖作者”不等于从不发帖。

PRIVATE GEOMETRY PREVIEW - NOT OFFICE RENDER - revised page 28

RQ3的回答：评论主要怎样形成往来

读者更常鼓励，帖主更常感谢；逐条配对后，含义更清楚。

直接配对进一步说明：鼓励组已回复记录中的感谢占比更高，但观测回复覆盖反而较低。回复怎样表达，与多少留言得到回应，需要分开判断。

这些发言主要围绕帖主组织，热闹的来源也不一样。

89%的明确回复由帖主发给其他用户，用户相互回复仅2%。接收次数接近的账号，可以来自53人或1,091人；所以留言量既可能反映广泛参与，也可能是已有发送者反复出现。

互惠率随建边规则和观察窗口变化；评论多或双向连接多，都还需要结合不同参与者人数判断。

PRIVATE GEOMETRY PREVIEW - NOT OFFICE RENDER - revised page 29

研究局限：哪些判断还不能由这批记录回答

限制	它怎样影响结论	下一步需要什么
100位作者，抽样机制不明	不能把样本内容比例和回复结构直接推广到全Keep	更清楚的抽样框与作者覆盖
正文、评论覆盖不全	主题与网络代表不同子样本；未采到不等于未发生	补齐正文、评论、图像和视频内容
曝光、粉丝与采集时点缺失	累计点赞仍受未观测差异影响，固定效应不等于因果识别	统一发帖后7天，并记录实际曝光
字面规则与成分名称尚未验证	不能据用词判定情绪；正文口径和标签边界限制结论	独立人工编码、未见样本验证，再冻结分类

后续先统一观察窗口，完整记录内容、参与人数和实际回复，再检验具体做法能否改变反馈。

下一步是补齐记录和统一观察窗口；若检验表达或回复做法的效果，需要另行设计实验。

PRIVATE GEOMETRY PREVIEW - NOT OFFICE RENDER - revised page 30

成员分工 / Credit

陈霖

问题的提出
数据清洗
RQ1：内容与点赞的分布

董依心（dyx）

RQ2：文字、主题与点赞的关联
RQ3：评论中的回应与参与