APPROXIMATE SHAPE/DATA PREVIEW - NOT OFFICE RENDER - PAGE 01

Keep 社区

帖子特征与互动反馈

可观察字面特征、点赞关联与评论互动结构

正式修订版 · 可观察特征与观察性关联

陈霖 · 董依心

APPROXIMATE SHAPE/DATA PREVIEW - NOT OFFICE RENDER - PAGE 02

研究问题与汇报路径

RQ1	样本的正文可观察范围、媒体形式、tag和点赞如何分布？	01 样本覆盖与描述 正文可见范围、媒体形式、原始tag、点赞分布
RQ2	固定词项命中、问号和正文长度与点赞是否存在条件关联，结论对样本口径及控制项如何变化？	02 字面特征与点赞 固定规则、作者与日期控制、三种正文口径及复核
RQ3	已采集评论的字面线索、直接回复方向及用户连接如何分布？	03 评论与连接 字面词项、直接回复、方向、窗口与参与人数

主讲按RQ1→RQ2→RQ3展开；内容分类仅保留为探索附录。

APPROXIMATE SHAPE/DATA PREVIEW - NOT OFFICE RENDER - PAGE 03

数据来源与清洗

9,532

帖子 · 100位作者

11,595

去重后评论

1,323

采集到评论的帖子

核查发现	处理方式	分析含义
1,916行重复评论	按评论ID去重，无字段冲突	避免同一发言被重复计入
3,984帖缺可用正文	保留；文字计数设0并另作标记	不能把缺失当作真实无文字
8,286帖点赞高于记录浏览数	使用累计点赞，不计算点赞率	不解释为曝光转化效率
仅1,323帖有已采集评论	其余帖子的评论覆盖记为未知	不作评论数的全样本回归
原始时间字段按UTC解析	模型日期与时段统一为北京时间	便于按国内用户的发布情境比较

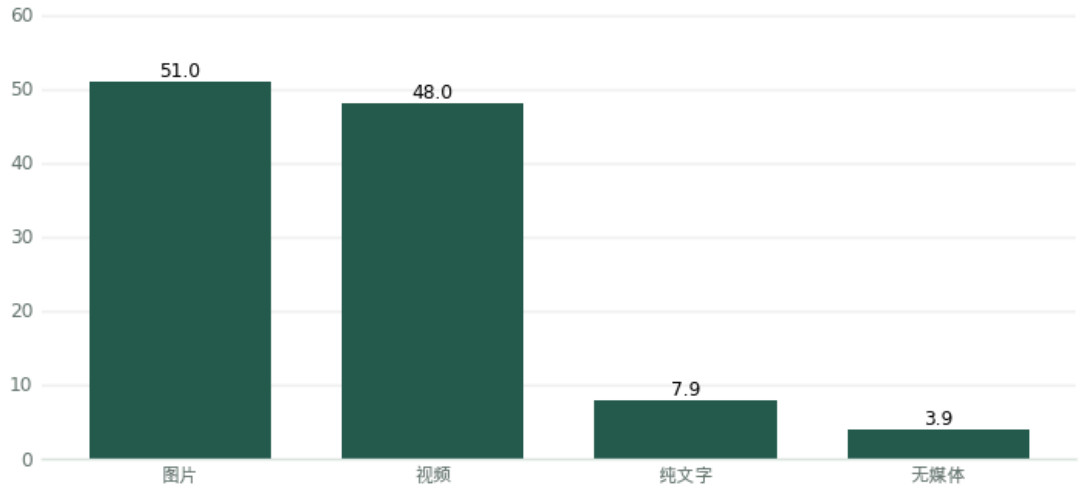
原始正文可见5,548帖；清理后非空5,414帖；5,209帖有原始tag。
三种正文口径并列披露；缺失标记不能恢复未记录的文字。

课程100位作者样本；帖子发表于2020年11—12月（UTC），评论最晚至2021年8月。

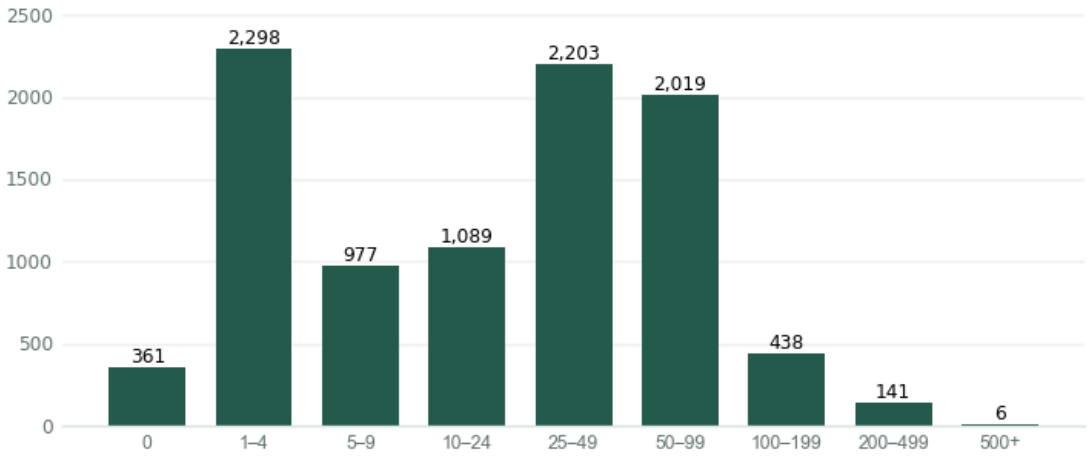
APPROXIMATE SHAPE/DATA PREVIEW - NOT OFFICE RENDER - PAGE 04

图片和视频帖点赞更高，整体分布同时存在长尾

不同媒体的平均点赞



点赞区间中的帖子数



均值37.05 · 中位数25 · 95%分位109.45 · 最高5,126

少量高赞帖拉高平均数，均值不能代表普通帖；媒体均值也相差约一个数量级。

媒体与点赞显示反馈差异；正文缺失和tag则界定了接下来能比较哪些记录。

两图为原始描述；右图显示各点赞区间的帖子数，区间宽度不同，不表示概率密度。

APPROXIMATE SHAPE/DATA PREVIEW - NOT OFFICE RENDER - PAGE 05

RQ1的回答：先交代记录范围，再看反馈分布

56.8%

清理后正文非空

5,414帖；其余4,118帖没有非空正文，不能据此判断图像或视频内容。

54.6%

记录有原始tag

5,209帖、269种tag；其中1,517帖缺正文，tag有时补充记录，但不等于正文。

25

点赞中位数

整体均值37.05；图片 / 视频帖原始均值更高，比较词项前需要考虑媒体与作者。

分母为9,532帖；正文非空与tag有无是不同记录维度，不能相互替代。

APPROXIMATE SHAPE/DATA PREVIEW - NOT OFFICE RENDER - PAGE 06

测量边界：本轮为什么不强制分类

本轮已完成的测量

固定词项命中、问号与正文长度；
原始tag、媒体、点赞与明确回复记录。
规则可重叠，也不穷尽帖子内容。

本轮未完成的验证

人工语义复核：0人。
五个旧NMF名称及17内容叶 / 15行为候选框架均不作为正式内容类别。

24条领域未指明 → 原型仍给18条赋域

这是两份AI记录均判“未指明”时的过度赋类线索；AI间一致也不能代替人工金标准。

本轮交付不依赖填写人工编码A / B表；分类材料仅保留为后续探索资源。

APPROXIMATE SHAPE/DATA PREVIEW - NOT OFFICE RENDER - PAGE 07

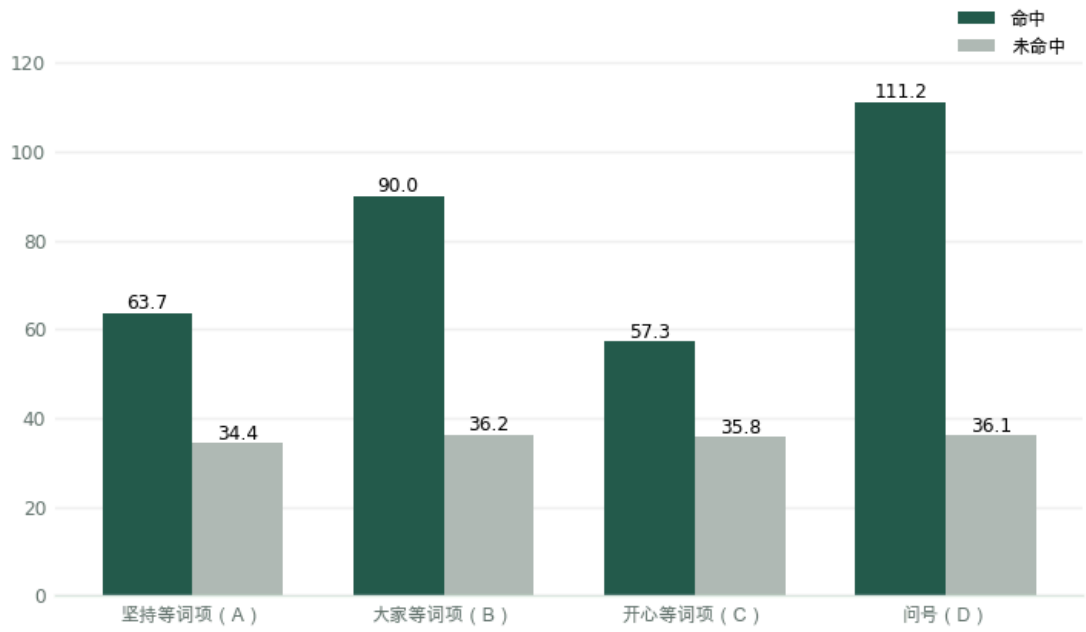
固定字面规则与原始点赞均值

五项可观察变量	固定规则与例子
正文长度	ln(1+清理后字符数)
坚持等词项（A）	坚持、目标、打卡、完成等
大家等词项（B）	大家、小伙伴、谢谢、一起等
开心等词项（C）	开心、快乐、喜欢、哈哈等
问号（D）	正文出现？或 ？即记1

四条规则允许交叉；命中记1，不构成内容分类。

回归结果变量：ln(1+点赞数)，
用于处理RQ1看到的点赞长尾。

四条规则的原始平均点赞



原始命中组均值较高；
还要检查正文覆盖、媒体和作者构成。

全样本9,532帖；未命中组含缺失正文设0的帖子，不能视为完整正文中的纯未命中组。

APPROXIMATE SHAPE/DATA PREVIEW - NOT OFFICE RENDER - PAGE 08

四条规则测到什么，以及解释到哪里

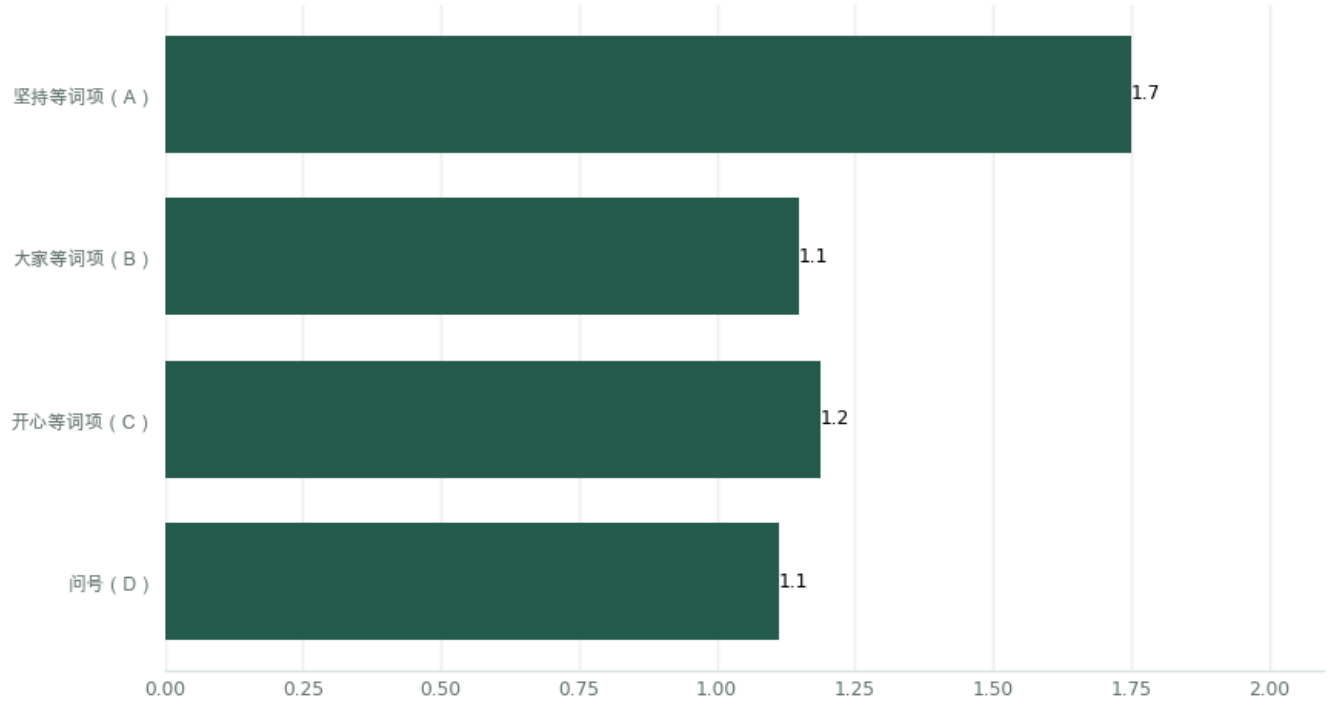
规则	固定字面匹配	解释边界
坚持等词项（A）	坚持、目标等；含“第…天”正则	不直接测自律人格或真实完成训练
大家等词项（B）	大家、一起、谢谢等；子串匹配	不直接测互助行为或关系强度
开心等词项（C）	开心、喜欢、棒等；子串匹配	不直接测情绪；未处理否定和反讽
问号（D）	正文出现？或 ？	不直接测真实提问或求助意图

71.9%非空正文未命中规则，这是未命中率；词表未按显著性增删，不代表完整分类。

A–C原词表按直观含义编制；改中性名不增加语义效度；仅沿用为固定、可复算的探索性指标。

APPROXIMATE SHAPE/DATA PREVIEW - NOT OFFICE RENDER - PAGE 09

字面规则可交叉，数值上未见明显共线性



完整M3：182 / 182 满秩

最大两两相关 0.119
作者内最大相关 0.085

182帖同时命中≥2项
交叉命中可以保留。

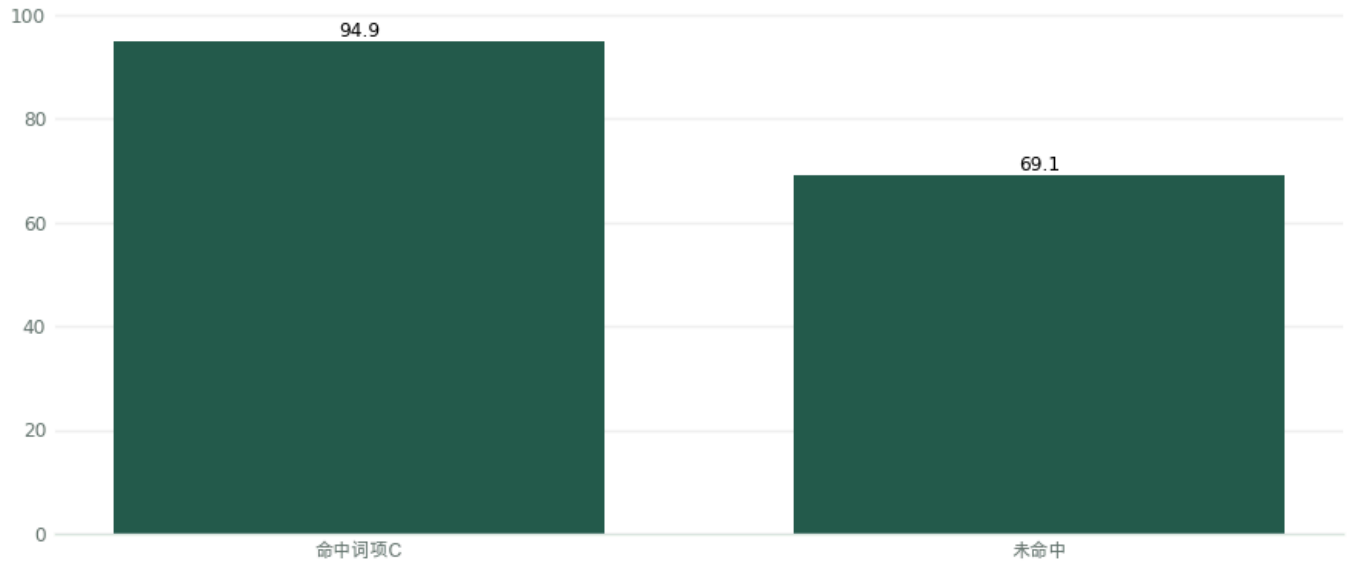
低VIF只说明与已纳入列的线性重复不强；不能证明四条规则具有语义独立性。

VIF基于完整M3全部设计列；低VIF不能证明语义独立或词典有效。

APPROXIMATE SHAPE/DATA PREVIEW - NOT OFFICE RENDER - PAGE 10

文字与点赞的原始差异，也伴随媒体构成差异

词项C命中两组的图片 / 视频帖占比



组别	帖数	涉及作者
命中	574	64
未命中	8,958	100

平均点赞：57.29 vs 35.76

两组的媒体和作者构成都不同，
不能把原始差异直接归给措辞。

下一步：同时纳入媒体、作者和日期，比较文字线索是否仍有额外关联。

全样本9,532帖；未命中组含缺正文设0者；图示为图片 / 视频帖比例，未作条件调整。

APPROXIMATE SHAPE/DATA PREVIEW - NOT OFFICE RENDER - PAGE 11

用作者与日期固定效应，进一步改善比较

历史基线 M3：$\ln(1 + \text{点赞数}) = \beta'X + \gamma'C + \alpha_{\text{作者}} + \delta_{\text{日期}} + \varepsilon$

X：正文长度、A / B / C词项命中、问号D。C：原始正文可见、有无tag、表情、课程分享、媒体、业务类型与时段。

模型	调整范围	R^2	开心等词项（C）系数 / 原始p
M1	X + C + 已记录作者属性	0.563	−0.050 / 0.285
M2	X + C + 作者固定效应	0.685	−0.087 / 0.016
M3 历史基线	X + C + 作者、日期固定效应	0.688	−0.086 / 0.016

作者固定效应利用同一作者的帖间变化；拟合度提高，不能据此认定消除了全部作者差异。

这里比较的是调整后的对数结果，不能把与原始均值的差别单独归因于某一个控制项。

历史M3：N=9,532、100位作者；作者聚类推断，五项核心系数BH校正；正文口径另行对照。

APPROXIMATE SHAPE/DATA PREVIEW - NOT OFFICE RENDER - PAGE 12

历史M3：全样本的指定字面线索关联

文字特征	系数β	原始95%区间	p	BH q
长度 ln(1+字数)	0.028	[−0.008, 0.064]	0.130	0.293
坚持等词项（A）	−0.119	[−0.293, 0.054]	0.176	0.293
大家等词项（B）	−0.004	[−0.131, 0.122]	0.946	0.946
开心等词项（C）	−0.086	[−0.155, −0.016]	0.016	0.079
问号（D）	0.108	[−0.100, 0.316]	0.307	0.383

词项C：β = −0.086

原始p = 0.016
BH q = 0.079

在这个全样本M3中，
五项BH q均未到5%；
不能概括其他正文口径。

五项文字线索仅增加0.065个百分点R^2，联合检验 p = 0.130。

原始均值差异未在调整比较中保留；不能据此推出“命中开心等词导致点赞下降”。

下一页并列三种正文口径；全样本不显著不等于所有设定都不显著。

表中为M3的作者聚类推断；95%区间与p为原始值，BH q同时考虑五项核心检验。

APPROXIMATE SHAPE/DATA PREVIEW - NOT OFFICE RENDER - PAGE 13

正文口径会改变统计判断：需要并列报告

正文范围	N	作者	五项联合p	长度BH q	C的BH q
历史全样本 + 标记	9,532	100	0.130	0.293	0.079
原始正文可见	5,548	95	0.067	0.106	0.093
清理后正文非空	5,414	95	0.040	0.048	0.048

三种口径并列披露：不能说“全部设定都不显著”，也不能按p值追认唯一主模型。

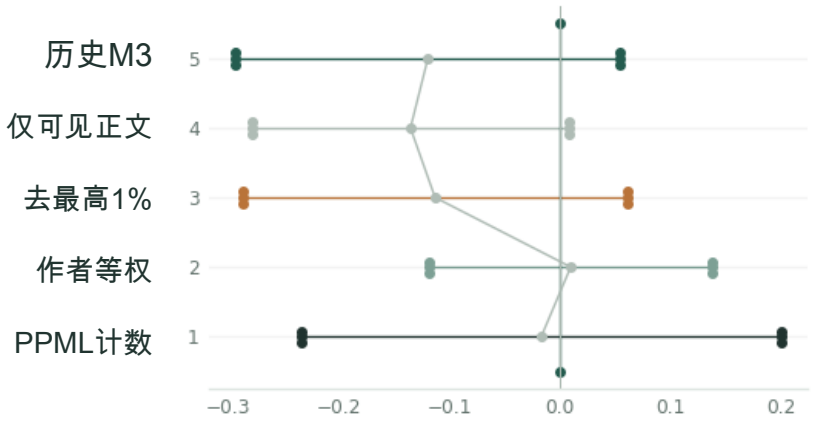
正文范围改变了比较人群；清理后非空正文p=0.040属于既有重分析结果，
不追认为事前确定的唯一主分析。缺失文字和曝光仍无法恢复。

作者聚类t / F推断；BH仅在各模型内校正五项，不覆盖全部探索性设定。

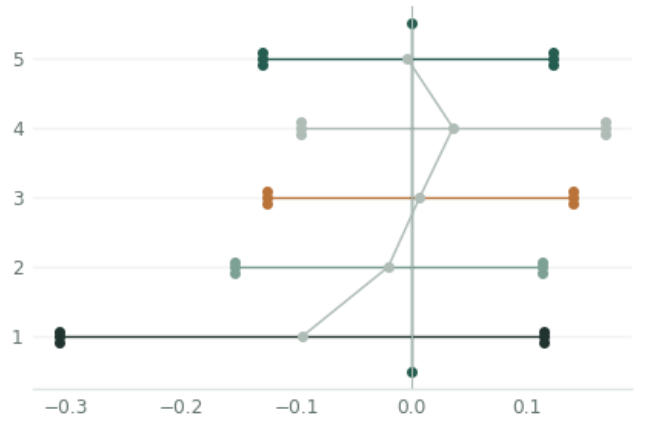
APPROXIMATE SHAPE/DATA PREVIEW - NOT OFFICE RENDER - PAGE 14

既有敏感性分析：A、B、C的方向与区间

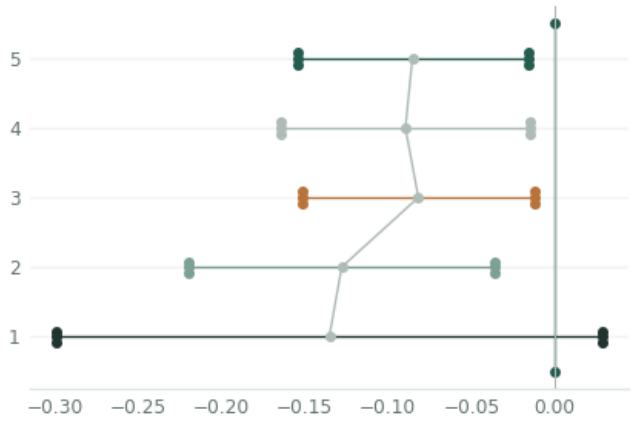
坚持等词项（A）



大家等词项（B）



开心等词项（C）



开心等词项（C）	历史M3	仅可见正文	去最高1%	作者等权	PPML
系数β	−0.086	−0.090	−0.082	−0.128	−0.135
原始95%区间	[−0.155, −0.016]	[−0.164, −0.015]	[−0.152, −0.012]	[−0.219, −0.036]	[−0.299, 0.028]
原始p	0.016	0.019	0.022	0.007	0.103
N	9,532	5,548	9,436	9,532	9,532

词项C在这些设定中均为负，但PPML区间跨0；逐作者剔除范围[−0.100, −0.074]。

横线为原始95%区间；M3/R1—R3解释ln(1+点赞)，PPML拟合点赞均值，两者尺度不同。

APPROXIMATE SHAPE/DATA PREVIEW - NOT OFFICE RENDER - PAGE 15

作者支持：少帖作者与作者内变化

100位作者 · 2名单帖 · 中位66帖

作者门槛	N / 作者	五项联合p
全部作者	9,532 / 100	0.130
至少5帖	9,524 / 95	0.131
至少10帖	9,462 / 87	0.130

提供作者内变化的人数

A 76人
B 42人
C 64人
D 32人

少帖作者剔除未改变全样本的联合检验判断；稀少特征的有效变化来源仍较少。

作者次数指课程样本内次数；单帖作者不提供同一作者内的特征变化。

APPROXIMATE SHAPE/DATA PREVIEW - NOT OFFICE RENDER - PAGE 16

原模型已有标签有无控制；tag内容另作对照

5,209帖有tag · 269种 · 1,517帖缺正文但有tag

模型设定	五项联合p	C的β / BH q	所回答的问题
历史M3	0.130	-0.086 / 0.079	正文编码 + has_tag
加9个tag身份	0.102	-0.083 / 0.088	正文范围不变
正文 + tag重编码	0.173	-0.070 / 0.167	被测文字范围改变

拼接后：词项A命中 877 → 3,342；问号D 125 → 354。

平台tag措辞改变了被测文字范围；tag是元数据，不能作为正文语义的标准答案。

9个标签按≥30帖且≥5位作者选择，不参考点赞；拼接tag是改变测量范围的补充分析。

APPROXIMATE SHAPE/DATA PREVIEW - NOT OFFICE RENDER - PAGE 17

字面特征与点赞的条件关联

RQ2的回答：证据对正文范围和测量方式敏感

固定字面特征的条件关联随正文范围变化。

五项联合p依次为0.130、0.067和0.040；非空正文模型的长度与C模型内BH q约0.048。解释范围应与各自样本一致，不能把局部证据概括为“文字无效”或“用词增赞”。

作者、tag与VIF复核支持计算层面的可比性。

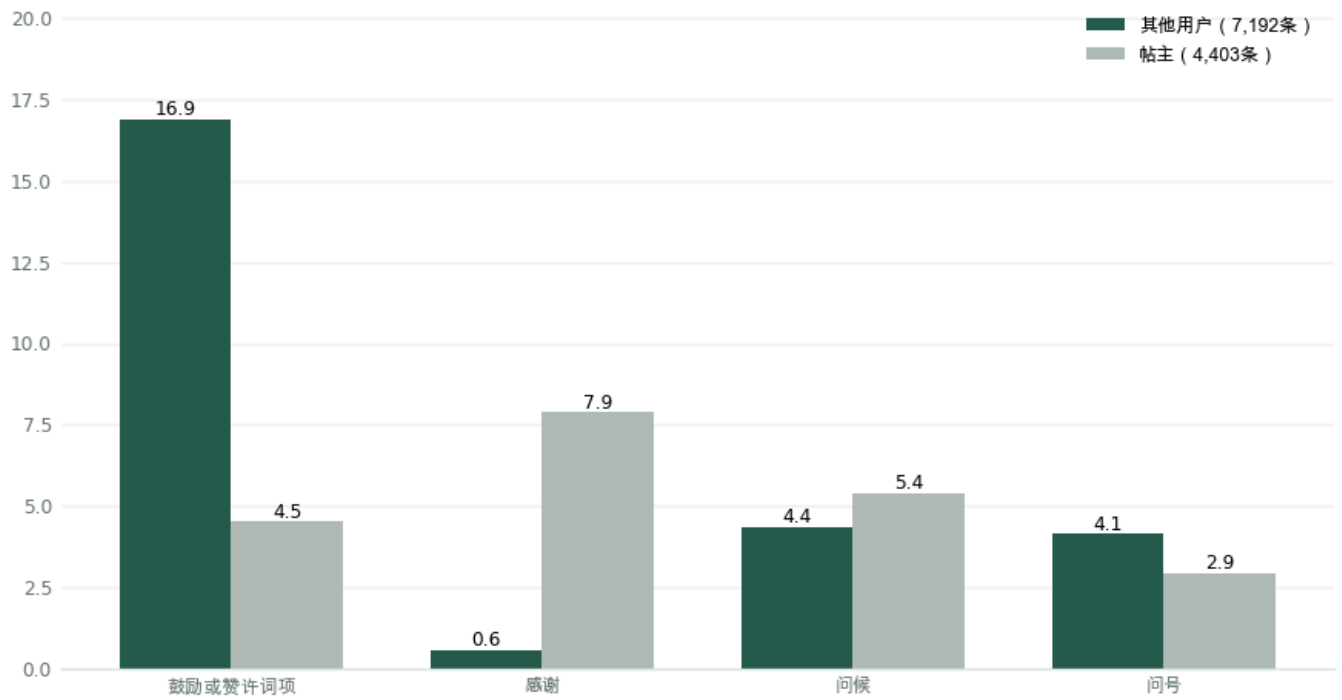
少帖作者、tag和数值共线性检查没有消除正文缺失、曝光差异和观察性选择；本轮也未进行人工语义复核。主结论只涉及操作性字面特征。

RQ3转向已采集评论：哪些词项出现、明确回复指向谁、由多少不同用户参与？

既有清理、规则、控制项与估计值保持不变；三种正文范围并列，不据显著性选择主模型。

APPROXIMATE SHAPE/DATA PREVIEW - NOT OFFICE RENDER - PAGE 18

评论长度、词频与发言者角色



评论较短：中位数6字符

“加油”612条 / 431人
“谢谢”359条 / 53人

“加油”的使用面更广，
“谢谢”的重复使用更集中。

按帖子角色看：其他用户更多命中鼓励或赞许词项，帖主更多命中感谢词项。

把外来根评论与帖主直接回复配对，分别观察已采集回复覆盖与最早回复的词项。

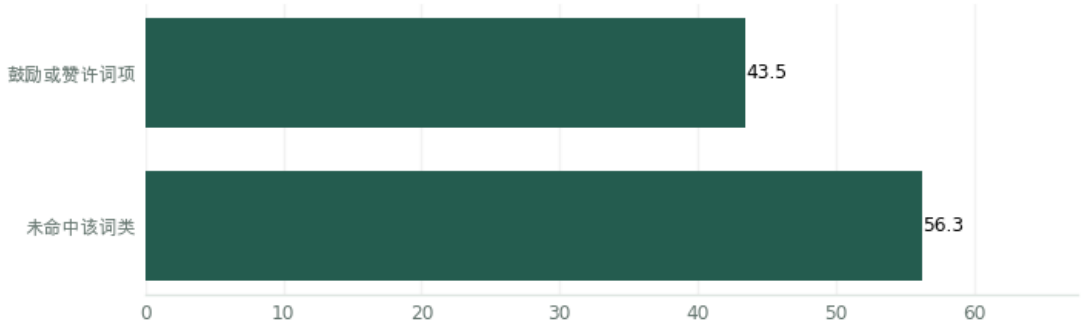
固定词表命中可交叉；分母为各角色全部发言。词项不直接测情绪、社会支持或语言功能。

APPROXIMATE SHAPE/DATA PREVIEW - NOT OFFICE RENDER - PAGE 19

词项命中与已采集直接回复：覆盖和致谢要分开

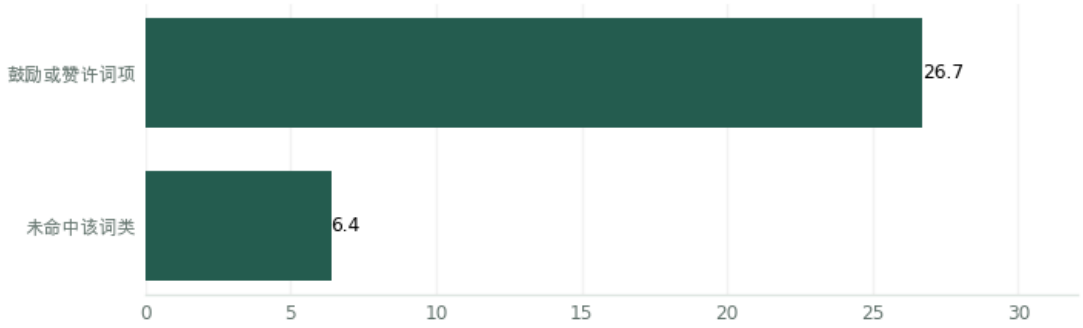
配对：6,609条外来根评论；从留言发出起7天，匹配明确指向该条留言的帖主直接回复。
根评论未指定回复对象；匹配到多条直接回复时，只取最早一条。

7天内匹配到已采集直接回复的比例



分母：各组全部外来根评论
513 / 1,180；3,055 / 5,429

已匹配记录中，最早回复含感谢词项比例



分母：已观察到直接回复的记录
137 / 513；195 / 3,055

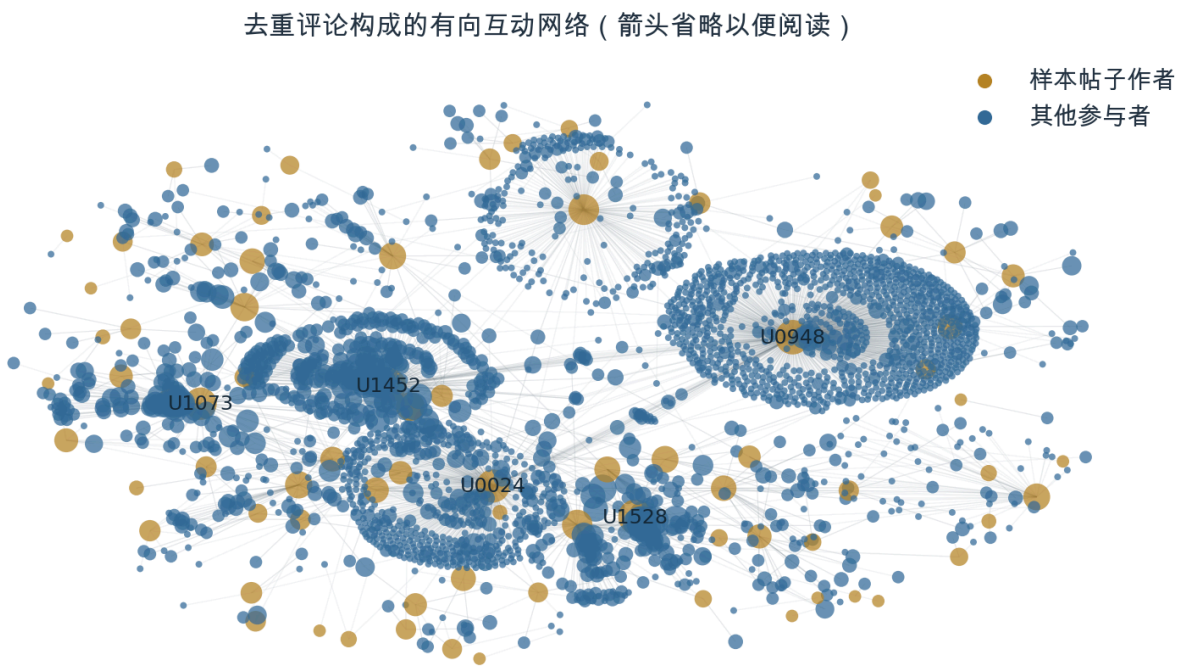
鼓励或赞许词项命中组：回复覆盖低12.8个百分点；已匹配记录中感谢词项高20.3个百分点。

已匹配回复中更常出现感谢词项，与更多留言得到回复是两件事；两组作者和情境也可能不同。

仅为已采集记录的描述；7天内未匹配直接回复，不等于真实未回复；未作因果检验。

APPROXIMATE SHAPE/DATA PREVIEW - NOT OFFICE RENDER - PAGE 20

评论关系网络：间接相连广，直接联系仍稀疏



2,932个有边账号 · 4,069条有向边

排除84次自我互动后，11,511次事件形成有向边；根评论按帖子归属连向帖主。图中省略箭头，金色为样本帖作者。

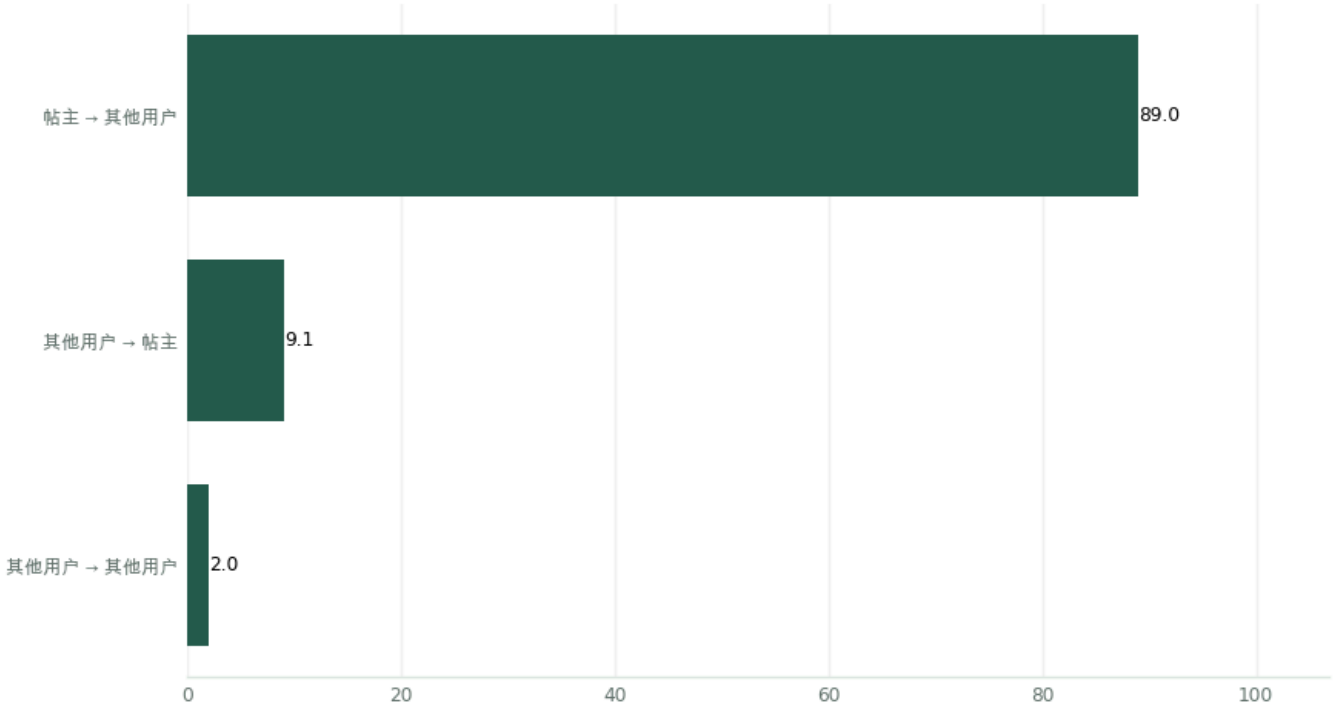
共同面向帖主留言，就能把许多账号间接连起。忽略方向后，94.4%处于最大连通部分；密度0.0473%，直接往来仍局限于少量账号配对。

这张图回答了账号怎样被连起来。谁在回复谁，下一页再把明确回复单独取出比较。

建边：根评论者→帖主是归属规则；明确回复者→已记录被回复用户；同向多次事件累加权重。

APPROXIMATE SHAPE/DATA PREVIEW - NOT OFFICE RENDER - PAGE 21

回话主要围绕帖主展开，用户彼此回复较少



4,361次 · 89.0%

4,902次明确回复中，4,361次由帖主发给其他用户；其他用户彼此回复97次，占2.0%。

已记录的直接回复方向主要围绕帖主；这描述回复事件构成，不等于所有留言的被回概率。

读者留言、帖主回话，会不会在账号之间形成双向连接？接着比较不同建边规则与观察窗口。

分母为4,902次非自我明确回复，排除6,609条根评论；89%不是全部评论的回复率。

APPROXIMATE SHAPE/DATA PREVIEW - NOT OFFICE RENDER - PAGE 22

留言与回话形成双向连接，互惠率随观察范围变化

全部互动 49.6% → 仅明确回复 29.9%

根评论按归属连向帖主，帖主再明确回复同一用户，就会形成双向连接。
去掉归属建边的根评论后互惠率降低，表明这一规则影响网络统计量。

观察窗口	非自我事件	有边账号	有向边	互惠率	前10位接收占比
全部已采集互动	11,511	2,932	4,069	49.6%	54.0%
各帖发布后7天内	9,451	1,376	2,278	74.1%	48.3%

首周的双向连接占比更高，事件接收也略分散；但窗口内的账号和边同时改变，
不能把差异解释为同一批关系后来变淡。首周从每条帖子的发布时间起算7天。

互惠率按有向边计：有反向连接的边数 / 全部有向边数；每边等权，排除自我互动。

APPROXIMATE SHAPE/DATA PREVIEW - NOT OFFICE RENDER - PAGE 23

高互动量可能来自接触面广，或少数人反复往来

前10位账号接收了54.0%的互动。判断这种集中意味着什么，需把次数和人数放在一起。

匿名账号	样本帖作者	接收事件次数	不同发送者	这段记录中的突出形态
U1528	是	1,378	53	已有发送者反复留言
U0948	是	1,275	1,091	收到更多不同账号的留言
U0112	否	180	4	与极少数账号集中往来

U1528与U0948接收次数接近，前者只有53位发送者，后者有1,091位。相同“声量”背后，可以是很不一样的参与范围。

U0112的180次只来自4人。看评论区有多热闹，不能只数留言，还要看有多少人在参与。

次数为收到的非自我互动事件，人数为不同发送者；“非样本帖作者”不等于从不发帖。

APPROXIMATE SHAPE/DATA PREVIEW - NOT OFFICE RENDER - PAGE 24

研究局限：哪些判断还不能由这批记录回答

限制	对本轮结论的影响	相应改进
100位作者，抽样机制不明	分布和回复结构不能直接推广到全Keep	扩大并说明抽样框与作者覆盖
正文和评论覆盖不全	正文口径不同；未采到不等于未发生	补齐正文、媒体和直接回复记录
曝光与统一采集时点缺失	固定效应仍不能识别每帖措辞的因果作用	统一观察窗口，记录实际曝光
未进行人工语义复核	词项只作字面测量；候选分类仅作探索附录	本轮交付无需补人审表；未来另行验证

当前可交付的证据是字面分布、条件关联与记录连接；计算核查不能称作语义效度验证。

后续优先补齐记录与统一观察窗口；语义分类若要转为正式研究，需另行独立人工验证。

APPROXIMATE SHAPE/DATA PREVIEW - NOT OFFICE RENDER - PAGE 25

三个问题的回答：分布、关联与连接

RQ1

正文非空覆盖56.8%，媒体均值不同，点赞有长尾。

tag与正文是不同记录维度，不能互相替代。

RQ2

固定字面特征的条件关联对正文范围敏感。

三口径联合p为0.130 / 0.067 / 0.040；不按阈值追认主模型。

RQ3

已记录回复主要围绕帖主，次数与参与人数不同。

89%是明确回复的事件构成；互惠率依赖建边与窗口。

APPROXIMATE SHAPE/DATA PREVIEW - NOT OFFICE RENDER - PAGE 26

成员分工 / Credit

陈霖

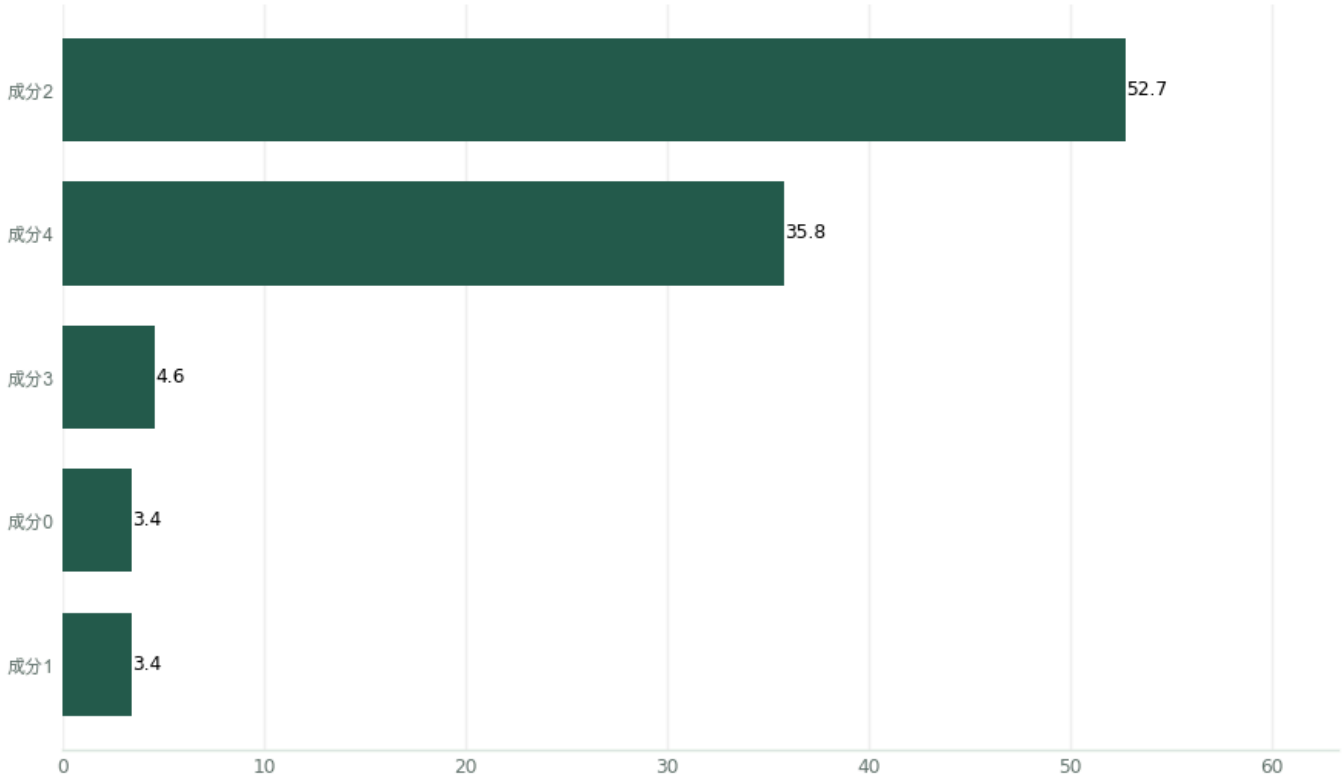
问题的提出
数据清洗
RQ1：样本覆盖与点赞的分布

董依心（dyx）

RQ2：字面特征与点赞的关联
RQ3：评论线索与连接结构

APPROXIMATE SHAPE/DATA PREVIEW - NOT OFFICE RENDER - PAGE 27

旧NMF仅描述模型成分，不给出真实内容占比



2,470帖 · 86位作者

2,470帖仅占非空正文45.6%

成分0—4沿用冻结模型ID；
最高权重仅用于这张描述图。

成分2和4的主导份额合计88.5%，不等于88.5%的帖子属于两个真实类别。静蹲旧成分85帖中78帖来自同一作者；删重后该成分不再单列。

随机种子复现、改汇总权重或结构诊断都不能替代人工语义效度验证。

旧5成分、固定权重及数值份额保留供核对；名称未经人工语义复核。

APPROXIMATE SHAPE/DATA PREVIEW - NOT OFFICE RENDER - PAGE 28

旧成分回归与候选分类均不进入主结论

旧成分模型：既有M3线性项 + Σ θ_k w_k（省成分2，连续权重和为1）

相对成分2的连续权重	系数θ	原始95%区间	p	BH q
成分0（旧静蹲）	−0.315	[−0.636, 0.005]	0.054	0.107
成分1（旧骑行）	0.018	[−0.523, 0.558]	0.948	0.948
成分3（旧跑步）	−0.471	[−1.048, 0.105]	0.108	0.144
成分4（旧生活）	−0.144	[−0.278, −0.010]	0.035	0.107

旧四项成分联合p=0.166；本表只保留数值核对，不作真实主题的反馈排序。

17内容叶 / 15表达行为仍为候选框架；同基座AI编码预检验不是独立人工复核。
未将候选类别替换进入本轮模型；识别器原型也不作为正式测量。
本轮人工语义复核0人；AI间及模型相对AI的分歧均不能称为人工准确率。

旧回归限于2,470帖、86位作者；连续成分权重不等于真实主题或表达行为效应。