SOCIAL MEDIA DATA ANALYSIS · 小组项目

什么样的健身分享更容易获得点赞?

Keep 社区帖子文本、点赞表现与评论互动网络分析

第【待填写】组

【待填写：成员姓名及学号】

课程：社交媒体与网络分析
资料范围：课程提供的 Keep 社区帖子及评论
帖子发布时间：2020–11—2020–12（UTC）
分析完成日期：2026–10–16

摘要

本研究分析100位作者的9,532条帖子，将正文转换为长度、自律/目标词、社交称呼/互助词、积极表达词和问号等变量，以 ln(1+点赞数) 为因变量建立回归；另将去重后的11,595条评论构造成互动网络。

主模型控制作者、发帖日期、内容形式及其他特征后，五项核心文本特征的联合检验 p=0.130，新增解释度为0.065个百分点；没有充分证据认定某类词汇稳定伴随更多点赞。积极表达词的负系数在原始检验中显著，但BH校正 q=0.079，且PPML计数模型区间包含零，应视为探索性信号。

观察到的评论互动集中于少数账号，前10位接收54.0%的事件。建议将词汇优化视为待检验方案，结合用户层面的对照实验评估互动质量。点赞不是运动效果，观察到的评论网络也不是整个平台的社交图谱。

关键词：Keep；内容分析；固定效应；聚类标准误；评论网络。组号和成员信息尚待填写；文中分工均为建议。

从健身记录到社区反馈

健身社区把运动记录、情绪表达和同伴交流放在同一场景中。点赞可以反映平台内一种可观察的反馈，但它还受到作者既有受众、媒体形式和曝光机会影响。因此，不能只比较某类帖子平均点赞就判断内容表达是否有效。

Richardson 等（2010）的随机试验发现，增加在线社区功能与较低的项目流失相关，但未发现组间步数增幅存在显著差异。[1] 这提示我们区分社区参与和行为改变。本项目仅研究平台内反馈，不测量运动坚持、健康或体重变化。

研究问题

编号	可检验问题	分析路径
RQ1	样本帖子、表达方式及点赞如何分布?	描述统计、正文分词与词汇命中统计
RQ2	同一作者不同帖子的文本特征与点赞是否相关?	作者与日期固定效应回归；稳健性比较
RQ3	采集到的评论如何连接用户？互动集中在哪里?	有向加权网络、互惠率、接收集中度

研究预期与解释边界

- 自律/目标词可能使运动记录更易理解；社交称呼和互助词可能邀请反馈。这些是待检验解释，不是已成立的因果机制。
- 积极表达和问号的方向不预设；正文长度是表达规模的控制与比较维度。四类二元特征和长度共同构成五项核心检验。
- 报告完整呈现正、负及不显著结果。词典在本次拟合前固定，但没有事前注册；研究仍属探索性分析。

课程对应：《内容分析与自然语言处理》第10、14、18页提供“描述—解释—决策”和文本预处理框架；本研究将其落实为可复查的编码与建模步骤。[3]

先确定样本与字段含义

文件	粒度与规模	用途
sample_post_2022.csv	每行1帖；9,532帖；100位作者	全部描述统计与回归
sample_comment_2022.csv	原始13,511行；去重后11,595条评论	仅用于评论覆盖说明与网络
KeepData_dictionary.pdf	课程提供的字段解释	确定ID、点赞、父评论与直接回复对象

实际清洗流程

步骤	发现及处理
主键与重复	帖子ID全部唯一。评论ID有1,916行重复；逐字段验证没有冲突，按cmtId保留1条。
表关联	所有去重评论均能关联到帖子；1323帖有采集到的评论，其余8209帖的评论覆盖未知，不赋值为0。
时间	原字段以Z结尾，按UTC解析；发帖日期、时段统一转换为Asia/Shanghai。北京时间末尾跨至2021-01-01。
正文	3984帖content为空；保留帖子，文本计数置0，并另设has_text控制“无可用正文”状态。
口径异常	8286帖likes大于viewCount（86.9%）。无法确认两个计数字段可比分母关系，因此不计算点赞率或将浏览数设为offset。
极端值	保留全部真实观测进入主模型。仅在稳健性规格中剔除点赞最高1%，不把极端值预先认定为错误。

> **文件名不能当作观测年份**
>
> 帖子UTC发布时间为2020-11-01至2020-12-31；评论最晚到北京时间2021-08-26。2022和2026均不是本项目观测年份。采集时点未提供，点赞的累计观察时长未知。

可复核证据：results/summary.json保存原文件SHA-256；results/post_features.csv保存匿名作者和建模特征。评论缺失覆盖与重复处理分别核查，不将删重视作“删异常用户”。

点赞分布长尾明显，均值高于中位数

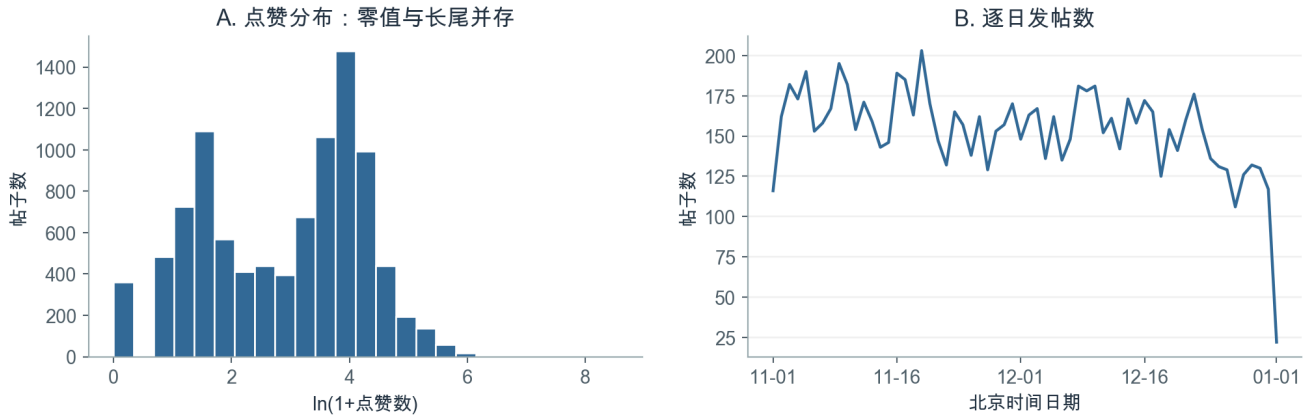


图1　全部9,532帖的点赞分布与北京时间逐日发帖数。首末本地日期为不完整日，末端下降不能解释为活跃度骤降。

变量	均值	中位数	95分位数	最大值
点赞数	37.05	25	109.4	5126
记录浏览数	70.61	2	39.0	383414
收藏数	0.90	0	1.0	3387
清理后正文字符数	15.64	3	57.0	1202

平均点赞为37.05，中位数为25，最大值为5126，零点赞占3.8%。点赞方差约为均值的164.8倍。主模型用ln(1+点赞数)缓和长尾影响；同时用聚类稳健推断和计数模型检查结论。

作者发帖数很不均衡：中位作者发布66帖，发帖最多者发布783帖。单纯把帖子看成独立随机样本会低估同一作者帖子的相关性，因此标准误按作者聚类；另用作者等权规格检查高产作者的影响。

字符数为去URL、成对课程后缀、方括号表情及空白后的字符数；并非纯汉字数。上述分位数基于所有帖子，含无可用正文者。

内容形式之间存在明显的原始差异

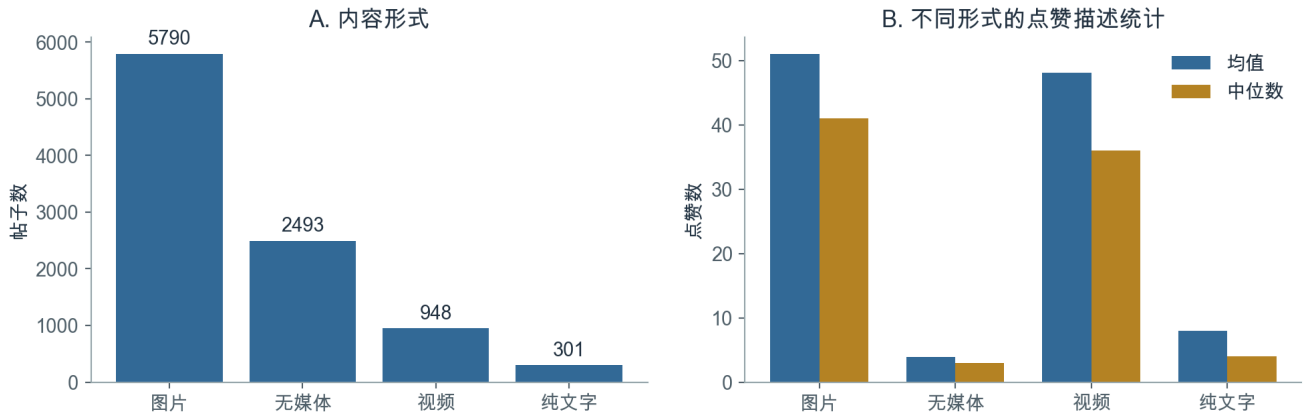


图2　内容形式及其点赞均值、中位数。类别是原始contentTypeStr，不等同于是否有正文。

形式	帖子数	占比	平均点赞	点赞中位数
图片	5,790	60.7%	51.03	41
无媒体	2,493	26.2%	3.91	3
纯文字	301	3.2%	7.94	4
视频	948	9.9%	48.05	36

图片和视频帖的原始点赞明显高于无媒体及纯文字帖，但这同时混合了作者构成、帖子业务类型和内容差异。不能据此断言“发布图片会提高点赞”，也不把此差异当作文本词汇的作用。

帖子业务类型包括normal、hiking、run、yoga、cycling、direct与share；这些原始类别进入回归。发帖时段分为00—05、06—11、12—17、18—23点。日期固定效应控制同一天样本共有的变化，无法解决每帖真实累计曝光时长不明的问题。

输出文件：media_summary.csv、post_type_summary.csv、monthly_summary.csv。北京时间2021年1月仅包含UTC年底跨日的少量帖子，不能与完整月份比较活跃趋势。

把可见正文转换为可重复的变量

原始content → 还原换行 → 去URL、课程后缀及表情标记 → 正文字符数与规则匹配 → jieba分词/词频 → 回归特征表

变量	定义与编码	用途
log_length	ln(1+清理后非空白字符数)	核心检验1；控制表达规模
self_discipline	含坚持、自律、目标等任一词或明确“第N天”模式=1	核心检验2；自律/目标词命中
social_address	含大家、小伙伴、谢谢、一起等任一词=1	核心检验3；社交称呼/互助词命中
positive_expression	含开心、快乐、喜欢、哈哈等任一词=1	核心检验4；积极表达词命中
question	出现半角?或全角？=1	核心检验5；标点特征
has_text	原content经去空白后非空=1	区分无可用正文与可用正文
has_tag	hashTags不等于[]记1	话题元数据；不混入正文词典
emoji_count	ln(1+方括号表情标记数)	控制标记表达；不代表全部Unicode表情
course_ref	原文出现Ⓚ记1	控制课程分享痕迹

正文中的话题元数据不拼接进词典匹配，以免将平台话题名当成用户表达。成对“Ⓚ…Ⓚ”视为可观察的课程分享后缀；非成对标记不强行删除。方括号表情不参加核心词匹配，另计数量。

> **词汇代理的含义**
>
> 命中=检测到字面表达；未命中=规则未检测到，不等于没有该主题或没有情绪。has_text=0也不意味着用户没有表达意图，可能是图片表达或字段未采集。

课程依据：[3]第14、18、24—28页；全部规则见code/analyze.py与text_dictionary.json。文本分析与回归通过同一postId关联，未使用点赞反向定义词典。

先固定规则，再检查其语义边界

维度	完整规则
自律/目标词	坚持、自律、打卡、目标、计划、努力、加油、挑战、突破、完成、进步、不放弃、全勤；第[数字或汉字数词]天
社交称呼/互助词	大家、朋友们、小伙伴、你们、一起、互相、互勉、共勉、陪伴、谢谢、感谢、请教、求助、求推荐
积极表达词	开心、快乐、高兴、幸福、喜欢、美好、满足、舒服、棒、赞、愉快、美滋滋、哈哈、嘻嘻、嘿嘿
问号	？或 ？ ； 不推断是否真正提问

怎样从一句话产生一行数据

匿名正文节选	生成的结构化信息
“夜跑打卡”	self_discipline=1；其余三类二元特征=0
“谢谢你们！……一起开启……”	social_address=1；其他维度按各自规则独立判断
“用心感受清晨的美好”	positive_expression=1
“今天 你笑了么？”	question=1；问号本身不等同于互动请求

词典采用子串匹配，每个维度命中任一项记1，不累计同一词反复出现次数；维度之间允许重叠。自律词中的“加油”属于激励表达，积极词维度则聚焦愉悦或赞许词。它们不是互斥的主题标签，也不是正负情感评分。

另使用jieba精准分词、停用词过滤和逐帖去重，计算词的文档频数。高频词用于描述“大家在说什么”，不据此生成新的显著性检验。停用词沿用课程数据内BaiduStopwords.txt并增加少量口语停用词；便携副本保存在code/stopwords.txt。

未拟合LDA：此任务要求至少一种文本或网络分析，本项目采用可解释内容分析并额外完成网络分析。词云不是回归变量，也不作为结论依据。

“打卡”和日常表达占据主要位置

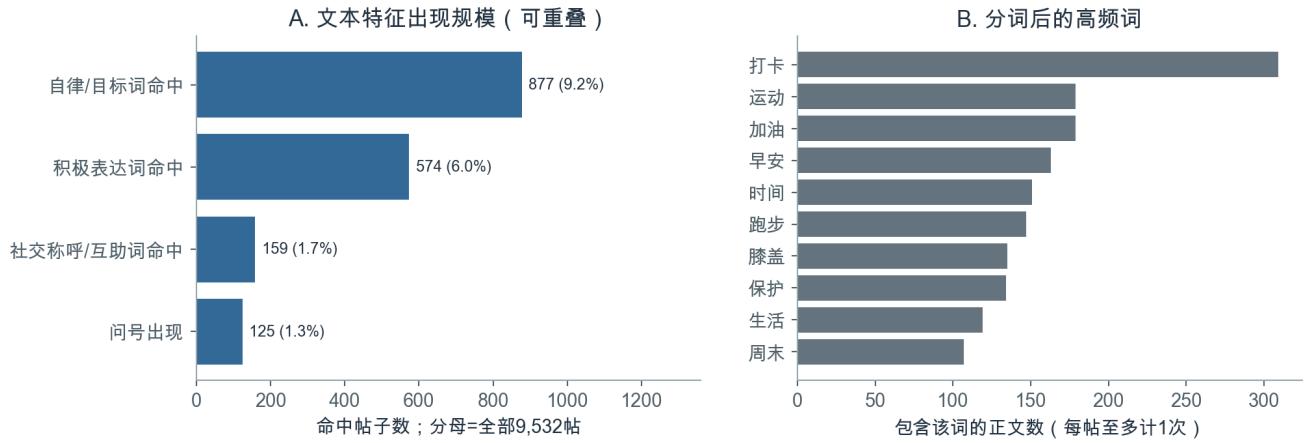


图3　文本特征命中数及高频词。各特征可重叠；正文分词仅分析清理后的可见文本。

特征	命中帖数	全部帖子占比	可见正文占比	有作者内变动的作者数
自律/目标词命中	877	9.2%	15.8%	76
社交称呼/互助词命中	159	1.7%	2.9%	42
积极表达词命中	574	6.0%	10.3%	64
问号出现	125	1.3%	2.3%	32

自律/目标词在全部帖子中占9.2%，在有可见正文的5548帖中占15.8%；不能混用两个分母。社交称呼/互助词和问号较少，分别仅有42和32位作者提供作者内部的0/1变化，其系数不确定性相对较大。

高频“打卡”“运动”“加油”等与健身记录语境相符，但不意味着平台上的全部内容以此为主。当前样本只覆盖100位作者，且41.8%的帖子没有可用正文；图片文字和视频语音未识别。

高频词为“含该词的帖子数”，每帖至多计1次；不是总词频。特征分母和作者内变动计数见text_features_summary.csv。

原始均值差异不能直接解释为内容作用

特征	命中帖平均点赞	未命中帖平均点赞
自律/目标词命中	63.67	34.36
社交称呼/互助词命中	89.96	36.16
积极表达词命中	57.29	35.76
问号出现	111.15	36.07

所有二元特征的命中帖在原始均值上都更受欢迎。例如社交称呼/互助词命中帖的平均点赞约90，未命中帖约36。这个比较同时包含作者受众规模差异、媒体形式差异及极端高赞帖，尚不能回答“同一作者采用这种表达是否更受欢迎”。

逐步控制什么

模型	控制项	比较含义
M1 基础关联	文本特征、内容形式、业务类型、时段、性别、keepValue、kgLevel、会员	不同作者和帖子混合后的条件关联
M2 作者固定效应	M1的帖子层面控制 + 作者虚拟变量；去掉作者内不变属性	同一作者不同帖子的条件比较
M3 主模型	M2 + 北京时间发帖日期固定效应	进一步扣除同一天的共同变化

100位作者的gender、keepValue、kgLevel和memberStatus在样本内均不变化；作者固定效应已吸收这些属性，所以M2/M3不再重复加入。没有粉丝数、推荐曝光、视觉内容质量、社交关系或统一采集时间，不能将固定效应解释为消除了全部混杂。

> **为什么不用“评论数”作为另一种全样本结果变量**
>
> 仅1323帖存在采集到的评论记录，无法知道其余帖子是真的零评论还是未采集。网络使用已有记录；回归不以这些记录推算完整评论效果。

主模型比较同一作者的不同帖子

$$\ln(1 + \text{likes}_{it}) = \alpha_i + \delta_d + \beta_1 \ln(1 + \text{length}_{it}) + \beta_2 \text{discipline}_{it} + \beta_3 \text{social}_{it} + \beta_4 \text{positive}_{it} + \beta_5 \text{question}_{it} + \gamma' Z_{it} + \varepsilon_{it}$$

i表示作者，t表示帖子；α是作者固定效应，δ是北京时间发帖日期固定效应。Z包括可见正文、话题标记、表情标记、课程分享标记、内容形式、业务类型和时段。日期按实际本地时间跨到2021–01–01，不人为截断。

项目	实施方式
估计	普通最小二乘；9532条观测，182个参数，设计矩阵满秩。
标准误	按100位作者聚类；CR1小样本系数修正；t分布自由度99计算p值和95%区间。[2]
多重检验	对五项核心文本系数进行Benjamini–Hochberg FDR校正；控制变量不加入该检验家族。
联合检验	五项文本系数同时为零的聚类稳健Wald F检验。
效应解释	二元变量的exp(β)−1表示“1+点赞数”条件几何均值的相对差异；不是算术平均点赞的变化，更不是因果提升。

长度使用自然对数：若1+正文长度翻倍，模型预期的1+点赞数几何均值乘以$2^{\beta 1}$。不把长度系数解释成“每多一个字增加多少点赞”。

这些规格在本次首次拟合前写入代码；没有事前注册。聚类稳健标准误允许同一作者误差相关及异方差，但不自动解决遗漏变量、抽样选择和反向因果。

没有充分证据表明核心词汇伴随更多点赞

核心变量	系数	聚类SE	95%区间	p	BH q
正文长度 ln(1+字数)	0.028	0.018	[−0.008, 0.064]	0.130	0.293
自律/目标词命中	−0.119	0.087	[−0.293, 0.054]	0.176	0.293
社交称呼/互助词命中	−0.004	0.064	[−0.131, 0.122]	0.946	0.946
积极表达词命中	−0.086	0.035	[−0.155, −0.016]	0.016	0.079
问号出现	0.108	0.105	[−0.100, 0.316]	0.307	0.383

因变量：ln(1+点赞数)。M3控制作者、日期、内容形式、业务类型、时段及其余文本标记；N=9532，作者聚类数=100。原始p值未使用星号，以免掩盖多重检验结果。

自律/目标词、社交称呼/互助词和问号的区间均包含零；这些结果不能支持“只需增加相关词就能获得更多点赞”。积极表达词系数为−0.086，原始p=0.016，但五项检验校正后q=0.079，未达到0.05。

模型	样本量	R^2	调整R^2
M1_基础关联	9,532	0.563	0.562
M2_作者固定效应	9,532	0.685	0.681
M3_作者与日期固定效应	9,532	0.688	0.682

主模型R^2=0.688，但五项核心文本特征相对“相同控制、去掉五项特征”的模型仅增加0.065个百分点解释度。五项系数联合检验F(5,99)=1.752，p=0.130。整体R^2的大部分不能归因于这些词汇。

> **不显著结果的正确读法**
>
> 现有样本与测量下，没有足够证据拒绝零关联；这不等于证明所有表达方式都没有作用。低频特征、粗糙词典和缺失视觉信息都可能降低辨识能力。

负系数也需要检验其稳定性

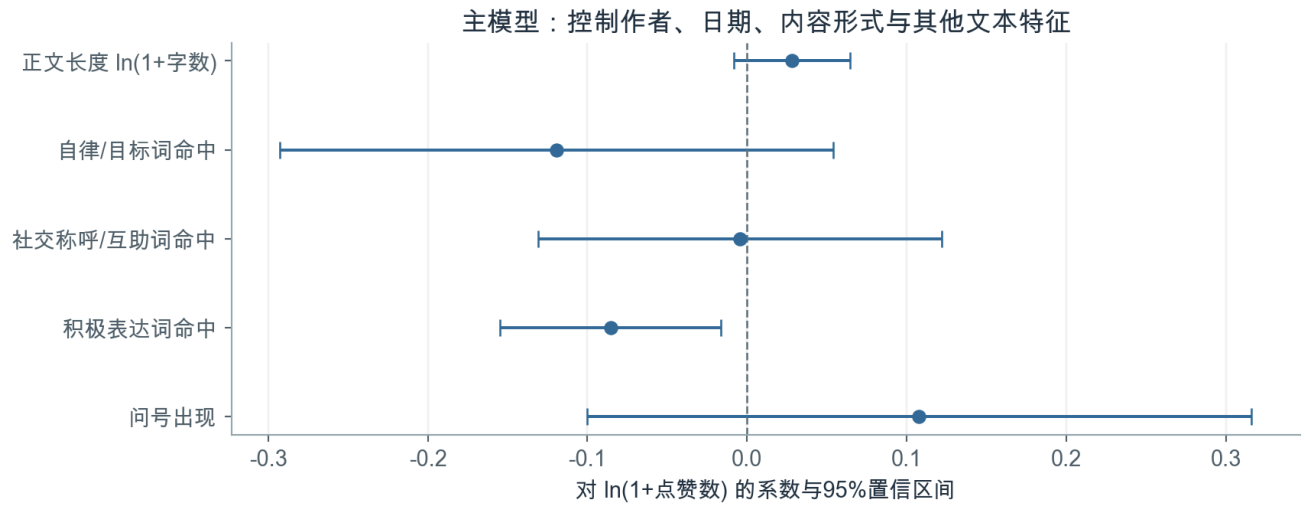


图4　M3五项核心文本系数和按作者聚类的95%置信区间。此处区间未进行多重检验调整；q值见表。

积极表达词的点估计对应“1+点赞数”的条件几何均值低约8.2%，其原始95%区间为[−14.3%, −1.6%]。这一变换仅说明模型尺度，不能据此建议减少积极表达。

原始均值为正、控制后的系数为负，说明发出这些表达的作者及帖子的其他特征与点赞有关。控制模型可改变比较对象，但并不证明积极表达造成点赞下降；词语可能出现在不同内容场景，仍有不可观测混杂。

长度的量级

1+正文长度翻倍时，主模型的1+点赞数几何均值点估计约变化2.0%；长度系数区间包含零。这不支持“文案越长越好”，也不能据此确定最佳字数。

全部系数、控制标记系数及变换区间保存在regression_coefficients.csv；词汇之间可能相关，见within_author_feature_correlations.csv。

换用计数模型后，积极表达的区间包含零

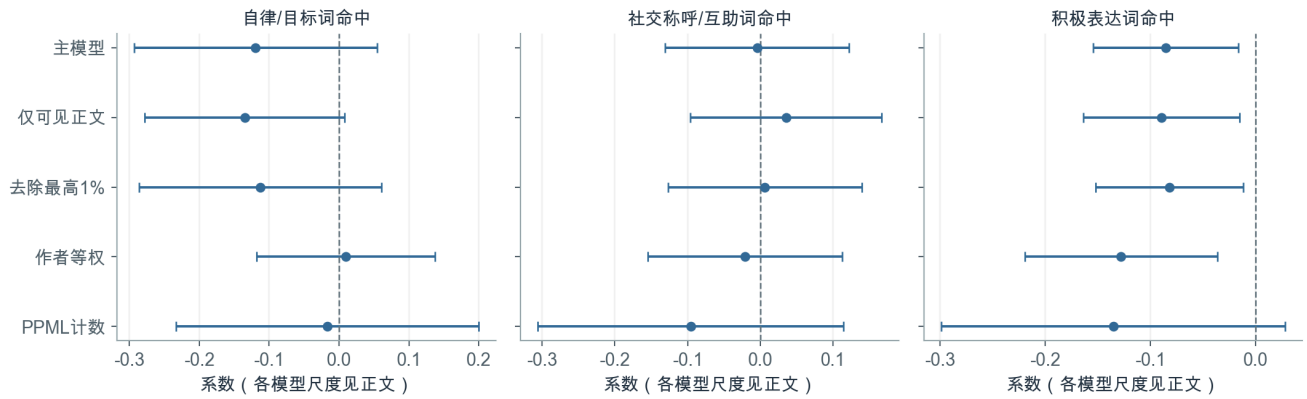


图5　三类词汇在不同规格下的系数与原始95%聚类置信区间。OLS刻画ln(1+点赞数)；PPML刻画算术条件期望点赞数的对数，系数不能直接视作同一估计量。

积极表达词规格	N	系数	95%区间	原始p
主模型	9,532	−0.086	[−0.155, −0.016]	0.016
仅可见正文	5,548	−0.090	[−0.164, −0.015]	0.019
去除最高1%	9,436	−0.082	[−0.152, −0.012]	0.022
作者等权	9,532	−0.128	[−0.219, −0.036]	0.007
PPML计数	9,532	−0.135	[−0.299, 0.028]	0.103

仅正文规格保留5548帖/95位作者；去除最高1%时，保留likes≤227.38的9436帖。作者等权使每位作者总权重相同，减少高产作者主导。PPML以原始点赞计数为因变量，采用相同控制项与聚类稳健推断，已收敛。

OLS中积极表达词的负关联在若干规格下仍存在，但PPML区间包含零，而且主模型BH校正后不显著。因此不能将它描述为稳定、确定的负面效果。其他词汇的证据同样不足，稳健性检验也不能消除选择偏差。

稳健性规格仅用于方向和敏感性检查，表内p值为各规格原始p值，不构成新的“挑显著”检验家族。完整五项结果见regression_coefficients.csv。

字面规则与真实语义之间仍有距离

对四类二元特征分别抽取5条命中及5条未命中的可见正文，共40个“帖子—特征”检查单元，可能含重复帖子。抽查样本未展示点赞数；由Codex辅助进行语义核查，未采用独立人工双编码，规则命中状态可见。它用于展示测量边界，不能据此宣称整体准确率或编码一致性。

例子与现象	规则结果	对解释的影响
“完成”的对象是身体部位配合或画作进度	自律词命中	通用词会产生健身自律语义的误报。
“一起”叙述线下和朋友跑步	社交词命中	不能据此推断面向线上受众的互动邀请。
“OK啦”表示满意	积极词未命中	口语表达可能被词典漏掉。
“我不要面子的吗？”等反问	问号命中	问号不是实际求助或信息需求。

保留哪些结论，放弃哪些推断

- 保留“含哪些字面词汇”及其统计关联，因为定义与代码可以复现。
- 不把词命中称为心理状态、真实社会支持、情绪强度或用户自律程度；不生成未经验证的情感总分。
- 不因结果不显著而回头修改词典；抽查发现用于限定结论，并为后续人工标注设计提供依据。
- 后续可从全部可见正文随机抽样，隐藏模型预测与互动指标，由两人按预先定义的语义标准独立编码，再报告一致性与分类误差。

完整40条记录及具体判断：results/text_coding_review.csv；固定抽样种子与过程：code/analyze.py、code/annotate_review.py。该抽查不是对独立测试集的效度验证。

一条边表示一次可观察的评论指向

根评论：评论者 → 帖子作者
明确回复：回复者 → replyUserId
同一用户对多次互动：合并为一条有向边，边权 = 事件数

先按cmtId去重，再用postId查找帖子作者。回复优先使用显式replyUserId；缺失时仅可用已观测的直接回复评论ID确定对象。不得把所有子评论都指向帖主。自我互动不进入网络，删除的84个事件单独记录。

转换阶段	规模
去重评论	11595条
时间早于所属帖的评论	0条
无法确定指向对象	0条
自我互动移除	84条
可用互动事件	11511次 = 6609次根评论 + 4902次明确回复
用户对合并后	4069条有向边；2932个有边节点
仅明确回复子网络	1074节点；1271边

网络只保留至少参与一条非自环边的节点；100位样本作者中有77位出现在该网络。其余不自动视作平台孤立用户。节点编号为稳定匿名标识，图和导出边表不显示原始用户ID。

> **网络指标不是发帖前的控制变量**
> 评论在发帖后产生，最晚延续到2021年8月。因此PageRank、入度或评论接收量只用于补充描述，不能作为“发帖前影响力”回归控制，也不能反推传播因果。

课程依据：《社交网络分析简介》第32—37页及《Social Network Influencial》第30、35页。[4][5] 网络是评论关系而非关注、好友或实际信息扩散路径。

少数账号连接了大部分已采集互动

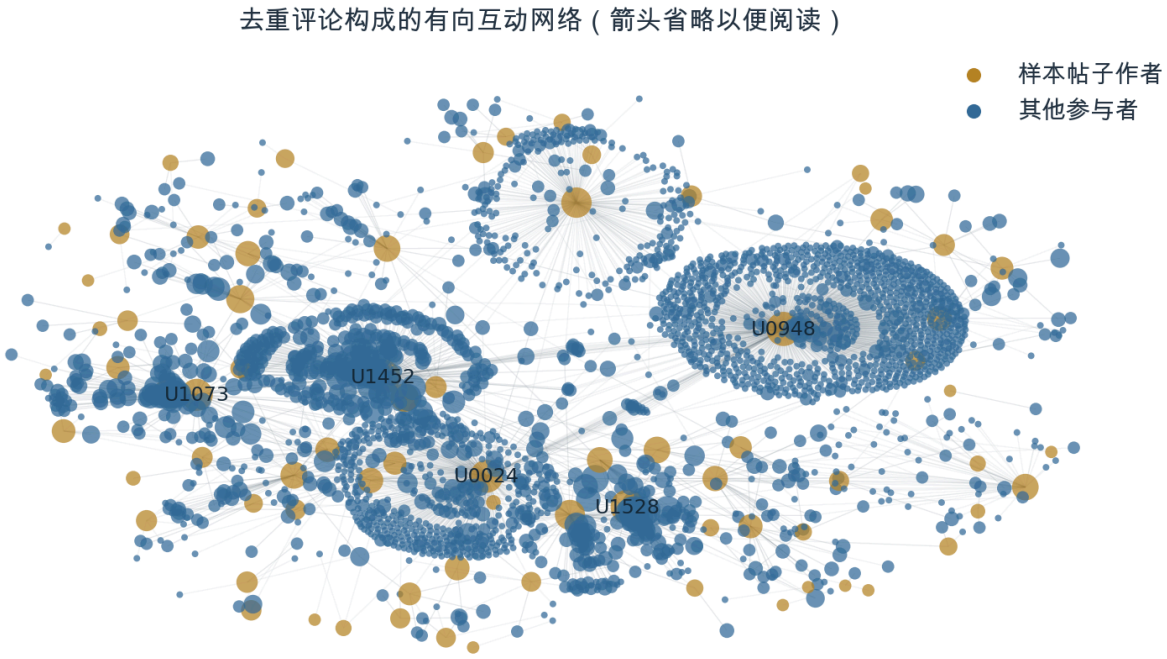


图6　全部2932个有边节点、4069条有向边。为可读性省略箭头；金色为样本帖子作者，蓝色为其他参与者；节点大小按接收事件数的对数缩放。仅标注前5位接收者。

指标	结果	含义
弱连通分量	35	忽略方向后彼此连通的子图数
最大弱连通分量	2768节点（94.4%）	有边节点大部分落在同一弱连通分量
密度	0.000473	4069 / (2932×2931)；稀疏程度受节点抽样影响
互惠率	49.6%	具有反向边的有向边占比，不按事件权重计算
仅明确回复互惠率	29.9%	改变建边范围后互惠率下降

最大弱连通分量占比高，说明这些采集互动存在跨作者的连接；它不证明单次内容能够触达全部节点。整体互惠率49.6%，仅明确回复网络为29.9%，显示根评论建边规则会影响结构指标。两个网络的节点集合不同，差异不宜解释为同一群体的行为变化。

布局使用固定种子的弹簧算法，节点的图面距离不是社交距离的统计估计。未计算网络总体的抽样置信区间，结果仅描述这一观测网络。

前10位接收者获得54.0%的互动事件

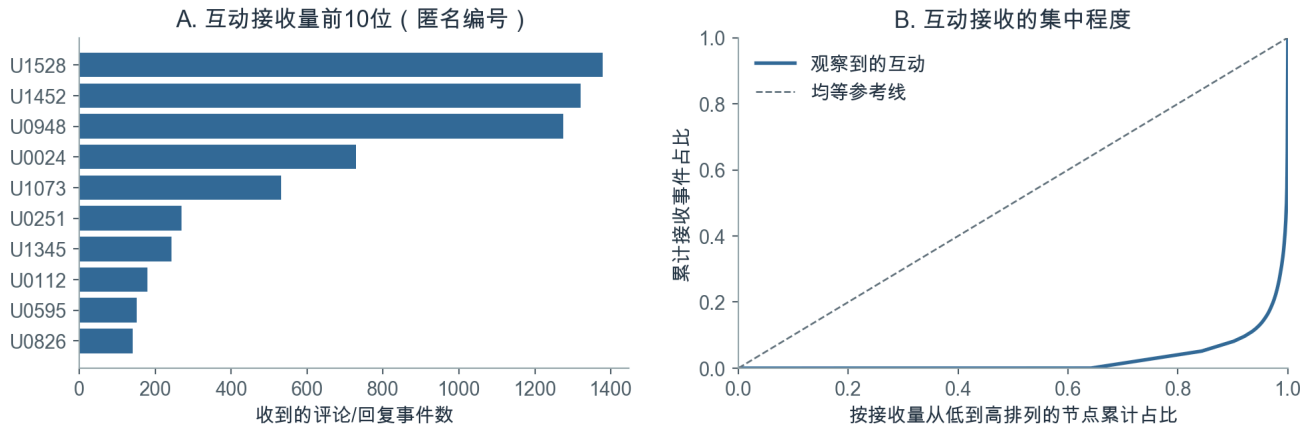


图7　接收事件前10位与累计接收分布。排序和占比均按边权，分母为11511次非自我互动事件；同一用户可重复产生事件。

前10位账号共接收54.0%的互动事件，第一位接收12.0%。61.3%的事件指向样本帖子作者。这里的“接收量”是评论和回复事件数，不是独立用户数、点赞数或平台粉丝数。

样本从100位作者的帖子出发采集评论，天然偏向这些作者及其活跃互动对象。根评论均指向帖主，结构上就会产生中心节点。集中度可用于说明样本内互动分配，但不能用来挑选Keep全平台“最有影响力用户”。

与文本结果共同说明什么

文本中的少量词汇不能稳定解释点赞差异，而已采集的评论在用户之间分配不均。这支持后续同时观察内容、受众及关系背景；它没有证明关系比内容更重要，也没有量化两者因果贡献。

入度表示不同发送者数量；加权入度表示接收事件数；PageRank为补充节点指标。三者在network_nodes.csv中分开保存，报告不将它们互换。

优先验证表达与互动机制，避免词汇处方

证据	可支持的建议	需要进一步验证
五项核心词汇联合检验p=0.130；词典代理粗糙	不要将固定词汇加入运营模板并承诺提升点赞。提供可选的真实运动经历、感受与问题填写提示。	内容质量、图片/视频和曝光机会是否改变结果。
原始均值与控制后系数不一致	评估内容方案时按作者或用户分组，记录曝光分母和统一观察窗口。	在可比作者、相近内容下做前瞻随机对照。
互动接收集中，且受抽样影响	对新用户和低反馈用户提供自愿互助场景；先监测是否有人被长期忽略。	用随机用户样本验证集中度；同时衡量回复质量。

后续研究设计（尚未执行）

若有平台实验权限，可将愿意参与的作者按用户随机分配至“运动过程记录提示”“面向伙伴的问题提示”和常规发布组，防止同一作者跨组污染。固定7天观察窗，记录真实曝光及独立互动用户数；把用户是否继续发布和高质量回复作为额外结果。样本量需用试点方差和最小有意义差异另行计算，本项目不虚设实验效果或样本数。

关键局限

- 100位作者的课程样本与不明抽样机制，不能外推到Keep总体。
- 正文缺失、图片文字和视频语音缺失，词典未经过独立人工效度验证。
- 统一采集时间、有效曝光分母和粉丝信息缺失；作者/日期固定效应不能完全处理帖子观察时长及时间变化的受众差异。
- 观察性回归不能识别因果；评论覆盖不完整，网络边界与根评论建边规则影响结构指标。

> **回答研究题目**
>
> 当前数据没有支持一种可复制的“高赞用词公式”。更可靠的产出是清楚的测量、可复查的条件关联，以及下一步能验证的研究设计。

结论可以追溯到数据、代码和原始材料

[1] Richardson CR, Buis LR, Janney AW, et al. (2010). An Online Community Improves Adherence in an Internet-Mediated Walking Program. Part 1: Results of a Randomized Controlled Trial. *Journal of Medical Internet Research*, 12(4), e71. doi:10.2196/jmir.1338。用于研究动机，不把该试验效果套用到Keep。

[2] statsmodels 官方文档：RegressionResults.get_robustcov_results，cluster参数、小样本修正与t分布推断。官方链接。访问：2026-10-16；实际使用statsmodels 0.14.2，数值复核采用独立矩阵算法。

[3] 课程材料《内容分析与自然语言处理.pdf》：第10页内容分析的三层问题，第14页预处理，第18页停用词，第24—28页中文分词。作者与年份未在文件中确认，故不补造。

[4] 课程材料《社交网络分析简介.pdf》：第32—37页网络度分布、点度与中介中心性。

[5] 课程材料《Social Network Influencial.pdf》：第30页入度/出度，第35页中心性与影响力的解释限制。

[6] 课程数据《KeepData_dictionary.pdf》与两份原始CSV；字段字典和数据原样保留在提交包。

复现顺序

```
python -m pip install -r requirements.txt
python code/analyze.py
python code/annotate_review.py
python code/validate.py
python code/build_deliverables.py
python code/render_outputs.py
python code/package_submission.py
```

分析过程.ipynb为已执行的伴随Notebook，保存表格和图像输出。数值核查用另一套矩阵计算独立复算主模型五项系数、聚类标准误、p值和区间，并核对去重、网络边权及互惠率。图表、回归表和正文均读取同一results目录。

所有产出均位于projects/group内。PDF由同一份分析报告.html打印生成；演示文稿复用同一批审阅过的PNG图与数值。没有发布到外部站点。

填写身份信息后即可整理提交

作业要求	对应成果
小组成员、题目与意义	封面、研究背景；成员留待真实填写
完整过程与描述统计	报告02—07及代码、Notebook
非结构化数据转结构化后回归	报告05—13；post_features.csv与回归结果
至少一种文本或网络分析	已完成词典内容分析、分词统计及评论网络
解释和建议	报告10—17；明确不显著结果及局限
Presentation全员参与	16页PPTX、逐页讲稿及建议分工表
PDF、PPT及必要文件打包	提交包ZIP含报告、演示稿、代码、数据、结果与复现说明

可调整的汇报分工

成员占位	建议负责内容	PPT页码
成员A【待填写】	研究背景、问题与文献核对	1—3
成员B【待填写】	数据清洗、描述统计与文本编码核查	4—7
成员C【待填写】	回归模型、推断与稳健性检验	8—11
成员D【待填写】	网络分析、建议与局限	12—16

仅为建议分工，尚非实际贡献记录。请按真实人数和完成情况调整；每名成员均需参与汇报。

课程PDF注明：以“第几组–社交媒体分析报告.zip”为文件名，课程截止后两周（11月10日23:59）提交，11月15日前各自提交互评。原文件未明确年份，本项目只转述原要求，不推断当前学期是否沿用该日期，请以课程平台通知为准。

> **提交前需要真实补齐**
>
> 填写组号、成员及学号；按实际人数和贡献修订分工；检查每位成员均有汇报部分；依组号重命名ZIP。互评模板不是已完成的个人互评，不能代替真实贡献记录。