Keep社区帖子特征与互动反馈

可观察字面特征、点赞关联与评论互动结构 | 2026年10月29日

摘要

本研究使用课程提供的9,532条帖子与11,595条去重评论，分析正文可观察范围、媒体形式和tag分布，比较固定词项、问号及正文长度与累计点赞的条件关联，并描述已采集评论的词项、直接回复和用户连接。主研究的测量对象是字面可观察特征，不再把固定词项或自动成分作为真实内容类别、人格、情绪或社会支持的测量。

正文清理后非空的帖子有5,414条；其中71.9%未命中四条固定规则。规则可以交叉命中，也不覆盖全部表达，未命中率不是分类错误率。三种既有正文口径并列报告：全样本、原始正文可见与清理后非空模型的五项联合p值分别为0.130、0.067与0.040。后者长度和开心等词项（C）的模型内BH q均约0.048，但这些口径是在原结果后补充比较的，不能据此追认为事前唯一主模型，或声称具有稳定增赞效果。

在4,902次明确回复中，89.0%由帖主发给其他用户；接收事件数相近的两个账号，发送者人数分别为53和1,091。评论次数、参与人数和直接回复覆盖提供不同的互动描述，均不直接等于真实社会支持或关系质量。

本轮未进行人工语义复核。候选内容框架、NMF成分、旧成分回归、多阈值及AI识别器均移入明确的探索性附录；400条文本的AI重建与留出预检验暴露了范围门控和过度检出问题，未形成可供正式类别效应分析的语义真值。主研究按当前可观察范围完成，人审手册及工具保留为有资源时的后续材料。

目录

章节	页码
1. 研究背景、问题与范围	3
2. 数据、可观察特征与分析方法	4
3. 正文可观察范围、媒体、tag与点赞分布	6
4. 字面表达的关联对正文可观测范围敏感	8
5. 评论词项与观测直接回复的分布	12
6. 评论区围绕帖主往来，互动量与人数需分看	14
7. 讨论、结论与后续资源	17
附录A　字面模型与互动口径的完整证据	18
探索性附录B　旧NMF词共现成分与候选内容框架	20
探索性附录C　400条文本的AI重建与识别器失败	23
附录D　复现位置与成员分工	24
参考文献	25

小节标题见正文；PDF书签可跳转章节。

1. 研究背景、问题与范围

1.1 从运动社区中的发言与反馈出发

Keep的帖子同时含有正文、媒体和平台元数据。用户可能发布很短的记录，也可能在评论区与其他账号往来。只比较高赞帖常见用词，容易把作者、媒体和累计观察时间的差别一并归入文案。本研究因此分开描述样本覆盖、正文特征的条件关联，以及采集到的回复连接。

既有运动社区研究为讨论线上参与提供背景[1]，词项计数和文本矩阵方法提供可复核工具[2–4]。这些文献不能替本样本验证某个词组对应的心理构念。本报告把解释限制在已记录的字面特征、点赞与互动结构。

1.2 三个研究问题

问题	本轮问题	证据与章节
RQ1	样本的正文可观察范围、媒体形式、tag和点赞如何分布？	覆盖、媒体、tag与点赞描述；第3章
RQ2	固定词项命中、问号和正文长度与点赞是否存在条件关联，结论对样本口径及控制项如何变化？	冻结模型、口径及控制项对照；第4章
RQ3	已采集评论的字面线索、直接回复方向及用户连接如何分布？	评论词项、直接配对和有向网络；第5—6章

1.3 本轮正式研究与探索材料的边界

主研究保留既有清理、固定词表、匹配方法、控制项与估计值，不重新选择统计结果，也不添加新的p值。所有正文模型并列披露；原M3是历史全样本设定，正文可见与非空口径是已有补充比较，均不因显著性被追认为事前唯一主模型。

本轮未进行人工语义复核，已完成的计算核查不称为语义效度验证。候选分类不进入正式RQ或主研究结论；旧NMF成分和分类重建仅在探索性附录记录其方法、结果与失败。未来若有资源，可使用现有手册与独立标注工具开展新的语义研究；这不是本作业本轮交付的先决步骤。

2. 数据、可观察特征与分析方法

2.1 数据来源和清理口径

研究使用课程提供的帖子表、评论表和字段说明。9,532帖来自100位作者，帖子发表于2020年11—12月（UTC）；北京时间末端跨至2021年1月1日。11,595条去重评论最晚延续至2021年8月26日。文件名中的“2022”不代表观测年份。

核查项	已有结果	本轮解释
帖子与评论主键	帖子ID唯一；评论ID重复1,916行，无字段冲突	评论按ID去重，保留11,595条
原始正文	5,548帖有可见字符，3,984帖不可见	未记录正文不能视为原帖没有内容
清理正文	5,414帖非空；134帖原始可见但清理后为空	与全样本、原始可见口径并列
评论覆盖	去重评论均能关联帖子，分布在1,323帖下	其余帖子评论覆盖未知，不填成零评论
点赞与浏览	8,286帖点赞数高于记录浏览数	不计算点赞率，使用累计点赞
时间、媒体和长尾	累计观察时长未知，未读取图像或语音内容	不以正文补出媒体语义；保留极端值敏感性

正文清理还原转义换行，移除URL、成对的课程分享后缀和方括号表情，并统一空白；原始hashTags字段不拼入基本正文。没有正文的全样本记录将字面特征设为0，并加入原始正文可见标记；该处理描述记录状态，不能恢复缺失内容或校正非随机缺失。

2.2 正文的四条规则列全词项，不作为语义分类

正文长度为ln(1+清理后非空白字符数)。以下规则按固定子串或已冻结模式匹配，任一命中记1，重复出现不累加。A含下表末项正则模式，其余词项作字面子串匹配；B、C和D先对词项作正则转义再匹配，不是按分词频率编码。A、B、C、D可以交叉命中，既不互斥，也不完备。它们不直接测量人格、情绪、真实提问或社会支持。

A—C最初按词语的直观含义编制，缺少独立词表评审和语义验证。本版仅将它们沿用为固定、可复算的探索性操作指标；中性改名不补上理论或经验效度，也不表明三组词项是语料自然形成的分类。本轮未因显著性保留、增删词项，既有匹配规则不变。

字面特征	全部固定词项 / 模式	操作与边界
坚持等词项命中（A）	坚持、自律、打卡、目标、计划、努力、加油、挑战、突破、完成、进步、不放弃、全勤、第[0-9一二三四五六七八九十百千]+天	末项为既有正则模式，其余按子串；不判断否定、反讽、意图或行为真实性。
大家等词项命中（B）	大家、朋友们、小伙伴、你们、一起、互相、互勉、共勉、陪伴、谢谢、感谢、请教、求助、求推荐	任一子串命中记1；未处理否定、反讽或上下文含义。
开心等词项命中（C）	开心、快乐、高兴、幸福、喜欢、美好、满足、舒服、棒、赞、愉快、美滋滋、哈哈、嘻嘻、嘿嘿	任一子串命中记1；未处理否定、反讽或上下文含义。
问号出现（D）	?、？	任一问号出现记1；修辞问句会命中，无问号的提问可能漏掉。

同一条“加油”可能用于自我提醒或给别人留言；“谢谢”也不能证明已经发生互助。规则名称仅帮助读者辨认所列词项。数值共线性与语义含义是不同问题，低VIF不证明四项是独立心理维度。

辅助控制沿用原始正文可见状态、有无原始tag、表情数量、课程分享标记、媒体形式、业务类型和发帖时段。原始tag是用户选择的元数据，不能作为正文语义的标准答案。

2.3 点赞模型与三种正文口径并列

因变量为ln(1+点赞数)。原M3同时放入正文长度、A—D、已记录控制项、作者固定效应及北京时间发帖日期固定效应。作者固定效应调整不随帖子变化的作者间差别，日期固定效应调整同日共有差别；标准误按各模型实际包含的作者聚类，保留有限样本修正及t / F推断[5]。

原全样本9,532帖 / 100位作者、原始正文可见5,548帖 / 95位作者、清理后非空5,414帖 / 95位作者均报告。每个模型内的五项系数用Benjamini–Hochberg方法作BH校正，并列五项联合检验[6]。模型内BH不覆盖所有口径、控制项和探索分析，因此q=0.048不构成对整个研究探索过程的统一校正。

作者支持、少帖作者、tag身份与拼接、完整设计矩阵VIF、最高1%点赞剔除、作者等权、PPML和逐作者剔除沿用既有冻结结果。这些检查说明比较对处理方式如何变化，不能修复缺失曝光、累计时长或语义测量。

2.4 评论的字面规则、直接配对与网络

评论按ID去重，统一全半角与空白，移除URL和方括号标记。词项每条评论至多计一次，各组可交叉命中，分母为相应角色全部已采集评论。为使规则可复核，完整列出原评论词表；组名只指词项集合。

评论字面规则	全部固定词项
加油等词项（评论组1）	加油、棒棒、真棒、太棒、很棒、厉害、优秀、佩服、精彩、漂亮、好看、点赞、好赞
谢谢等词项（评论组2）	谢谢、感谢、多谢、谢啦、谢了、感恩
早安等词项（评论组3）	早安、晚安、早上好、晚上好、下午好、中午好、周末好、节日快乐、新年快乐、生日快乐
问号（评论组4）	?、？

直接配对以其他用户发给帖主的根评论为起点，要求所属帖子、reply、replyUserId和parentId共同匹配，在根评论后168小时内取最早观测到的帖主直接回复。未采到直接回复不等于实际上没有回复。

有向网络以账号为节点、发送者指向接收者：根评论按所属帖子指向帖主，明确回复指向被回复账号。同向多次事件合并为边权，排除84次自我互动。全部事件、仅明确回复与发帖后7天三种范围分别描述。评论词项与网络均不度量真实支持、情感或关系质量，也不放入发帖前点赞模型。完整配对、窗口和互惠口径见附录A。

3. 正文可观察范围、媒体、tag与点赞分布

本章回应RQ1，说明可以观察哪些正文、媒体和元数据，以及点赞分布的范围，为第4章的关联比较和第5—6章的评论描述确定分母。

3.1 正文覆盖随内容形式变化，评论记录集中在部分帖子

文字记录的覆盖随内容形式和作者而变化。9,532 帖中，5,548 帖有可见正文，3,984 帖无可用正文；清理后仍非空的正文为5,414 条。图片帖的正文覆盖率为76.0%，视频帖为89.1%，纯文字帖为100.0%，无媒体帖仅为0.1%。100 位作者中，5 位完全没有可用正文，26 位每帖都有正文，正文覆盖率中位数为84.3%。文本分析因此主要呈现正文较充分的内容形式与作者的表达。

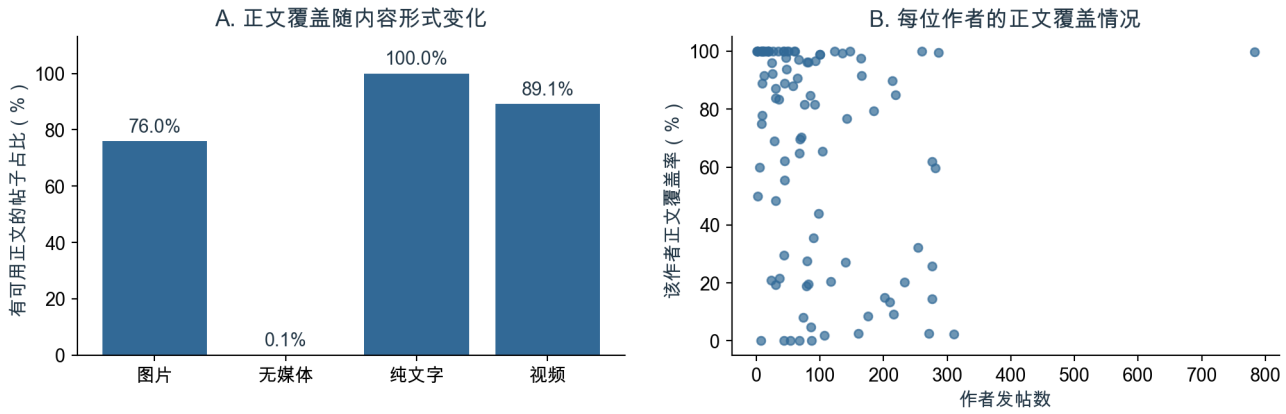


图1　不同内容形式的正文覆盖率，以及100 位作者的发帖数与正文覆盖率。覆盖按原始正文是否存在可见字符界定。

原M3以全部帖子为历史比较范围；原始正文可见和清理后非空口径同时列出。3,984帖的原始正文不可见，另有134帖清理后为空。图片文字和视频语音尚未观察，不能用缺失标记或现有正文规则补齐。

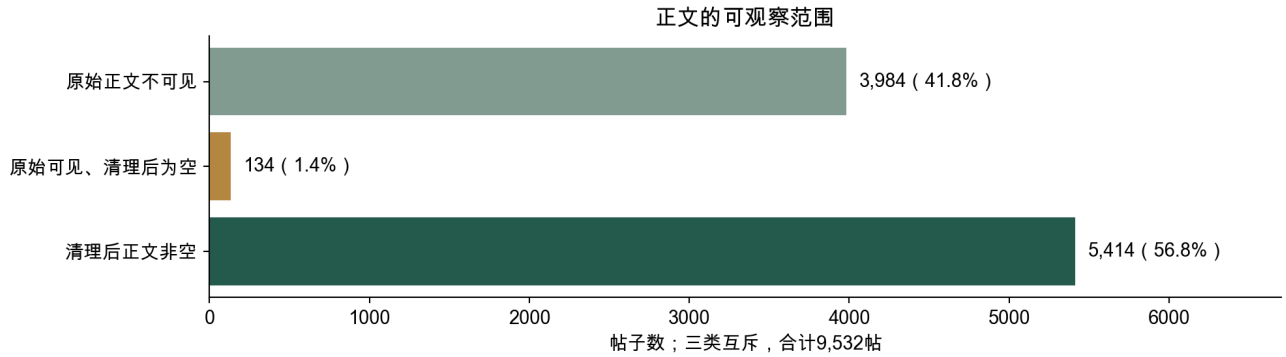


图2　按原始正文可见与清理状态划分，三类互斥，合计9,532帖。图中表示记录可观察范围，不是语义类别。

评论数据覆盖的是已采集到的互动。原始13,511 行按评论ID 去重，删除1,916 行无字段冲突的重复记录后，剩下11,595 条，全部能够关联到帖子，分布在1,323 帖下；其余帖子的评论情况记为覆盖未知。不同ID 下的相同短句仍然保留，以记录不同账号或时点实际发生的发言。

按实际时间字段，帖子发表于2020 年11—12 月（UTC）；转换成北京时间后，末端少量帖子跨至2021 年1 月1 日。评论最晚延续至2021 年8 月26 日。分析范围为课程提供的这批历史样本，抽样机制和统一采集时点未提供，全文据此讨论样本中的内容与互动。

3.2 点赞分布有长尾，作者发帖量也不均衡

样本包含100 位作者的9,532 条帖子。平均每帖获得37.05 个赞，中位数为25，最高一帖达到5,126，零点赞占3.8%。均值高于中位数，反映少量高反馈帖子将平均水平向上拉；中位数则更贴近分布中间的帖子。

作者发帖数中位数为66，最多一位发布783帖，高产作者的内容习惯因而会在按帖统计的结果中出现更多次。

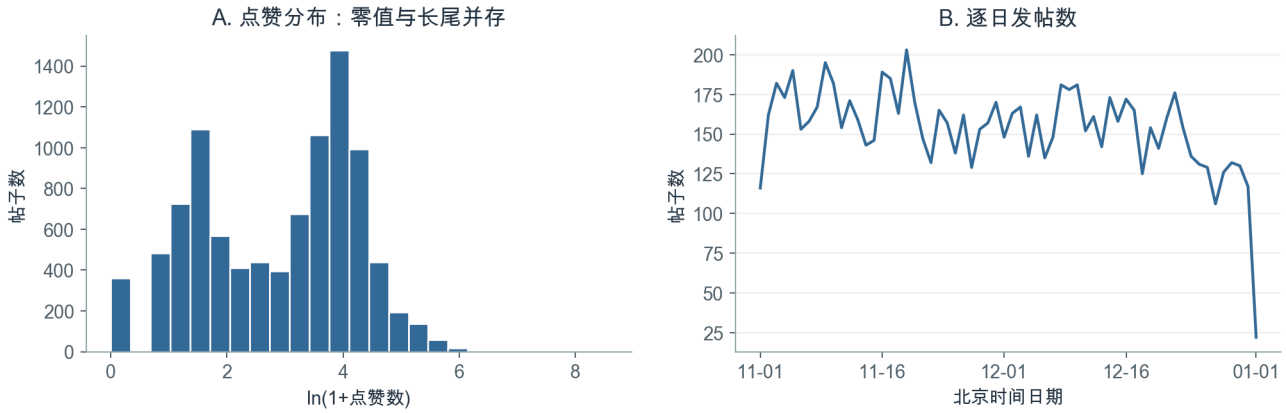


图3　全部9,532 帖的点赞分布与北京时间逐日发帖数。首末本地日期的观察时长均不足完整一天。

不同内容形式的反馈差别也很大。图片和视频帖的平均点赞分别为51.03 和48.05，纯文字帖为7.94，无媒体帖为3.91；中位数保留了相同的排序。读者实际看到的是，不同形式的帖子处在很不一样的反馈水平上。因此，讨论文字表达之前，必须把媒体形式及其对应的作者和内容情境纳入比较。

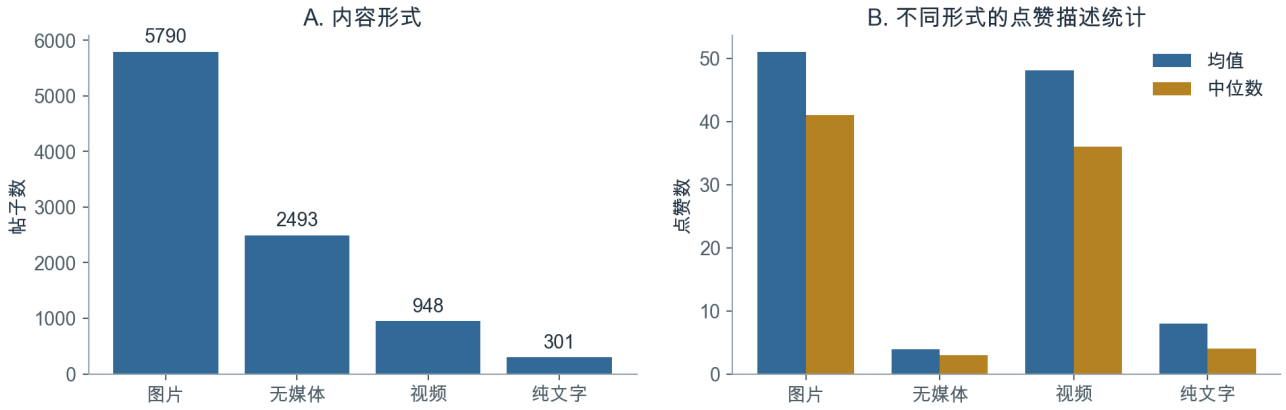


图4　按原始内容形式字段划分的帖子数、平均点赞与点赞中位数；内容形式与有无可用正文分别统计。

媒体形式对应着不同的累计点赞水平，后续文字比较据此同时控制媒体形式、作者和帖子情境。但样本中8,286 帖的点赞大于记录浏览数，两个字段的统计口径存在差异。完整媒体分组数值见附录A。

3.3 原始tag覆盖一半以上帖子，与正文可见并不相同

5,209帖带有原始tag，占54.6%，共269种；其中1,517帖没有原始正文。5,207帖只有一个tag，仅2帖有两个。有tag、正文可见和某条规则命中分别描述不同字段，不能相互替代。tag的身份控制和拼接比较在第4章单独报告，避免把平台活动标题中的固定用词当作原正文的新增表达。

4. 字面表达的关联对正文可观测范围敏感

4.1 原始均值有差异，但词典只能覆盖部分表达

以下原始均值沿用历史9,532帖的编码比较，“未命中”组包含没有观察到正文的记录，不能视为已经确认这些帖子不使用相应用词。未调整时，四项字面线索的命中组平均点赞均较高：坚持等词项（A）63.67对34.36，大家等词项（B）89.96对36.16，开心等词项（C）57.29对35.76，问号111.15对36.07。两组的作者、媒体和发帖情境并不相同，这些均值描述的是组别构成与反馈的共同差别，不能直接解释为措辞效果。

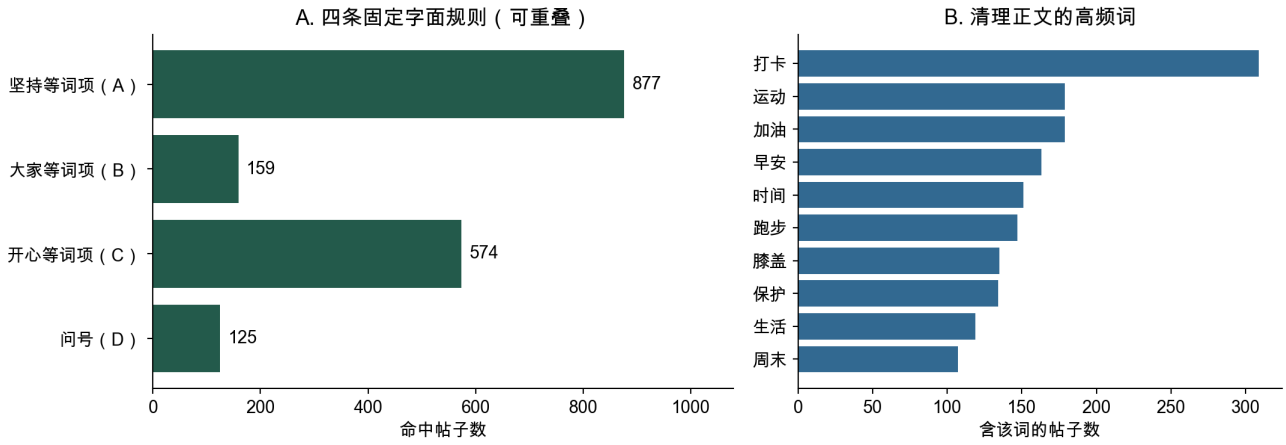


图5　指定字面特征的命中数与高频词。它们可重叠，词频以含该词的帖子数计，每帖至多一次。

字面线索	命中帖数	全部帖子占比	有作者内变化的作者数	完整原M3 VIF
坚持等词项命中（A）	877	9.2%	76	1.750
大家等词项命中（B）	159	1.7%	42	1.149
开心等词项命中（C）	574	6.0%	64	1.186
问号出现（D）	125	1.3%	32	1.112

非空清理正文中，只有1,523帖命中至少一项，3,891帖没有命中任何规则，占71.9%。71.9%是四条非完备规则的未命中比例，不是分类错误率。全样本未命中数为8,009，其中包含未观察到正文的记录。这不是“多数帖子没有表达”，而是说明指定词表只捕捉了局部线索。RQ2的结论因而必须限定为这些规则的关联，不能概括全部内容的作用。

四项全样本最大两两φ相关为0.119，作者内最大相关为0.085；完整M3的四项VIF为1.11—1.75，设计矩阵9,532×182且满秩。182帖同时命中至少两项。现有数值未呈现明显共线性，不支持仅因担心重复而合并规则；低VIF也不能证明语义独立或量表有效。[10]

4.2 原M3的估计可复算，但不能替代可观测正文中的比较

原全样本M3中，开心等词项（C）系数为−0.086，原始95%区间为[−0.155, −0.016]，原始p=0.016；对五项同时作BH校正后q=0.079。五项联合p=0.130，新增R^2为0.065个百分点。这些是原设定下可以复算的结果。

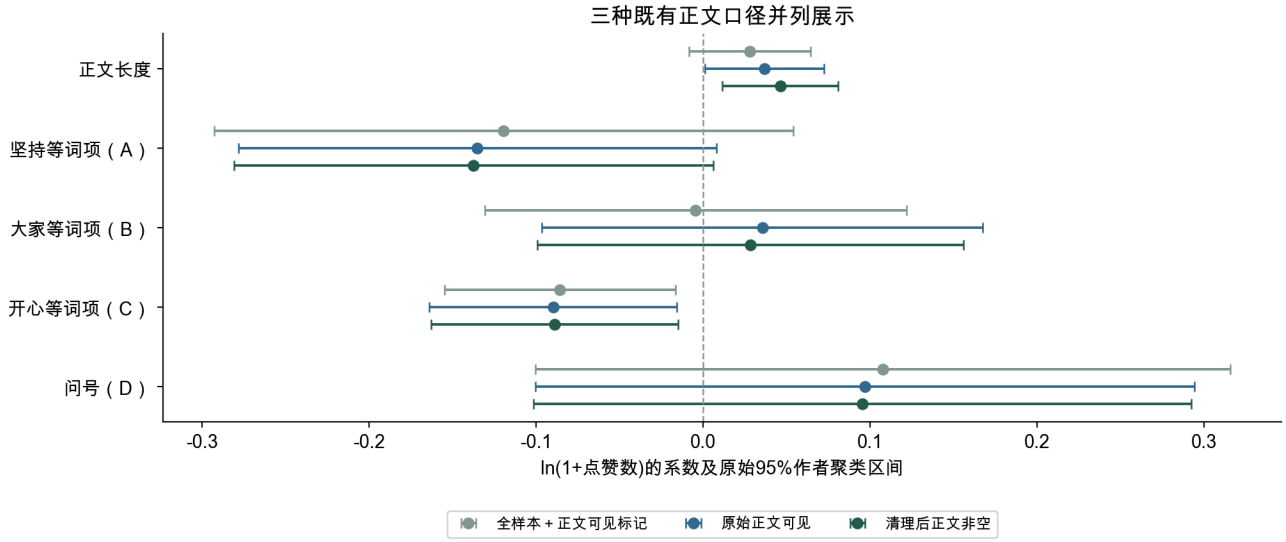


图6　三种既有正文口径的五项系数与原始95%作者聚类区间；样本数、作者数和模型内BH q见下表及附录A。

原始算术均值与模型的对数条件关联也不在同一尺度，不能将方向差别单独归因于作者固定效应或某一个控制项。把研究对象限定为正文实际可见的帖子后，比较范围发生了变化。原始正文可见的5,548帖仍包含134条清理后为空的记录；非空清理正文为5,414帖。三个口径的结果并列如下：

正文口径	帖数 / 作者数	五项联合p	长度BH q	开心等词项（C）BH q
原全样本 + 缺失标记	9,532 / 100	0.130	0.293	0.079
原始正文可见	5,548 / 95	0.067	0.106	0.093
清理后正文非空	5,414 / 95	0.040	0.048	0.048

在非空正文模型中，长度系数为0.046、开心等词项（C）系数为−0.089，两项在该模型内的BH q均约0.048，整组p约0.040。不能因此挑选这个模型来宣布稳定效果，也不能继续把全样本p=0.130概括为所有正文处理都没有关联。该重分析是在原结果之后开展，且没有对所有探索性模型统一校正；结果靠近阈值，仍受到正文可观察范围的选择限制。三种p值的变化不是系数之间差异的显著性检验，也不能证明非随机正文缺失已被解决。

本轮正式问题聚焦可观察的固定字面特征，三种正文口径并列解释。非空正文口径的p=0.040和两项q=0.048不被追认为事前确定的唯一主模型；全样本p=0.130也不被概括为文字普遍没有关联。三者都缺少实际曝光、完整媒体内容和统一累计观察时长，不能识别词项的因果作用。

4.3 少帖作者没有主导原字面结果，稀少特征的支持仍有限

全样本100位作者的发帖数最少1、中位数66、最多783。2位作者只发1帖；不超过10帖的14位作者合计80帖，占0.84%。单帖作者没有作者内变化，不为共同斜率提供这种信息，但少帖存在本身不使固定效应整体失效。

分别剔除发帖少于5帖或10帖的作者，原字面模型得到以下结果：

保留规则	帖数 / 作者数	五项联合p	开心等词项（C）β / BH q
原全样本	9,532 / 100	0.130	−0.086 / 0.079
每位作者至少5帖	9,524 / 95	0.131	−0.086 / 0.080
每位作者至少10帖	9,462 / 87	0.130	−0.085 / 0.095

这些门槛没有实质改变原M3的统计判断，提示少帖作者不是这项结果的主要来源。不过，长度在93位作者内有变化，大家等词项（B）只有42位、问号只有32位；不能把100个作者理解为每个特征都有100个充分的变化来源。固定效应也不能排除同一作者随帖变化的曝光和内容差别。

4.4 原始话题标签值得控制，但拼进正文会改变测量

5,209帖有原始tag，占54.6%，共269种；其中1,517帖没有原始正文。原M3已经控制“有无标签”，并非没有考虑tag，但没有控制具体标签身份。

既有补充分析只依据频数与作者覆盖，选择至少30帖、至少5位作者使用的9个tag身份作为补充控制，并保留原正文编码。另把正文与tag拼接后重编码，作为测量范围变化的对照：

设定	五项联合p	开心等词项（C）β / BH q	实际比较
原M3	0.130	−0.086 / 0.079	正文线索，已有has_tag
加9个tag身份控制	0.102	−0.083 / 0.088	正文范围不变，调整常见标签差别
正文 + tag重编码	0.173	−0.070 / 0.167	被测文字范围改变

拼接后，坚持等词项（A）命中从877增到3,342帖，问号从125增到354帖。统一的“坚持 Keep 的那些天”或带问号的活动标题可以机械地增加命中，不能等同为作者在正文中表现了不同的真实行为或提问意图。原始tag本身也不保证与正文主题一致，因此用作并行元数据和敏感性对照，不作为语义标签的标准答案。

9个常见tag是控制项，不是新的九类内容。没有进一步加入标签数量，是因为5,207帖只有一个tag，仅2帖有两个；在有无tag之外加数量，额外变化几乎只来自这两帖。

4.5 方向相近，不等于所有统计判断都稳定

原有的原始正文可见、去除最高1%点赞、作者等权和逐作者剔除分析中，开心等词项（C）的点估计方向较一致；100次逐作者剔除均为负，范围为[−0.100, −0.074]。PPML计数模型也给出负向点估计，但原始区间跨零。

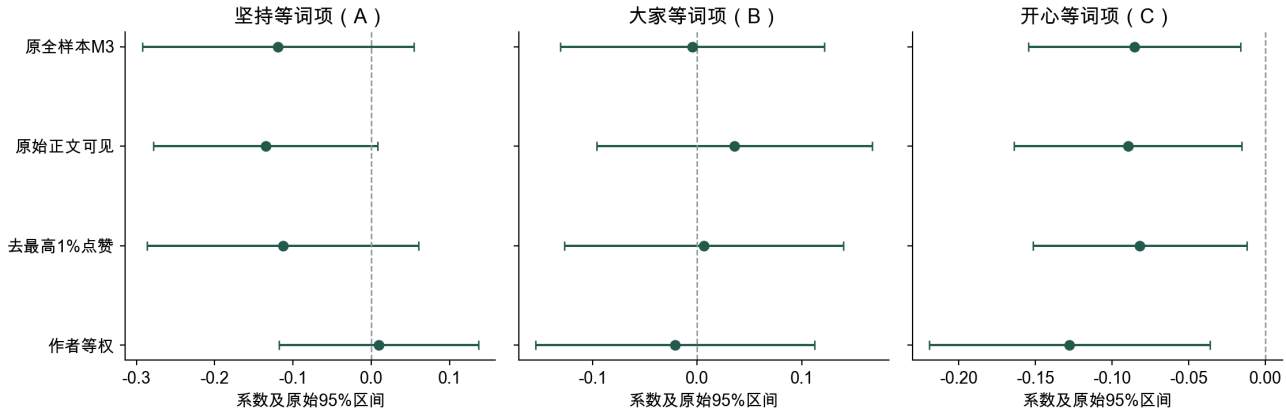


图7　从冻结结果表重画的A、B、C系数与原始95%作者聚类区间。原“仅可见正文”是5,548帖口径，不含本轮新增的5,414帖模型；不同尺度不能直接比较系数幅度。

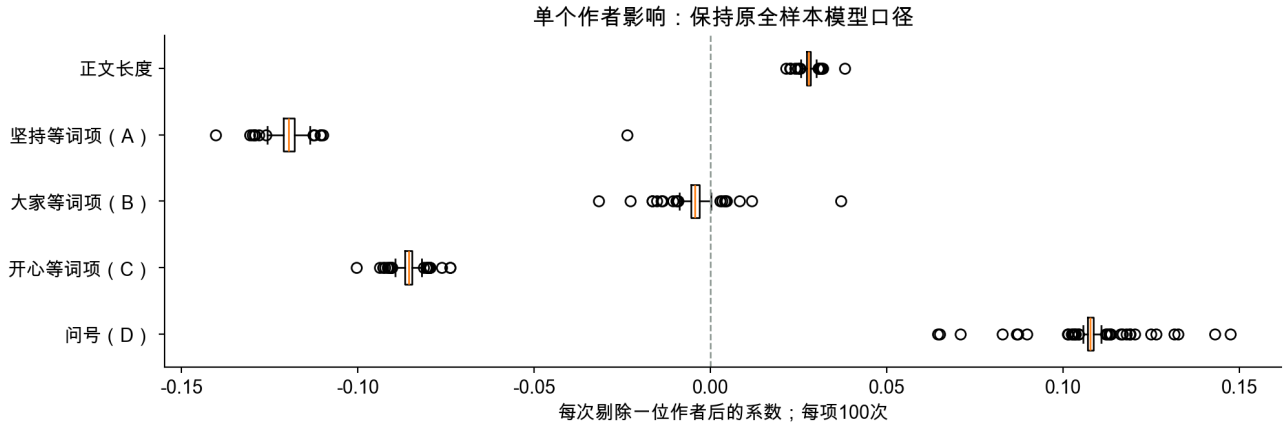


图8　原全样本设定中逐一剔除作者后的系数分布。这项检查处理单个作者影响，不处理语义效度或正文非随机缺失。

因此，本章保留的判断是：开心等词项（C）的负向点估计在若干处理下相近，但整组证据与多重检验结论会随正文口径改变。数据提供的是受测量、样本和已记录控制条件限制的关联，不能据此建议通过减少开心等词项（C）来提高点赞。

5. 评论词项与观测直接回复的分布

5.1 短评论与重复词项有不同的用户覆盖

清理后评论字符数中位数为6、75分位数为10；1,373条只留下标记或符号，占11.8%。这些记录只支持评论长度与字面形式的描述，不能据此判断发言者的态度强度。

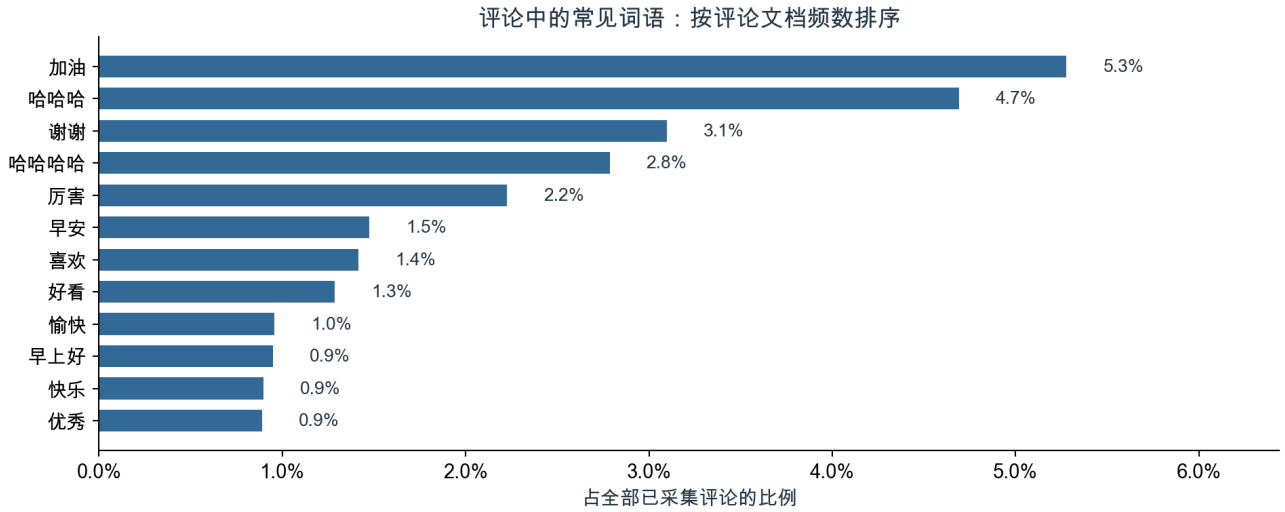


图9　以11,595条去重评论为分母展示常见词的出现占比。每条评论内同一词至多计一次，词项至少覆盖5位发言用户，各词可共同出现。

“加油”出现在612条评论中，涉及431位发言用户；“谢谢”出现在359条评论中，涉及53位用户。前者在更多用户之间出现，后者更集中于较少使用者。另有3,362条评论具有重复的标准化文本，按不同ID保留。评论次数和不同发言用户数应同时报告，不能把重复的短句直接当作更深的关系。

5.2 发言角色对应不同词项命中率

其他用户发言7,192条，帖主发言4,403条；同一用户可在不同帖子下切换角色。下表与图按每条评论的所属帖子定义角色，保留根评论、回复及84次自我互动。

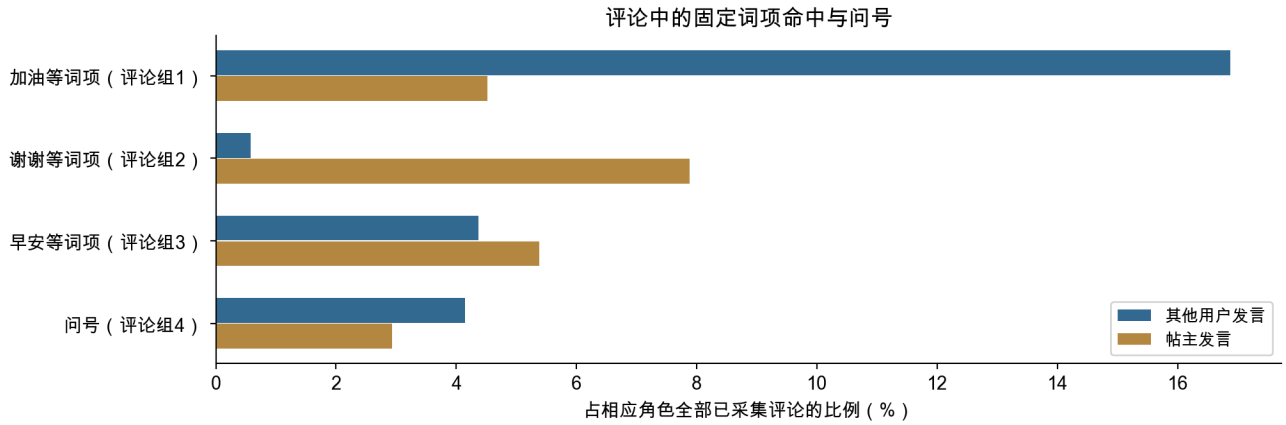


图10　按发言者是否为所属帖子的作者分组，比较四组固定字面规则。分母为各角色全部已采集评论，各项可以重叠。

评论字面规则	全部命中数	全部占比	其他用户命中率	帖主命中率
加油等词项（评论组1）	1,413	12.2%	16.9%	4.5%
谢谢等词项（评论组2）	389	3.4%	0.6%	7.9%
早安等词项（评论组3）	551	4.8%	4.4%	5.4%
问号（评论组4）	427	3.7%	4.1%	2.9%

评论组1在其他用户发言中的比例较高，评论组2在帖主发言中的比例较高。这是词项与角色的对应分布。评论组2包含“感谢”“多谢”等完整表中所列词项，因此命中数389大于“谢谢”单词项的359。它们不能直接证明已经发生真实支持，或将“感谢”解释为支持效果。

5.3 根评论的直接回复覆盖与回复词项应分开看

从6,609条其他用户发给帖主的根评论出发，按冻结规则查找根评论后7天内、明确指向该条评论及其作者的帖主回复。每条根评论只取最早符合条件的观测回复，共有3,568条根评论配到回复。

根评论的字面规则	根评论数	涉及帖主数	观测到7天内直接回复	已回复记录中，最早回复命中评论组2
命中加油等词项（评论组1）	1,180	54	513（43.5%）	137（26.7%）
未命中加油等词项（评论组1）	5,429	77	3,055（56.3%）	195（6.4%）

直接回复比例以各组全部根评论为分母；最后一列仅以已观察到直接回复的根评论为分母，同一帖主可以进入两组。命中评论组1的根评论中，最早回复命中评论组2的比例在已回复记录中为26.7%，另一组为6.4%；换成全部根评论作分母则为11.6%和3.6%。

同一批记录中，评论组1命中组的观测直接回复覆盖为43.5%，低于未命中组的56.3%。这说明回复词项分布和直接回复覆盖可以走向不同。它不证明某组留言更容易被忽视或得到更高质量回应，因为帖主、具体情境与采集完整程度各不相同。本轮没有对此新选显著性检验，也不把未命中组视为语义上缺乏鼓励或未获得支持的对照组。

6. 评论区围绕帖主往来，互动量与人数需分看

6.1 评论指向和重复次数，构成用户间的关系网络

图11中的每个点是一位用户账号。线从评论发送者指向接收者：根评论按归属指向帖主，明确回复指向记录中的被回复用户。同一发送者向同一接收者评论多次，合并成一条有向边，次数累加为权重。十次同方向留言在图中对应一条权重为十的边，记录的是这对账号之间累计发生的事件。

排除84 次自我互动后，11,511 次评论事件合并为4,069 条有向边，涉及2,932 个有边账号。节点同时包含发送者和接收者，文本统计中的2,910 位发言者则只计算实际发出评论的用户。网络由此把每次发言放回到它所指向的对象上，呈现谁向谁留言或回话。

为回答不同问题，原有分析实际用了三种网络范围。

网络范围	节点与边	权重与所含事件	它主要帮助理解什么
全部已采集互动	2,932 个账号、4,069 条有向边	同方向事件次数为权重；包括6,609 次根评论及4,902 次明确回复	留言与回话合在一起，向谁集中
仅明确回复	1,074 个账号、1,271 条有向边	同方向重复回复合并为边；既有互惠统计不赋权、不计重复次数	去掉根评论归属后，明确回复关系是否双向存在
发帖后7 天内	1,376 个账号、2,278 条有向边	同方向事件次数为权重；包括该窗口内的根评论和明确回复	限定发帖后首周，结构描述如何变化

三类网络都排除自我互动，方向均为发送者指向接收者；首周网络来自全部已采集事件的时间截取。

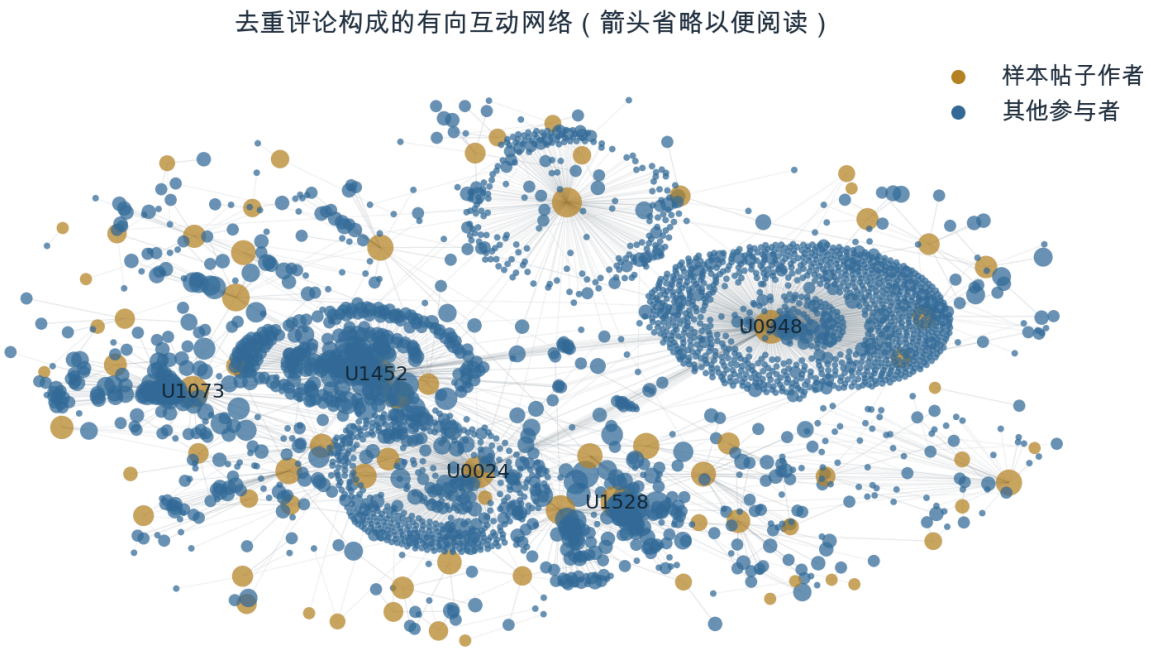


图11　全部2,932 个有边节点与4,069 条有向边。为便于阅读，图中省略箭头；金色为样本帖子作者，蓝色为其他参与者，节点大小按接收事件数的对数缩放，仅标注前5 位接收者。位置按网络布局排列。

6.2 大多数账号可以间接连起来，实际回话却主要由帖主承担

忽略线的方向后，网络分为35 个互不相连的部分，其中最大部分包含2,768 个账号，占有边账号的94.4%。网络密度为0.0473%，即全部可能的有向账号配对中，实际出现直接连接的比例很小。这两项结果合起来呈现了一种“间接联系广、直接联系稀疏”的结构：大多数账号能够通过已有连接串在一起，日常

评论则发生在有限的账号关系中。

评论角色进一步说明这个结构里发生了什么。在4,902 次明确回复中，帖主回复其他用户4,361 次，占89.0%；其他用户回复帖主444 次，占9.1%；其他用户彼此回复97 次，占2.0%。采集到的明确回话，大部分是帖主在承接留言，其他参与者相互接话的事件份额很小。而根评论按规则指向帖主，因此结合根评论与明确回复，可以确定评论区围绕帖主展开的清晰特征。

评论区的活动主要由面向帖主的留言与帖主回话构成，其他用户彼此交流则是其中较少的一部分。同一条帖子下，多人留言形成了参与的广度，帖主持续回复形成了来回承接；这两种活动共同解释了样本中评论量的主要来源。横向回复的97 次事件，则记录了帖主之外参与者直接接话的部分。

6.3 同样接收很多评论，可能是接触面广，也可能是少数人反复往来

前10 位账号接收了54.0% 的非自我评论事件，样本帖子作者接收了61.3%。评论去向集中在部分账号上；进一步对照接收次数与发送者人数，可以看清这些接收量是怎样积累起来的。

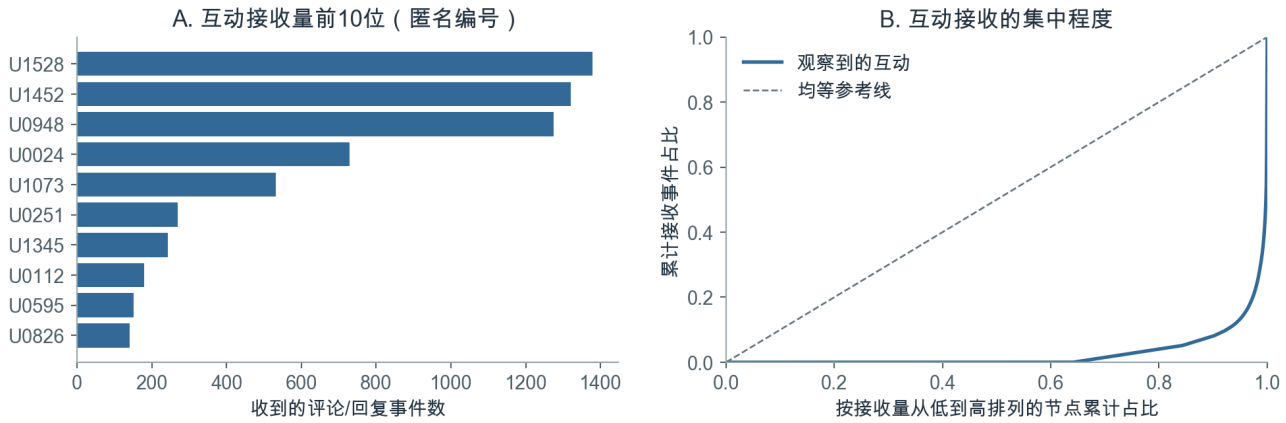


图12　接收事件前10 位与累计接收分布。按接收事件次数排序，分母为11,511 次非自我事件，同一用户的多次事件分别计数。

现有匿名节点表提供了一个很直观的比较。U1528 收到1,378 次互动，发送者有53 位；U0948 收到1,275 次，发送者却有1,091 位。前者的接收量更多包含已有发送者的重复发言，后者的发送者覆盖面更广。不属于样本帖子作者的U0112 也收到180 次互动，但只来自4 位发送者，说明较高接收量还可能出现在很有限的账号往来中。

匿名账号	是否为样本帖子作者	接收事件次数	不同发送者人数	记录中更突出的特征
U1528	是	1,378	53	相对于人数，重复发来的事件较多
U0948	是	1,275	1,091	与相近接收量相比，涉及更多不同发送者
U0112	否	180	4	接收事件集中来自很少几位发送者

接收事件数为加权入度，不同发送者数为入度；统计同时包含根评论和明确回复。

多少个不同账号向其发来评论（入度），反映接收关系的范围；累计收到多少次评论（加权入度），反映事件量。将这两个中心性指标联系起来，U0948 突出的是较广的发送者覆盖，U1528 突出的是已有发送者的多次发言。两者在网络中承担的接收形态因此有所不同。

6.4 双向连接与首周窗口的结构差别

全部互动网络的互惠率为49.6%，表示近一半有向连接同时存在反方向的连接。例如，用户给帖主留言，帖主又回话给该用户，这对账号便形成双向连接。指标按账号之间是否存在双向关系计量[8]，每条连接贡献相同权重，概括了关系层面的往来。

只保留明确回复后，互惠率为29.9%。整体网络中，用户的根评论与帖主的回复可以组成一对双向连接；限定为明确回复后，其中一部分关系保留的是帖主发出的回话。两项互惠率的差异，使“留言加回话”这一主要往来形式在结构上更加清楚。

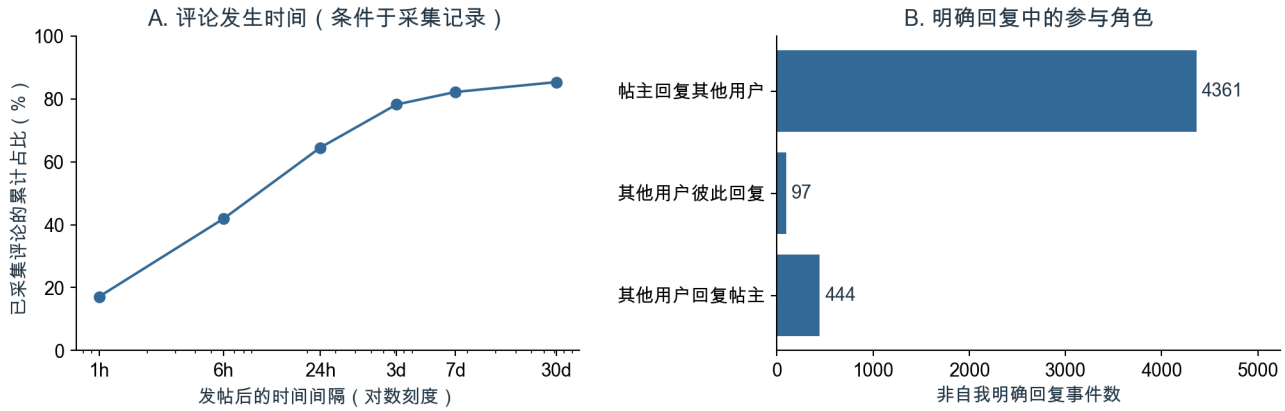


图13　已采集评论距发帖的时间分布，以及4,902 次非自我明确回复的角色分布。时序比例以全部11,595 条去重评论为分母。

已采集评论中，64.5% 发生在发帖后24 小时内，82.2% 在7 天内，距发帖时间的中位数为11.3 小时，评论集中在发帖后的较早阶段。首周网络的互惠率为74.1%，前10 位接收占比为48.3%；全部记录对应为49.6% 和54.0%。首周记录呈现更多双向连接、较分散的事件接收；纳入较晚的账号和评论后，整体关系构成随之变化。

观察窗口	非自我事件数	有边账号数	有向边数	互惠率	前10 位接收占比
全部已采集互动	11,511	2,932	4,069	49.6%	54.0%
发帖后7 天内	9,451	1,376	2,278	74.1%	48.3%

互惠按边是否双向存在计量，接收占比按事件次数计量；每个窗口分别确定接收量前10 位账号。

在线程层面，6,609 个根评论线程中，57.0% 观察到帖主参与；在这些已参与线程里，最早观测到的帖主回复距根评论的中位时间为2.05 小时。这说明样本中相当一部分留言线程有帖主接话，且在已接话的线程里，回应时间的中位数约为两小时。互惠率描述账号关系的双向性，线程参与描述留言串里的承接，第5章的直接回复比例则定位到根评论本身；三种结果分别补充了交流过程的不同层面。

上述网络图与数值沿用既有冻结结果，本轮重新核对描述范围与术语，未重估网络或全面重审评论采集过程。根评论指向帖主是构网规则的一部分；连通、互惠和中心性描述观测连接，不等于真实友谊、社区凝聚力或社会支持。

7. 讨论、结论与后续资源

7.1 三个研究问题得到怎样的回答

RQ1显示，文字可观察范围随媒体与作者变化，累计点赞呈长尾，tag有无也不同于正文可见。正文、媒体和元数据应分别保留，不能因为没有记录到正文就补成没有内容。

RQ2显示，A—D与长度的关联取决于比较口径和已记录条件。开心等词项（C）的命中组原始平均点赞较高，而若干调整模型的点估计为负；原始算术均值和对数条件系数处在不同尺度，无法将差别归因于单一控制项。三种正文口径的联合p为0.130、0.067与0.040，应共同呈现；非空正文模型内q约0.048靠近惯用阈值，且不覆盖全部模型探索，不支持稳定增赞结论。

RQ3显示，评论中的固定词项随发言角色分布不同，明确回复以帖主发给其他用户为主，事件量与不同发送者人数反映不同接收形态。网络互惠和线程参与描述不同层面的连接，均不能直接作为真实支持或关系质量的测量。

7.2 当前结果可以怎样使用

本轮可交付的是明确分母、规则和模型条件的观察性报告。使用者可以据此检查某种比较是否混入了正文缺失、媒体构成或少数账号的重复发言；不能把高赞帖常用词当作推荐文案，也不能把负向系数改写成“减少开心用词能提高点赞”。

对象	目前可采用的做法	依据与条件
研究小组	在报告中并列三种正文口径，公开全部词项及样本分母	字面关联会随观察范围改变，规则不穷尽表达
平台分析者	若获得新数据，统一发帖后7天曝光、反馈和不同参与者数	当前累计观察时长未知，次数与人数含义不同
后续研究者	有资源时使用候选手册与独立标注工具开展单独语义研究	本轮未进行人工语义复核；候选类别仅作探索
平台运营者	如评估表达或回复提示，以新设计的实验记录实际曝光和回应	当前观察性关联未识别干预收益

7.3 限制与交付边界

样本仅来自课程提供的100位作者，抽样机制和统一采集时点未知，不能代表Keep全平台。缺失正文、媒体内容未观察与评论采集缺口限制了可见范围。作者和日期固定效应不能消除随帖变化的曝光、粉丝变化、媒体内容与观察时长差别；点赞也不等于训练效果、自律程度或留存。

四条正文规则与四组评论规则是可交叉命中的字面规则，不是互斥、完备的语义分类，亦未完成本轮人工语义复核。低共线性和计算可复现均不建立语义效度。模型内BH只调整每个设定的五项检验，正文口径与其他补充分析未构成一个统一校正的检验家族。

本轮按可观察字面特征与互动关联的范围完成作业。探索性附录保留NMF、候选框架及失败的AI识别器，以说明为何没有正式报告真实主题占比或类别效应；其工具可供未来资源允许时使用。本轮不以补完人工分类作为结论或交付的前提。

附录A　字面模型与互动口径的完整证据

A.1 三种既有正文口径的五项结果

每个区间均为原始95%作者聚类区间；BH q分别在各模型内对五项校正。全样本 / 原始可见 / 清理非空三个口径分别包含9,532 / 5,548 / 5,414帖及100 / 95 / 95位作者。以下全部估计沿用冻结结果，未追认任何一个口径为事前唯一主模型。

模型	字面特征	β	聚类SE	原始95%区间	原始p	BH q
全样本	正文长度 ln(1+字数)	0.028	0.018	[−0.008, 0.064]	0.130	0.293
全样本	坚持等词项命中（A）	−0.119	0.087	[−0.293, 0.054]	0.176	0.293
全样本	大家等词项命中（B）	−0.004	0.064	[−0.131, 0.122]	0.946	0.946
全样本	开心等词项命中（C）	−0.086	0.035	[−0.155, −0.016]	0.016	0.079
全样本	问号出现（D）	0.108	0.105	[−0.100, 0.316]	0.307	0.383
原始可见	正文长度 ln(1+字数)	0.037	0.018	[0.001, 0.073]	0.043	0.106
原始可见	坚持等词项命中（A）	−0.135	0.072	[−0.278, 0.008]	0.064	0.107
原始可见	大家等词项命中（B）	0.036	0.066	[−0.096, 0.167]	0.593	0.593
原始可见	开心等词项命中（C）	−0.090	0.037	[−0.164, −0.015]	0.019	0.093
原始可见	问号出现（D）	0.097	0.099	[−0.100, 0.294]	0.332	0.415
清理非空	正文长度 ln(1+字数)	0.046	0.018	[0.011, 0.081]	0.010	0.048
清理非空	坚持等词项命中（A）	−0.137	0.072	[−0.281, 0.006]	0.060	0.101
清理非空	大家等词项命中（B）	0.028	0.064	[−0.099, 0.156]	0.659	0.659
清理非空	开心等词项命中（C）	−0.089	0.037	[−0.163, −0.015]	0.019	0.048
清理非空	问号出现（D）	0.096	0.099	[−0.101, 0.292]	0.338	0.422

A.2 原有敏感性分析的保留范围

原有可见正文、最高1%剔除、作者等权与PPML结果仍在冻结结果表中，五项变量和控制项定义未改。原“仅可见正文”为5,548帖，不能与新增5,414帖混称。

补充设定	样本量	开心等词项（C）β	原始95% 置信区间	原始p 值
仅可见正文	5,548	-0.090	[-0.164, -0.015]	0.019
去除点赞最高1%	9,436	-0.082	[-0.152, -0.012]	0.022
作者等权	9,532	-0.128	[-0.219, -0.036]	0.007
PPML 计数模型	9,532	-0.135	[-0.299, 0.028]	0.103

本表保留各设定的原始区间和p 值；主分析的多重检验结果列于A.1。

OLS 刻画对数变换后反馈的条件均值，PPML 刻画原始点赞数的条件期望，两者分别对应各自尺度上的关联。逐作者剔除中，开心等词项（C）系数100 次均为负，范围为[-0.100, -0.074]；大家等词项（B）的系数则会变号。各检验分别检查正文缺失处理、极端值、高产作者权重、模型尺度及单一作者影响，情境解释以已有文本与记录字段为基础。

A.3 评论配对、网络与时间口径

网络从100 位样本作者的帖子出发构建，根评论按归属指向帖主。节点表另保留PageRank，记录沿评论方向分配、同时考虑来源账号位置及其互动去向的结构评分[9]。

评论内容处理统一全半角和空白，移除URL 与方括号标记，再分词并过滤停用词；同一评论内同一词只计一次。四组评论字面规则按固定词表匹配，可相互重叠，分母为相应角色的全部已采集评论。文本统计保留不同评论ID 下相同的短句和84次自我互动；网络则排除自我互动，因此两者分母分别为11,595 和11,511。

直接配对要求回复由帖主发出，所属帖子一致，reply 字段指向该根评论，replyUserId 为根评论作者，parentId 也与该根评论匹配；回复发生在根评论之后或同一时刻，间隔不超过168 小时。每条根评论取该窗口内最早观测回复，实际无首时点并列。配对到的3,606 次窗口内直接回复对应3,568 条根评论；分析评论组2时，每条根评论只贡献一次观察。全部评论中有781 条明确回复引用的评论ID 未在表内出现，完整对话仍有缺口。

网络接收者优先按replyUserId 确定，缺失时只从确实已观测的被回复评论补识别；无回复指向的根评论归到帖主。既有网络核查中，接收者均可确定，事件时间均不早于发帖。全部网络及首周网络的边权为同方向事件累计次数；仅明确回复网络的既有互惠统计只使用去重后的有向连接。互惠率为具有反向边的有向边占比，每条有向边按相同权重计数。

时间口径须分别保留：评论时序和首周网络从发帖起算；直接配对的7 天从根评论起算；57.0% 的线程帖主参与比例包括线程内回复，以该线程全部已采集记录为范围。各项时间统计均以实际采集到的事件为基础。

A.4 媒体分组的完整描述数值

内容形式	帖子数	样本占比	平均点赞	点赞中位数
图片	5,790	60.7%	51.03	41
无媒体	2,493	26.2%	3.91	3
纯文字	301	3.2%	7.94	4
视频	948	9.9%	48.05	36

探索性附录B　旧NMF词共现成分与候选内容框架

本附录全部属于探索性材料，不回答主研究中的真实主题比例或类别效应。保留旧结果是为了公开测量限制；这些分析既没有被本轮升级为正式语义分类，也没有据其p值挑选新类数或阈值。

B.1 模型捕捉到反复出现的词群，覆盖边界仍然明显

原NMF最终使用2,470帖、86位作者。各成分的最高权重份额如下；为避免将模型结果误读为经过验证的五类内容，新图使用中性的成分编号与关键词。

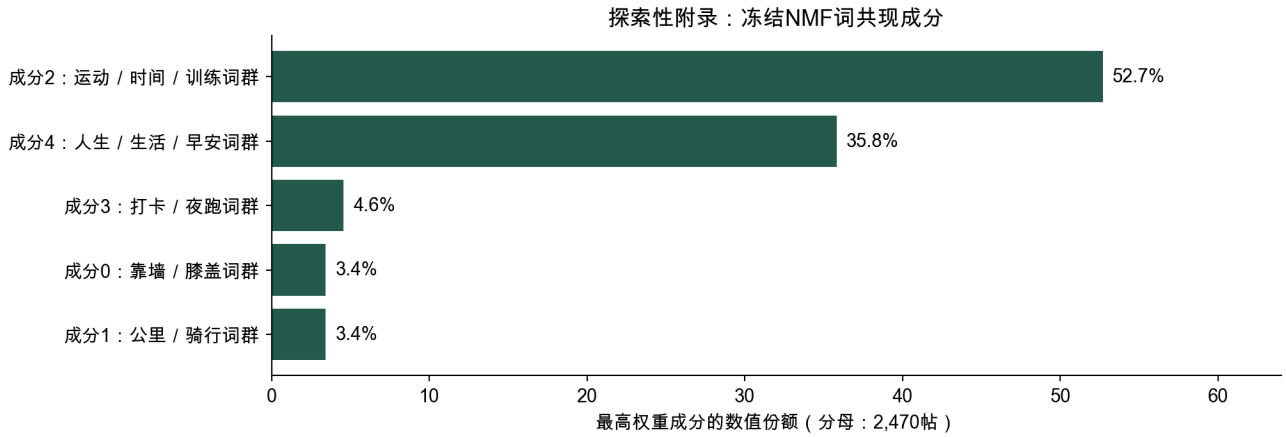


图14　原冻结模型中最高权重成分的数值份额。每帖取一个最大权重用于描述，比例不是人工语义分类的精度或覆盖率；回归使用连续权重。

原名称分别为静蹲、骑行、运动训练交流、跑步打卡、生活感悟问候。其中有具体运动项目、上位内容域，也有表达功能，层级并不一致。52.7%与35.8%只能保留为原成分2和成分4的主导份额，不能直接认定为这些比例的帖子在语义上确实属于两个真实类别。

五类覆盖完整性的疑问有依据，但不能把2,944条未入模正文直接当作五类之外的帖子。未入模部分既有被词数门槛排除的明确运动或问候短句，也有饮食、装备等遗漏领域和信息不足的记录。

B.2 语义筛查发现具体错配，不能据此估计全样本错误率

此前核查固定随机种子，对每个原主导成分抽12帖，共60帖，另抽20条未入模的非空正文；抽样不使用点赞。单轮AI辅助筛查发现，60条中40条明确支持原名称、6条只部分支持、12条不支持被分配的名称、2条信息不足。

例如，山河保护人的感悟、囤口罩提醒被分到静蹲；餐食配菜和食品品牌推荐被分到运动训练交流；绘画进展、出行和学期结束感受被分到跑步打卡。高归一化权重不能排除这种错配，因为它只给出几个成分之间的相对份额，不是类别正确的概率。[11]

各成分等额抽取使小成分被有意放大，不能用60条的未经加权比例推断全样本错误率。“不支持分配到的名称”也不等于不属于其余四类。本轮未进行人工语义复核，不能声称已证明多数帖子都在五类之外。

B.3 事后给作者等权，不能消除拟合阶段的模板影响

原静蹲成分的85条主导文档中，78条来自一位作者；骑行成分的85条中，58条来自一位作者。沿用旧成分标签再计算作者平均份额，静蹲由3.4%降至0.6%，骑行由3.4%变为2.9%。这些数值说明产量与作者平均构成不同，但没有重新估计词群，因而不能证明分类已摆脱作者习惯。

2,478条拟合正文里有2,374种不同清理文本，104条为完全重复行。保持同一TF-IDF词表及IDF，删除完

全重复正文后，原来独立的静蹲成分不再单列，相关词进入更宽的打卡成分；另出现包含三明治、咖啡、鸡蛋、早餐等词的成分。将拟合目标调整为作者等权时，词群结构也变化。作者等权诊断仍保留原始IDF，不是完整解决作者偏重的新文本管线。

K=3、4、6、7、8的对照与上述结果一起保留，未根据点赞、显著性或单纯拟合误差挑选新K。旧三次随机种子产生相近关键词，只证明同一设定容易复现；它不能代替语义、删重或作者构成稳健性。新出现的词群同样尚未完成语义验证。

B.4 连续权重可共存；二元多标记是另一种编码

原模型每帖有五项连续权重，合计为1，可以同时为正。带截距时省去成分2，是避免五项权重和为1带来的完全共线；省略不意味着语义互斥。回归系数表示其他权重和控制不变时，某一权重替代成分2权重的条件差异。

权重≥0.20的补充二元编码中，1,088帖有至少两个标记，成分2与成分4同时出现894帖。各标记比例合计145.9%，不能画成互斥饼图。五个标记同时进入回归时，设计矩阵171 / 171满秩，不能因存在五个变量就机械删除其中一个。

权重阈值	至少两个标记的帖数	五标记联合p	最小BH q
0.15	1,331	0.289	0.205
0.20	1,088	0.286	0.296
0.25	835	0.517	0.479

0.20取自1 / 5，只是便捷诊断；0.15与0.25用于观察阈值敏感性，并非语义金标准。三个阈值下都没有观测到“五项全零”组，二元系数不是相对于真实无主题组的差异。每个模型内五项BH也不覆盖整个阈值探索家族。给旧成分增加多标记没有修好其名称和覆盖问题，不能据此宣布已经获得新的真实主题回归。

B.5 成分回归仍是探索性关联，作者支持应在子样本内核算

原连续成分模型的联合p=0.166，四项BH校正后均未达到5%。成分4的原始p=0.035、BH q=0.107，不能据此给真实内容类型作稳定反馈排序。区间以冻结成分为给定输入，未纳入NMF估计与阈值选择的不确定性。

主题子样本有10位单帖作者，作者发帖数中位数为14；40位不超过10帖，合计181帖。不能用全样本只有2位单帖作者来替这个子模型保证支持充分。

主题子样本内最低发帖数	保留帖数 / 作者数	原连续成分联合p
1	2,470 / 86	0.166
2	2,460 / 76	0.166
5	2,423 / 64	0.179
10	2,309 / 48	0.266

剔除少帖作者没有带来明确整组证据，但保留至少10条主题入模帖时只剩48位作者。它检查的是估计支持，并不修复成分的语义效度。也没有开展“开心等词项（C）×主题”的交互或分层检验，因此不能把开心等词项（C）的关联反转归因于生活问候帖。

B.6 早期候选建议：未采用为最终分类

下表是较早修订阶段提出、未采用为最终分类的候选建议；它的层级与边界不是后续冻结规则。后续400条文本重建见探索性附录C及冻结码本，其中单独问候不自动赋内容领域。早期候选一级内容域只回答“谈

什么”，运动项目放到子层；“怎么表达”另列记录、经验建议、求助、问候或推荐等目的。帖文允许多标记，并分别保留其他可辨识内容、信息不足和无可用正文。

候选内容域	拟覆盖的内容
运动与训练	训练、课程、运动过程、成绩与方法
饮食与营养	餐食、食谱、营养补充、食物推荐
身体状态、健康与恢复	疼痛、疾病、疲劳、康复和体重状态
日常生活与兴趣	工作学习、家庭、旅行、绘画、节日、生活感悟与问候
装备与产品体验	手环、鞋服、运动器材等体验或推荐
平台功能与社区活动	加入圈子、平台挑战、功能或服务体验
其他可辨识主题	正文语义可判断但目前类别无法表达的内容

这份框架尚未用于生成全样本新标签，也不是新增一组已验证回归结果。若未来开展独立语义研究，可由独立标注者使用覆盖作者、媒体、已入模和未入模帖的样本，讨论分歧、冻结边界并作留出核查；本轮没有开展人工语义复核，也不把该工作列为本次作业必须完成的步骤。没有足够正文时保持未知，不仅凭原始tag补出主题；类数与边界也不由点赞或p值决定。

B.7 原连续成分回归及二元多标记口径

原TF-IDF词表含1,046项，NMF拟合2,478帖，8帖近零贡献被排除，最终2,470帖。连续权重在每帖合计为1，省略成分2作参照。下表名称仅用于对照历史结果，不表示类别已验证。

冻结成分	主导帖数	连续权重β	原始95%区间	原始p	BH q
成分0（旧称靠墙静蹲记录）	85	−0.315	[−0.636, 0.005]	0.054	0.107
成分1（旧称骑行里程记录）	85	0.018	[−0.523, 0.558]	0.948	0.948
成分2（旧称运动与训练交流）	1302	参照	不适用	不适用	不适用
成分3（旧称跑步与训练打卡）	113	−0.471	[−1.048, 0.105]	0.108	0.144
成分4（旧称生活感悟与问候）	885	−0.144	[−0.278, −0.010]	0.035	0.107

连续系数按1单位权重变化计；解释10个百分点替代时需乘0.1。二元标记则定义为权重达到阈值，表示固定其余四个标记和控制后的条件差异；五项同时进入、没有单一参照类。三个阈值下均未观察到五标记全零组。所有区间未纳入主题估计、语义归类与阈值选择的不确定性。

探索性附录C　400条文本的AI重建与识别器失败

C.1 重建流程和证据地位

此前的AI重建从400条正文出发，分为160条开发、80条校准及160条留出。候选框架分别归纳“谈什么”与“怎么表达”，形成17个内容叶和15个表达行为候选项，并在冻结手册中另设上层领域。原型训练只使用开发与校准的正文及AI编码，不使用点赞、评论、作者或旧分类来选择类别与阈值。该过程得到可复查的候选手册，未得到独立的人类语义真值。

留出160条由同一模型基座、分离上下文的两个AI代理编码；一致性只衡量两份AI记录之间的对应，不能称为人类一致性、准确率或构念效度。两名成员本轮未开展人工语义复核，人审表为空；候选手册与工具仅保留为后续资源。

C.2 冻结后审计暴露了过度检出

留出诊断	冻结聚合结果	本轮判断
两份AI均判断领域未指明	24条中22条通过原型门控，18条仍被赋至少一个领域	门控不能可靠保留未指明状态
体验自述候选项	原型检出150 / 160条；AI A、B分别标41和37条	明显的边际扩张，不能以150条作为真实占比
候选类训练支持	21个语义槽中14个达到开发5阳性 / 5阴性原型门槛，7个未支持	可拟合门槛不等于可靠检测
人工语义复核	完成编码者0人，未计算人类验证指标	AI记录不合成为真值

这些诊断不是以某一AI代理为标准答案宣布错误率，而是说明冻结原型与候选规则的适用范围和输出边际存在冲突。因而没有用全体预测量改写正式主题占比，也没有新跑类别—点赞回归。原冻结codebook、recognizer和识别器实现均保留，不为本轮报告修补或调参。

完整聚合见results/classification_rebuild_scope_audit.json、classification_ai_agreement.json、classification_rebuild_training.json及classification_rebuild_recognition.json；候选手册与原始流程见《分类测量重建_实证依据与验证报告》及本地冻结记录。附录仅引用聚合，不导出原始帖ID或私有编码文本。

附录D　复现位置与成员分工

D.1 证据位置与本轮文件保护

内容	冻结证据
正文词项、命中与原始均值	code/text_dictionary.json；results/text_features_summary.csv
三种正文口径	results/teacher_complete_body_model.json
数值共线性、作者内变化	results/teacher_feedback_dictionary.json及VIF表
少帖作者、tag身份和拼接	results/teacher_author_tags_summary.json
评论词项与角色	code/comment_text_config.json；results/comment_text_features.csv
直接回复配对	results/supplemental_direct_reply_language.csv及supplemental_summary.json
网络与时间窗口	results/extension_summary.json、network_nodes.csv与相关表
探索性成分和结构审计	results/teacher_topic_summary.json、teacher_label_coverage_summary.json及teacher_topic_structure_summary.json
AI重建、冻结与候选手册	results/classification_*.json；validation/classification_rebuild/freeze_record.json
本版范围与生成	code/observable_feature_scope.json；code/build_observable_feature_report.py

本版生成器只读冻结证据，不重算统计。旧报告、结果、原图与冻结分类材料按SHA-256核对；图中含构念名称的旧图从结果表重画为observable_新图，原图保留。新报告、PDF页图与验证元数据位于validation/observable_feature_report对应记录。计算和文件核查只验证引用与交付一致性，不验证语义。

D.2 成员分工

陈霖负责问题提出、数据清洗与RQ1；董依心负责RQ2与RQ3。上述为既有实际分工。本轮均未进行人工语义复核，未将AI编码计为成员已完成人审。

参考文献

[1] Richardson CR, Buis LR, Janney AW, et al. An Online Community Improves Adherence in an Internet-Mediated Walking Program. Part 1: Results of a Randomized Controlled Trial[J]. Journal of Medical Internet Research, 2010, 12(4): e71. doi:10.2196/jmir.1338.

[2] Tausczik YR, Pennebaker JW. The Psychological Meaning of Words: LIWC and Computerized Text Analysis Methods[J]. Journal of Language and Social Psychology, 2010, 29(1): 24–54.

[3] Lee DD, Seung HS. Learning the Parts of Objects by Non-negative Matrix Factorization[J]. Nature,1999, 401(6755): 788–791.

[4] Salton G, Buckley C. Term-weighting Approaches in Automatic Text Retrieval[J]. Information Processing & Management, 1988, 24(5): 513–523.

[5] Cameron AC, Miller DL. A Practitioner’s Guide to Cluster-Robust Inference[J]. Journal of Human Resources, 2015, 50(2): 317–372.

[6] Benjamini Y, Hochberg Y. Controlling the False Discovery Rate: A Practical and Powerful Approach to Multiple Testing[J]. Journal of the Royal Statistical Society: Series B, 1995, 57(1): 289–300.

[7] Santos Silva JMC, Tenreyro S. The Log of Gravity[J]. The Review of Economics and Statistics, 2006,88(4): 641–658.

[8] Wasserman S, Faust K. Social Network Analysis: Methods and Applications[M]. Cambridge: Cambridge University Press, 1994.

[9] Brin S, Page L. The Anatomy of a Large-Scale Hypertextual Web Search Engine[J]. Computer Networks and ISDN Systems, 1998, 30(1–7): 107–117.

[10] statsmodels. Variance inflation factor. 官方方法说明：VIF文档。

[11] scikit-learn. NMF. 官方实现说明：NMF文档。本项目的贡献归一化、样本筛选和语义诊断另见代码与冻结结果；实现文档本身不能验证数据的类别名称。