Keep正文分类测量重建：实证依据与验证结果

2026年10月29日 | 冻结版 **v1** | **AI**开发与预验证，人工验证待完成

此前最根本的问题是，研究把“词被命中”“模型中的词共现成分”与“真实内容或心理构念”混在了一起。补充低VIF、更多控制项或新的主题名字，都不能补上这条测量证据链。因此本轮重新做了语料取样、开放归纳、试编码、边界修订和留出检验；旧四规则与五个NMF成分保留为历史字面结果，不作为新类别设计的约束。

新结果支持建立一套可审查的候选编码手册，同时也发现：当前自动识别器不能可靠地把这套手册推广到全体正文。下文保留失败结果，不用全样本预测量冒充真实内容比例，也不据此重跑正式主题—点赞回归。

1. 原先的分类为什么不够成立

原四变量实际是三组词项和一个问号规则，层次并不一致。“打卡”可以记录行为、发布口号或仅指某种完成；“大家”可以称呼读者，却不证明发生互助；积极词不等于真实情绪；问号可能是反问、标题设问或自问自答。这些规则可以作为字面线索，尚不足以分别测量自律人格、社会支持、积极心理状态和真实求助。

五个NMF成分回答的是哪些词倾向共同出现。原分析固定K=5，依据少量高权重文档命名，近零权重排除后只覆盖2,470帖；删重和作者构成又会改变成分。连续权重本来可以并存，不能再解释成五个互斥、完备的真实内容类型。非空正文中71.9%未命中四规则，也不能直接称71.9%被错误分类，因为那四条规则从未构成穷尽式分类器。

本轮因此撤回“类别天然成立”的默认前提。低共线性只说明变量在样本中没有严重线性重合；它不说明名称准确，也不说明覆盖充分。作者固定效应和tag控制处理的是比较条件，不能替代正文语义验证。

2. 先固定观察对象，再重新抽样

只对清理后的正文作语义编码。原始tag、图片和视频不参与补全文意；需要研究这些信息时，应另建信息通道。9,532帖中5,414帖清理后非空，4,118帖没有可供本轮解释的正文；这不等于其原帖没有内容。

作者在不查看点赞等互动结果的情况下分为60 / 20 / 20人三个角色。开发样本刻意兼顾作者与长度，帮助发现类别；校准和留出在各自角色内随机抽取，并排除早先角色及历史已检查正文中的完全相同模板。该设计防止同一作者或相同文本直接跨阶段，但不能消除相似模板、共同平台语言及同基座AI的共享偏误。

阶段	作者角色池 / 帖子	实际审读正文 / 作者	用途
开发	60人 / 6,446帖	160条 / 55人	开放归纳、形成定义
校准	20人 / 1,591帖	80条 / 14人	严格试编码、补遗漏、固定边界
留出	20人 / 1,495帖	160条 / 19人	冻结后两份AI盲标、原型对照
空正文控制	另抽12条	12条 / 10人	检验不把缺正文当所有语义阴性

开发、校准与留出模板及作者角色均不重合，12条空正文控制均保持空正文状态。留出抽样框是881条符合条件的不同正文，实际抽到19位作者；不是“全Keep的代表样本”。新编码共涉及400条不同的非空正文，留出160条各编码两次。

编码输入只有匿名样本编号和正文；点赞、评论数、旧词典、旧NMF、作者身份、原始tag均不进入编码包。开发和校准仍是看过原研究后进行的探索性修复，不能改称事前注册研究。

3. 分类依据变成“概念区分 + 本地语料 + 反例”

本轮把两个问题分开：内容对象回答“谈论什么”，表达行为回答“这段文字在做什么”。一条“今晚跑了五公里，明天继续”的合成例句，同时包含运动对象、事件呈报和未来计划；没有必要只归一类。这是本项目的工作设计，并非某篇论文已经替Keep验证的标准分类。

运动社区研究可以为归纳、试编码和双人复核提供流程依据，例如Kalinowski等先阅读形成主题，再用试编码修订，并双人编码剩余材料；其八类及美国黑人女性社区比例不能直接移植。Kalinowski等，2023

主帖表达和回复支持也应分开：Wang等分别测量披露、提问、支持需要与支持提供；Stragier等的健身支持分类针对活动后的回复。本文据此要求行为证据，避免把称呼或感谢直接当作已发生互助，而不借用其社区效应。Wang等，2015，Stragier等，2018

词汇连贯与标签适配不是同一件事，Ying等提供了对原文和候选标签另行验证的思路；LIWC的方法文献也不能为未经独立评审的自编中文词表背书。这些文献支持验证任务，不证明当前Keep候选类别已经有效。Ying等，2022，Tausczik与Pennebaker，2010

3.1 内容对象：17个细分记录，按研究任务聚合展示

开发阅读形成15个内容细分，校准新增消费交易和居住装修，共17叶；为了展示而聚合成5个父组，并保留“其他明确内容”槽。父组的数量与合并方式是研究者的选择，不是统计模型证明的唯一自然分区。身体状态与体重外形、生活中的文化与关系仍保留叶级区别，不能因在同一父组就解释为同一心理构念。

父组	保留的细分	开发 / 校准阳性帖	开发阳性作者
运动与身体活动	运动与身体活动	61 / 16	30
身体状态、体重与外形	体重、减脂与身体形态管理、身体感受、健康与休息	32 / 11	20
饮食、食物与营养	饮食、食物与营养	11 / 19	9
生活、关系与社会文化话题	人生观、处世与自我调适、人际关系与陪伴、家庭与子女照料、工作、学习与职业、阅读、知识、艺术与媒体、天气、季节与自然环境、出行、地方与游览、个人装饰与穿着、节日与新年度祝愿、宗教场所与宗教活动、消费、交易与商业处境、居家环境与装修	63 / 37	34
工具、服务与记录奖励机制	课程工具、记录与奖励机制	2 / 2	2
其他明确内容	开放残余，须明确新对象	0 / 0	0

这些计数证明对应对象在所读材料中确实出现，不能证明该聚合最优或推算全体比例。允许运动、身体、饮食与生活并存；“生活”要求具体生活、关系或社会文化对象，既不是“所有非运动”，也不吸收“早安”“加油”等无具体对象片段。本轮留出检验只评估父组，**17**叶没有逐叶完成留出验证。

3.2 表达行为：区分可观察话语，不推断人格

开发形成12个表达行为，校准发现明确感谢、商品供给和其他可辨识表达行为遗漏，增至15个。它们是候选行为码，不是要求每条都命中的15类人格。尤其将“记录行动”“未来意愿”“动员口号”分开，不合称自律；将体验自述、对象评价、感谢分开，不合称积极情绪。

表达行为	开发**160**阳性	校准**80**阳性
行动、进度与日常事件呈报	67	42
身体感受与主观体验自述	35	15
计划、目标与期待	14	7
可泛化信息与机制解释	12	4
方法与可执行建议	12	1
概括性议论、格言与价值主张	31	14

行动号召与自我提醒	20	5
寒暄与祝愿	13	6
明确联络或共同参与邀请	2	0
明确面向他人的回应征询	2	1
明确对象评价、褒贬与致敬	17	16
指称式题注与景象描写	10	9
明确感谢表达	0	2
商品服务供给与交易告知	0	1
其他可辨识表达行为	0	4

表达行为可以并存，但每个阳性都必须有正文逐字证据。礼貌称呼不能自动判为联络邀请；问号不能自动判为征询；一组动作数字不能自动判为指导。梦境、假设、转引可以含明确话题，却不能据此声称现实中的运动、疾病、关系或心理状态发生。

3.3 未知、缺失和其他分别保留

空正文是没有可用文字；信息不足是片段难以解读；领域未指明是能理解表达，却没有明确对象；领域不确定是可能指向某对象但证据不够；其他明确内容是确有对象而现有父组容不下。这些状态不都写成0，也不统一扔进“生活”。多标签中的0仅表示当前证据和口径下未编码该行为；原型的0则只表示未检出信号。

4. 校准实际改了什么

80条校准正文先按开发手册严格编码，随后保留原始版本并逐项修订。修改发生在留出包打开之前，留出出现的新缺口只记录，不再就地扩充v1。

发现的问题	样本编号（匿名）	落实的修改
开发内容遗漏消费交易和装修	D003、D128、C001、C006、C007、C071、C078	增加commerce/home_housing叶并明确归d_life的展示聚合；原开发与严格draft校准不覆盖，另保存v1编码。
感谢、供给交易和虚构段子不被12功能覆盖	C007、C037、C075、C006、C030、C044、C080	新增3个明确行为/开放残余；开发回查阳性仍0，标低支持、不承诺可自动识别。
谐音愿望和梦中体验易误推实际状态	C006、C030、C044、C080	撤C006未来意愿、C030身体体验；添加具体其他行为并清理已解决的不确定项。
领域/行为与真实事实必须分开	C030、C044、C048、C078、C080	内容对象允许虚构/否定；不据此推断实际行动、疾病、人格、关系或支持。

三个新表达行为在回查160条开发正文时仍无明确阳性，因此保留为稀有候选，未为了训练而凑阳性。新增内容叶归到生活展示组也有条件：必须明确购物、交易、商业处境或住房装修本身，不能遇到品牌、家中训练、购买力比喻就一律加码。

完整纳入、排除、近邻边界及合成例句见《分类编码手册_v1》。定义、识别程序、模型和开发 / 校准输入均在2026-10-29 13:54:26 UTC记录SHA-256，随后才释放留出包。哈希能审计本地文件是否改动，不能把本次回顾性探索转成外部注册。

5. 冻结后检验：一致性与覆盖一起报告

两份留出编码来自相互隔离上下文的同基座AI，编码员只见冻结手册和正文。它们没有互看结果，但共享模型训练与概念偏误；以下是**AI**预验证的一致性，不能称人工信度、准确率或构念效度。正类一致率为2×双方阳性 / 双方阳性总数，避免只看大量共同阴性带来的高总一致率。

编码	观察状态	领域状态
AI A	readable 153；insufficient 7	specified 122；unavailable 7；unspecified 24；uncertain 7
AI B	readable 153；insufficient 7	specified 122；unavailable 5；uncertain 8；unspecified 25

内容父组	A / B全部阳性	可比较n	正类一致率	κ
运动与身体活动	42 / 42	121	100.0%	1.000
身体状态、体重与外形	35 / 37	121	94.4%	0.921
饮食、食物与营养	31 / 31	121	100.0%	1.000
生活、关系与社会文化话题	64 / 64	121	97.6%	0.950
工具、服务与记录奖励机制	5 / 6	121	100.0%	1.000
其他明确内容	4 / 4	121	100.0%	1.000

表达行为	A / B全部阳性	可比较n	正类一致率	κ
行动、进度与日常事件呈报	63 / 73	150	89.6%	0.812
身体感受与主观体验自述	41 / 37	152	94.9%	0.931
计划、目标与期待	18 / 16	149	94.1%	0.934
可泛化信息与机制解释	4 / 4	152	100.0%	1.000
方法与可执行建议	1 / 1	152	100.0%	1.000
概括性议论、格言与价值主张	26 / 26	151	100.0%	1.000
行动号召与自我提醒	20 / 22	152	85.7%	0.834
寒暄与祝愿	17 / 18	152	97.1%	0.968
明确联络或共同参与邀请	1 / 0	152	0.0%	0.000
明确面向他人的回应征询	0 / 0	151	—	—
明确对象评价、褒贬与致敬	36 / 37	151	95.9%	0.946
指称式题注与景象描写	28 / 18	152	73.9%	0.695
明确感谢表达	1 / 2	152	66.7%	0.664
商品服务供给与交易告知	0 / 0	152	—	—
其他可辨识表达行为	0 / 1	152	0.0%	0.000

留出160条中，A / B分别有39 / 40条被赋多个内容域、71 / 73条被赋多个表达行为。当前多标签设计有实际共现证据；把它们强制互斥会丢掉同帖信息。两份编码又各有4条明确对象落入其他槽，动物和器物内容提示v1仍有覆盖缺口；这不是旧五成分的总体遗漏率。

领域比较只纳入双方均可读、均明确领域的正文，逐标签再排除不确定项；因此可比较n不能与160混用。函数比较允许领域未指明。完全没有正类时正类一致率可能无法定义；κ在期望一致率为1时留空，不能补为0或1。阳性少于5的类别证据稀薄，不能凭高总一致率宣布通过。

两份编码在42条记录的状态、标签或不确定项上存在差别，分歧原文和双方证据已保存为本地人工复核包；没有在计算前由AI强行裁决成一个“金标准”。本节的每类2×2计数、总一致率、排除原因和低支持标记均保留在汇总JSON / CSV。

6. 自动识别原型暴露了什么

为检验规则能否扩展，而非直接发放全样本新标签，本轮仅以160条AI开发编码训练字符2—4元TF-IDF + 逐标签逻辑回归，用80条校准选择预定候选阈值；词表只在开发集拟合，所有输入只用正文。该方案只是小样本基

线，不能代表所有自动分类方法。

21个语义槽中只有14个达到开发至少5阳性、5阴性的训练门槛；另7个不输出自动0 / 1：工具、服务与记录奖励机制、其他明确内容、明确联络或共同参与邀请、明确面向他人的回应征询、明确感谢表达、商品服务供给与交易告知、其他可辨识表达行为。5 / 5是原型可拟合门槛，不是可靠性证明；校准阳性不足3的已训练类仍标记阈值未校准。

表达行为	模型判阳性 / **160**	**AI A / B**阳性	相对**A**：精确率 / 召回率	相对**B**：精确率 / 召回率
行动、进度与日常事件呈报	159	63 / 73	42.0% / 100.0%	47.4% / 98.6%
身体感受与主观体验自述	150	41 / 37	28.7% / 100.0%	25.9% / 100.0%
明确对象评价、褒贬与致敬	132	36 / 37	26.6% / 91.7%	27.0% / 91.9%
可泛化信息与机制解释	0	4 / 4	— / 0.0%	— / 0.0%
方法与可执行建议	0	1 / 1	— / 0.0%	— / 0.0%

上表的精确率和召回率仅以各份AI编码为参照，预测NA和语义不确定项按规则排除，是有输出条件下的指标，既非准确率，也非人类金标准性能。完整逐类TP / FP / FN / TN、F1、分母及Wilson区间见`results/classification_rule_vs_ai.csv`；逐类参照阳性中的NA数与把NA计作未检出的比例，另保存在覆盖审计中，不与条件召回率混用。区间按帖子二项模型计算，未处理同作者聚集、共享AI系统误差或类别设计不确定性。

6.1 不用过滤后的指标掩盖“无明确领域”

AI参照 / 领域状态	正文数	原型适用门控通过	至少赋一个领域
AI_A / specified	122	121	108
AI_A / unspecified	24	22	18
AI_A / uncertain	7	7	7
AI_A / unavailable	7	7	7
AI_B / specified	122	121	108
AI_B / unspecified	25	23	19
AI_B / uncertain	8	8	8
AI_B / unavailable	5	5	5

双方都判断领域未指明的24条中，原型仍给18条赋了至少一个领域。这个分歧不会进入“双方均有明确领域”的逐类条件比较，因此必须另列。留出正文中另有28条与开发词表没有任何字符n元重合，仍有28条被赋领域；这时判定来自截距和阈值，不是成功理解了新正文。

当前原型同时出现过度检出、漏检与未指明领域误赋。不能仅因为它覆盖了多数正文，就把输出当作比旧五成分更好的真实分类。这次失败把正式应用的阻断点具体化了：需要足量且经人工核查的阳性 / 反例、适用范围识别和真正独立的语义验证，而不是继续调整阈值直到留出结果好看。

6.2 全语料运行只核查处理范围

9,532帖里，原型机械区分4,118条空正文、144条仅符号或数字正文、5,270条含文字正文。只有4,985条通过其领域门控；这只是程序状态，不是内容真实可识别率。全量`rebuilt_content_features.csv`保留分数、状态和NA，明确标为初筛，不进入正式回归，也不据其检出次数绘制“Keep主题占比”。

7. 正式研究应该采用哪些修订

四个旧词典变量继续可以报告为具体字面特征，但删除从词命中直接跳到自律、心理情绪、社会支持或真实求助的表述。旧五NMF成分继续可以报告为探索性词共现结构，不能作为已验证的全体真实分类。

新手册用于人工编码和后续测量验证。当前有语料与反例依据的，是“这些对象和行为在本地正文中出现、应加区分”；尚未证明的是“父组最优、类别齐全、普通人可稳定编码、原型能可靠推广、类别能解释点赞”。每一层结论都应单独取证。

多标签不要求互斥或合计100%，内容域和表达行为也不合并竞争。以后做回归时，独立0 / 1标签不因共同出现就必然完全共线；仍需在实际估计样本检查频数、作者内变化、秩和相关性。若重新使用归一化总和为1的主题权重，则仍须处理参照成分。验证未完成前不为新标签给出正式互动效应。

作者少帖和tag问题沿用前轮复核：全样本与主题子样本的作者支持须分别检查；tag保留为用户自选元数据，不能充当正文人工真值。它们可以用于日后冻结方案的情境控制或另一信息通道，不能挽救语义定义不成立的类别。

8. 已交付的人工验证工具与尚缺证据

已生成A / B两份各160条的盲审表，不含模型输出、旧类别、作者或互动结果；配有完整编码手册、冻结指纹、填写说明和校验程序。两人应先分别完成，再检查分歧并由未参与初始编码者裁决；若据此修改语义定义，须升级v2并另取新留出，不能回写本轮v1的检验结果。

人工应优先核对生活父组是否过宽、事件 / 体验 / 评价边界、短句领域未指明、其他槽与稀有类。对缺乏阳性的类另补有明确取样规则的针对性材料，可用于边界研究；该补样比例不能混入总体占比。17叶若要用于实质结论，还需逐叶验证。

当前人审状态为 **pending**：两份表均未填，程序未计算任何人类一致性或人类准确率。我们不能替研究者完成真实人类判断，现阶段最可靠的交付是可审查的重建记录、冻结手册、保留失败的预检验与可直接开始的人审材料。

9. 文件与复核入口

文件	用途
分类编码手册_v1.md / PDF	逐类定义、纳入排除、近邻和合成例句
code/classification_codebook_v1.json	冻结机器可读定义与开发、校准证据
results/classification_codebook_calibration.json	校准修订轨迹与计数
validation/classification_rebuild/freeze_record.json	定义、程序、模型及输入哈希
results/classification_ai_agreement.json / CSV	每类AI一致性、2×2计数、分母与排除
results/classification_rule_vs_ai.csv	原型相对两份AI的完整条件指标
results/classification_rebuild_scope_audit.json	未指明领域、覆盖、词表零重合和划分复核
validation/classification_rebuild/private/human_review_A.csv、B.csv	本地全文盲审表，公开仓库忽略
validation/classification_rebuild/private/holdout_disagreements_for_later_human_review.json	未裁决的AI分歧证据，本地保留

在本地原始数据与已保存语义标注齐全时，运行`make classification-evaluate PYTHON=/path/to/python`重算评估，再运行`make classification-report`导出本报告与手册。语义标注本身不是可由正则重建的真值；公开代码和聚合结果不能代替缺失的人审。准备、拟合脚本在冻结后拒绝覆盖本版，后续重建须用新版本目录。