什么样的健身分享更容易获得点赞?

Keep 社区帖子文本、点赞表现与评论互动网络分析

第【待填写】组 · 【待填写：成员姓名及学号】

100位作者 · 9,532条帖子 · 11,595条去重评论

研究问题：表达方式与点赞有关吗?

RQ1：帖子、表达方式与点赞如何分布?

RQ2：同一作者的文本特征与点赞是否相关?

RQ3：评论连接了谁，互动是否集中?

RQ4：文本能否改善样本外点赞预测?

研究意义与计划

在线社区可能有助于留存，社区互动与运动成效需要区分。[1]

计划：清洗 → 文本编码 → 固定效应回归 → 稳健性 → 网络 → 建议

以上分析均已完成；后续实验仅为研究方案。

[1] Richardson et al., Journal of Medical Internet Research, 2010;12(4):e71. doi:10.2196/jmir.1338

数据核查决定能回答什么

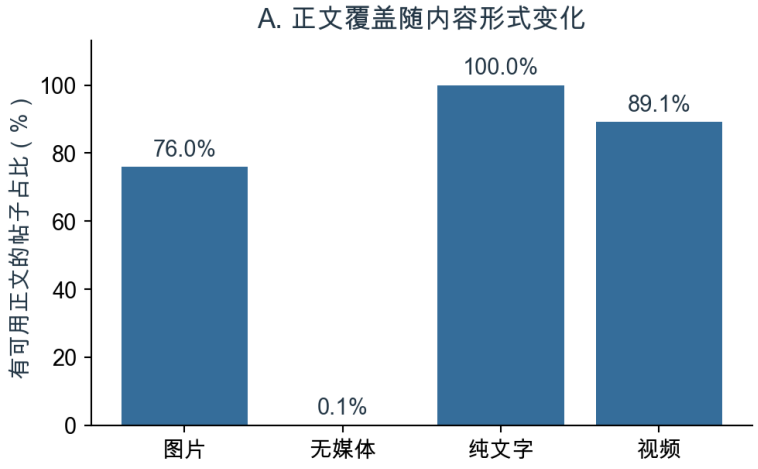
评论13,511行 → 按cmtId去重后11,595条；1,916行完全重复。

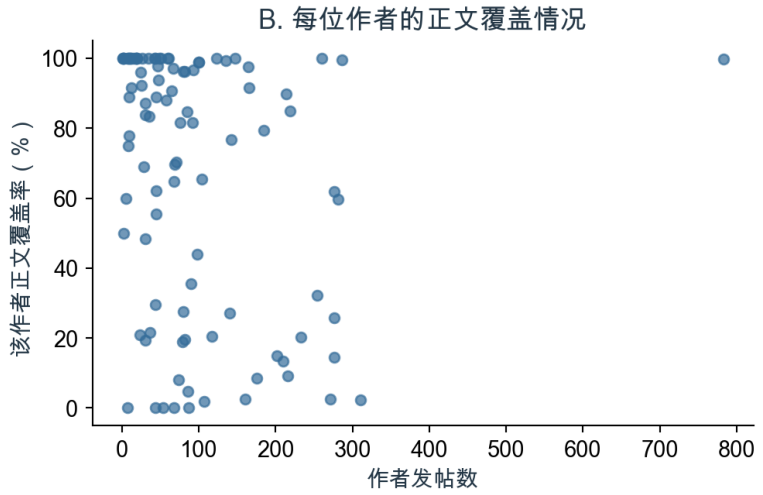
正文缺失41.8%；仅1,323帖采集到评论，其余不记为零评论。

86.9%帖子点赞高于浏览数：不用该浏览字段计算点赞率。

北京时间逐日建模；末尾跨至2021-01-01。

正文覆盖取决于帖子形式与作者



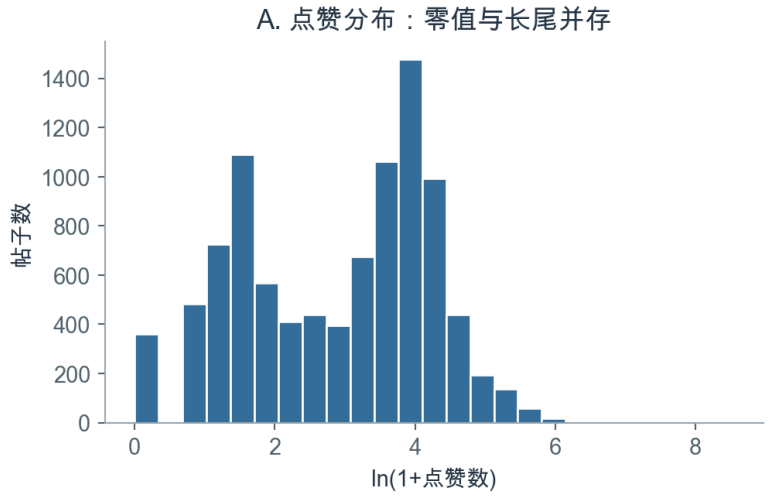


无媒体帖正文覆盖率0.1%，图片76.0%，视频89.1%，纯文字100%。

5位作者无可用正文；26位作者全部帖子有正文。

保留缺失指示和形式控制；主题分析只使用信息较充分的正文。

点赞分布存在长尾





均值37.05，中位数25，最大5,126；零点赞占3.8%。

用ln(1+点赞数)；按作者聚类；另检查计数模型。

首末本地日期不完整，不解释末尾下降为活跃度骤降。

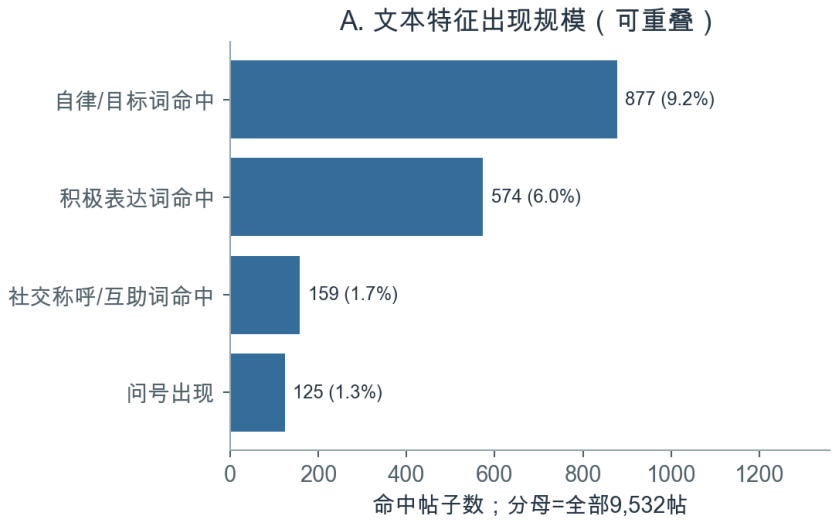
如何把正文变成回归变量

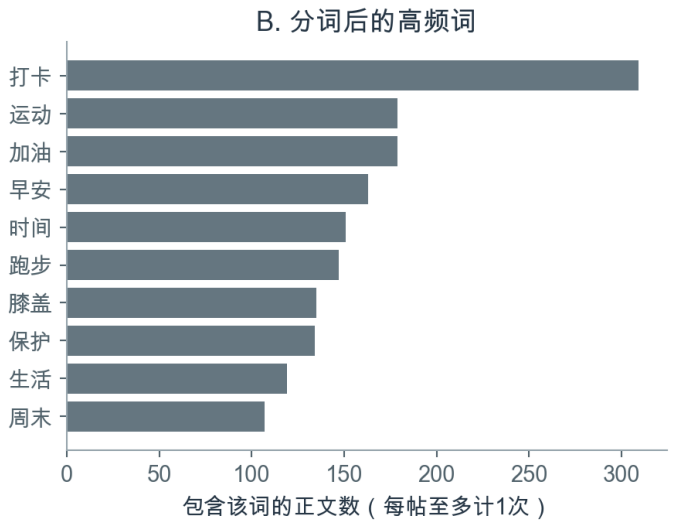
核心变量：长度、自律/目标词、社交称呼/互助词、积极表达词、问号。

清理URL、课程后缀、表情标记；话题标签单独编码。

词典命中可重叠；只表示字面表达，不是心理或情感量表。

文本规模：注意分母和低频特征



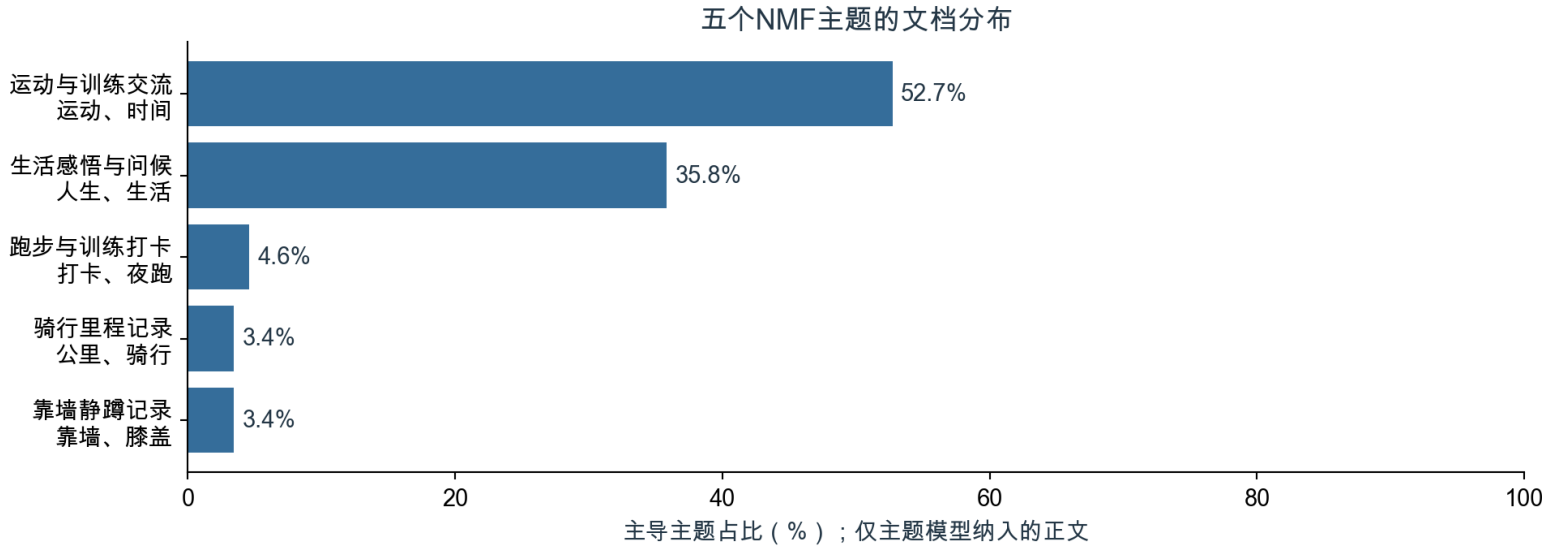


自律/目标词877帖：全部帖9.2%；可见正文15.8%。

社交词159帖；问号125帖，提供作者内变化的人数较少。

高频词是逐帖去重后的文档频数，不能当作效果证据。

NMF补充识别内容表达模式



2,470帖、86位作者，1,046词项；主题数固定为5。

运动与训练交流52.7%，生活感悟与问候35.8%。

静蹲、骑行主题集中于少数作者，反映重复记录习惯。

主题回归仍未提供明确的增量证据

以“运动与训练交流”为基准，加入4个主题权重。

联合检验p=0.166；4项BH校正后均未达到5%显著性水平。

初始化关键词稳定，但不能代替抽样稳定性和测量效度。

主模型：控制作者和日期

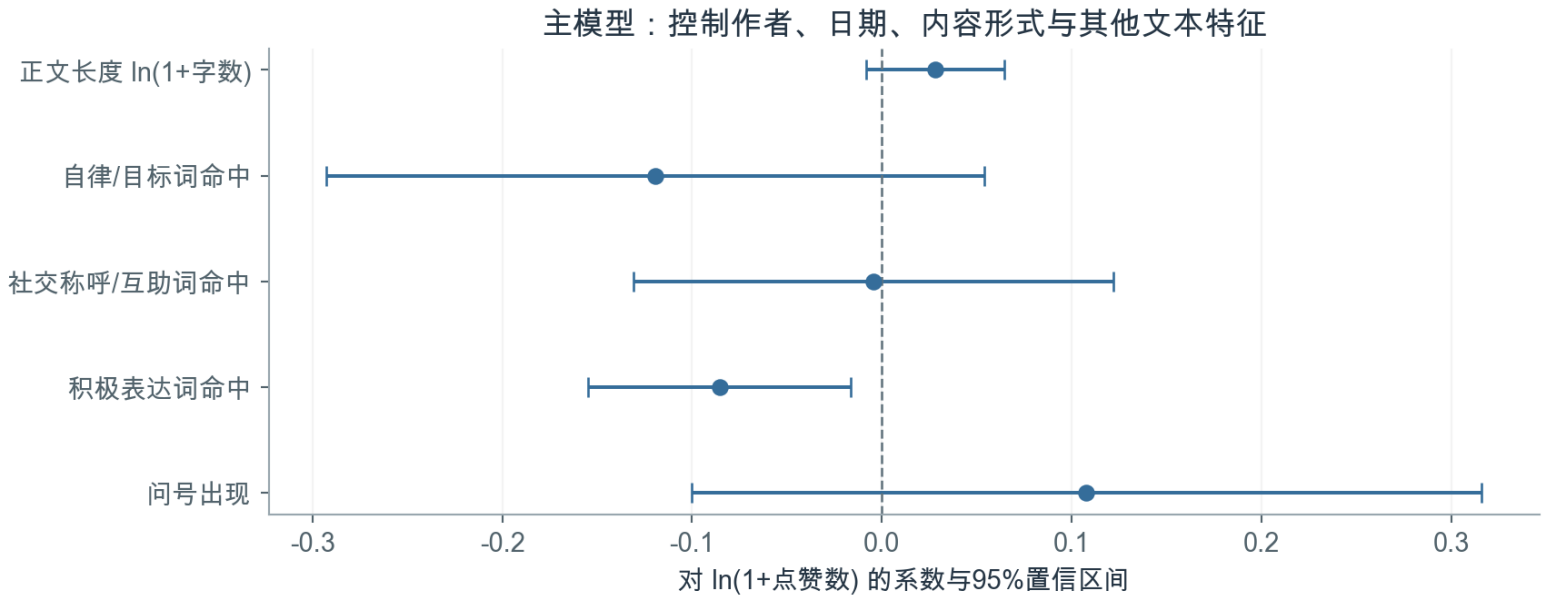
因变量 ln(1+likes)；全部9,532帖，100位作者。

作者固定效应 + 日期固定效应 + 内容形式/类型/时段及文本标记。

作者聚类CR1标准误；t分布df=99；五项核心检验BH校正。

作者内不变的性别、会员、等级等由作者固定效应吸收。

主结果：核心文本特征的关联证据有限

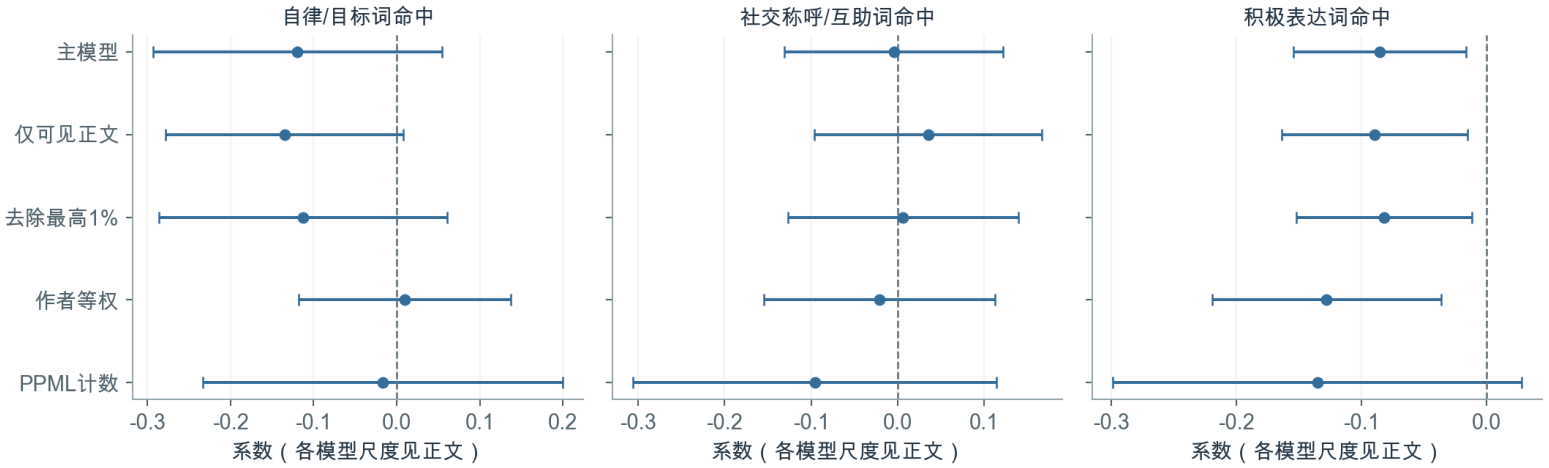


五项核心特征联合检验p=0.130；新增R^2仅0.065个百分点。

积极表达词β=-0.086；原始p=0.016，BH q=0.079。

不显著不是证明无作用；现有测量下证据不足。

稳健性：结论依赖尺度与规格

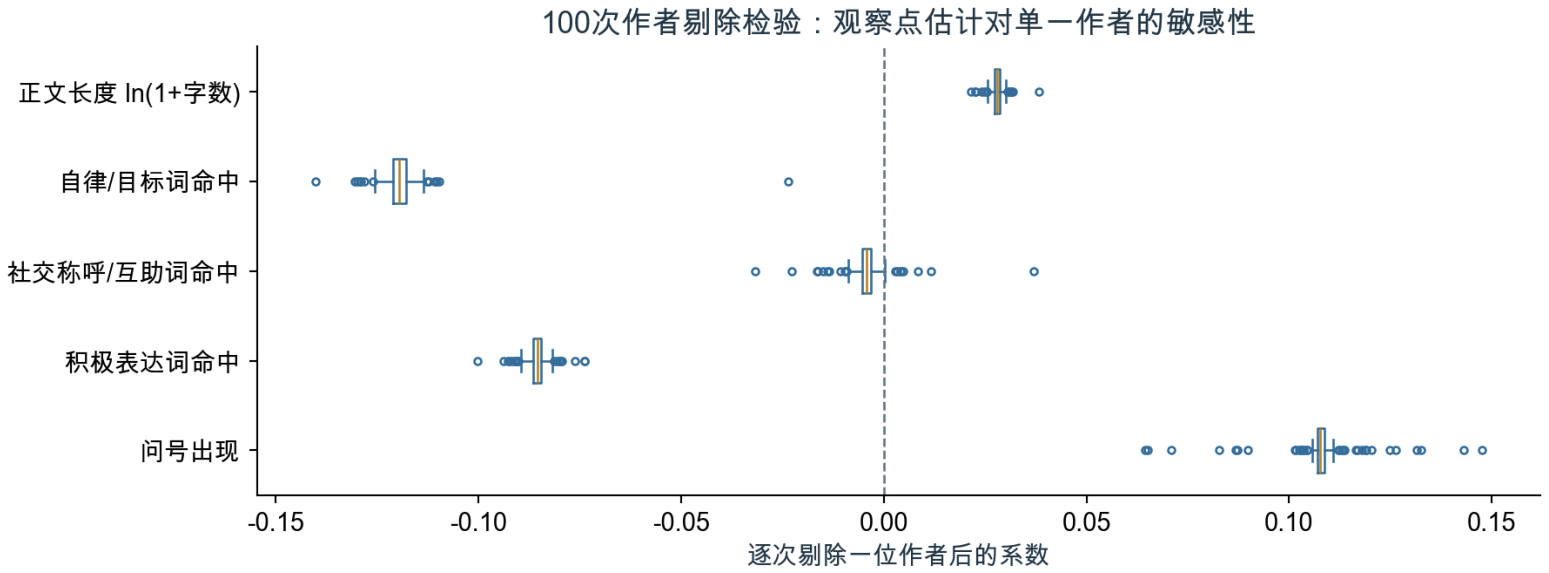


检查仅可见正文、去最高1%点赞、作者等权、PPML计数模型。

积极表达词的PPML区间包含0，原始p=0.103。

OLS与PPML的估计量不同；不能以某个规格显著就宣称稳健。

逐作者剔除：点估计与统计证据分开判断



逐次剔除1位作者，重复100次主模型估计。

积极表达词始终为负，范围[-0.100,-0.074]。

符号稳定不能替代BH校正和PPML结果；社交词在11次剔除后转正。

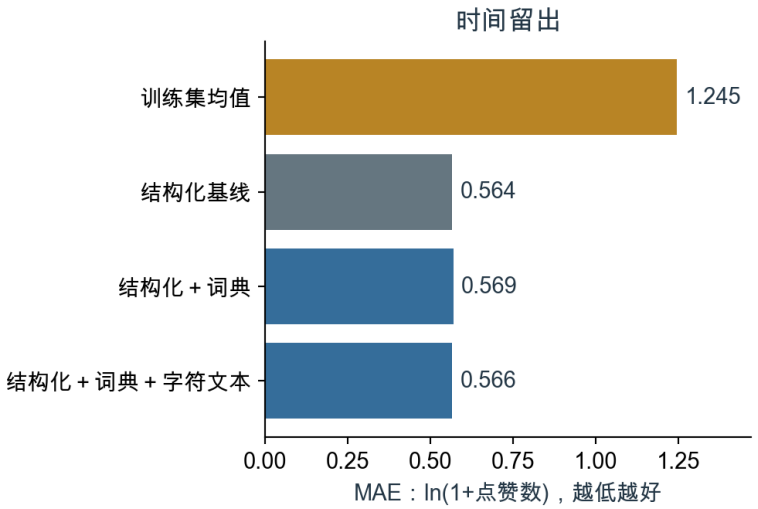
预测对照：文本是否帮助样本外泛化?

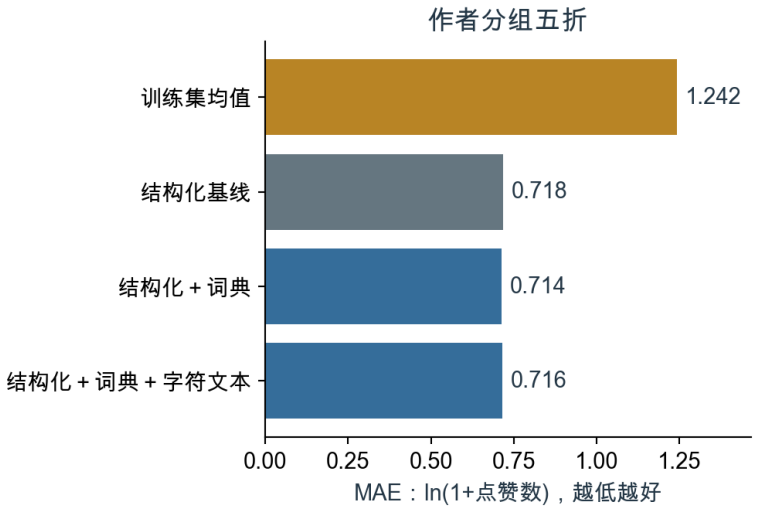
时间留出：7,098帖训练、2,434帖测试。

作者分组五折：同一作者只在一个测试折出现。

同一划分比较均值、结构化、加词典、加字符文本；编码仅拟合训练集。

两种留出评估均未显示稳定的文本增益





时间留出MAE：结构化0.5641，加字符文本0.5656。

作者分组MAE：结构化0.7180，加字符文本0.7164。

配对作者聚类区间均跨0；未见正文子集也未改变判断。

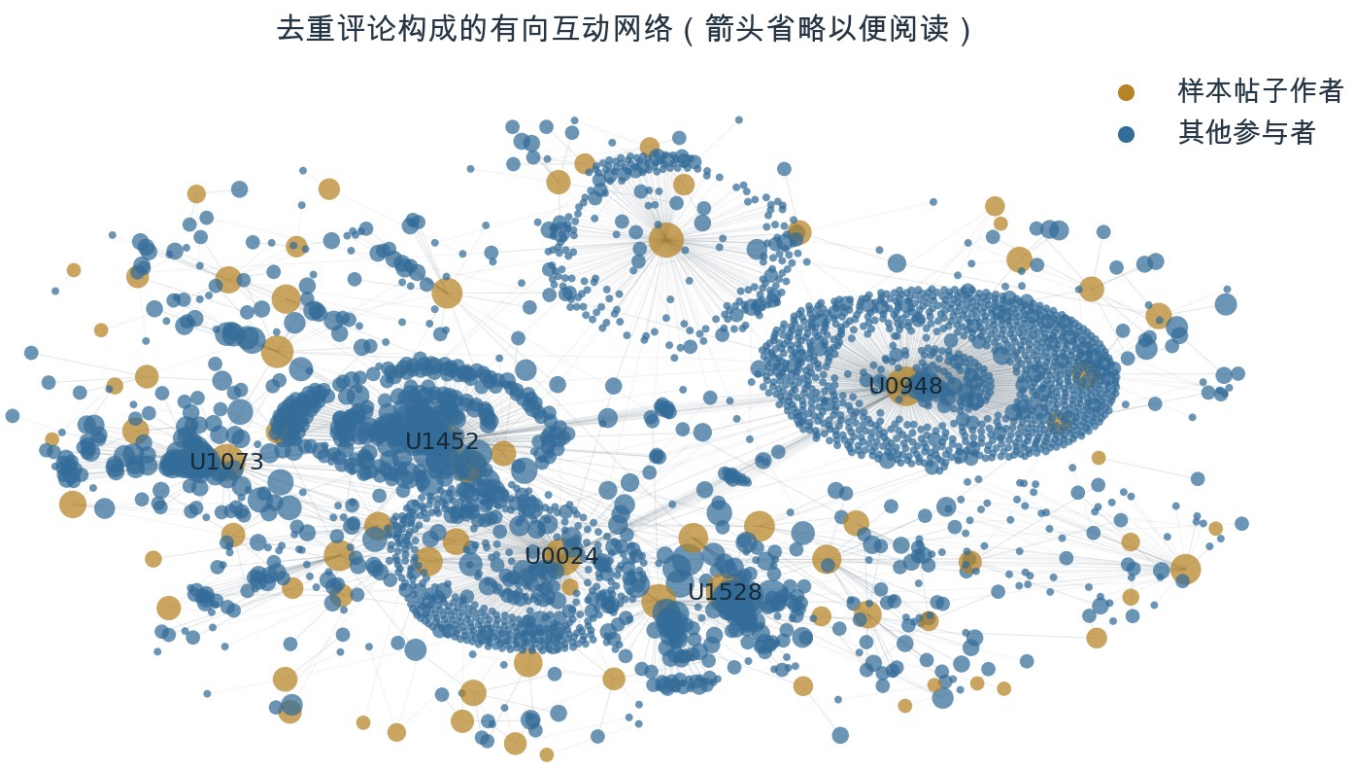
词典测量也需要接受检查

40个帖子—特征检查单元：按规则命中分层抽样，无点赞展示。

“完成”可能指绘画；“一起”可能描述线下朋友；问号可能是反问。

Codex辅助抽查，未做独立人工双编码；不宣称准确率。

评论网络：明确每条边的指向

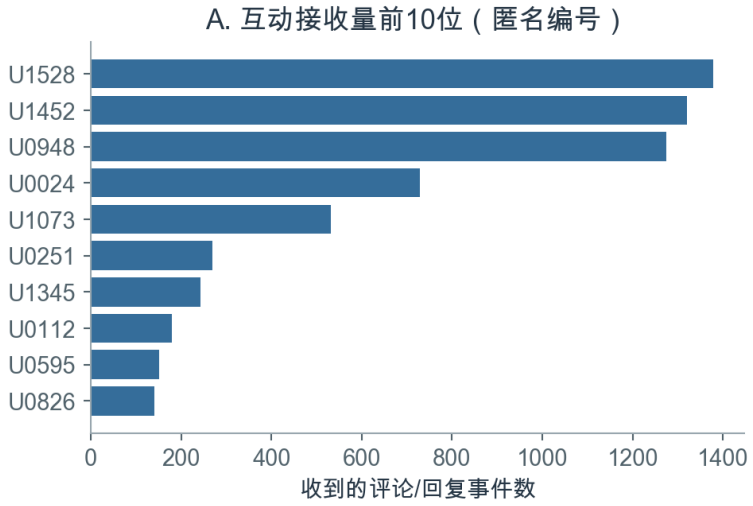


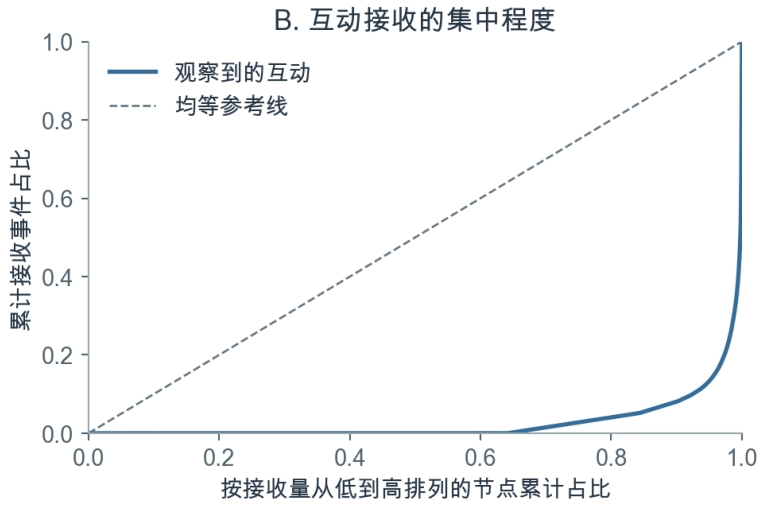
根评论：评论者→帖主；明确回复：回复者→replyUserId。

去重后移除84次自我互动；11,511事件合并为4,069条边。

2,932个有边节点；箭头在图中省略，原数据保持有向。

互动集中，但样本边界影响很大



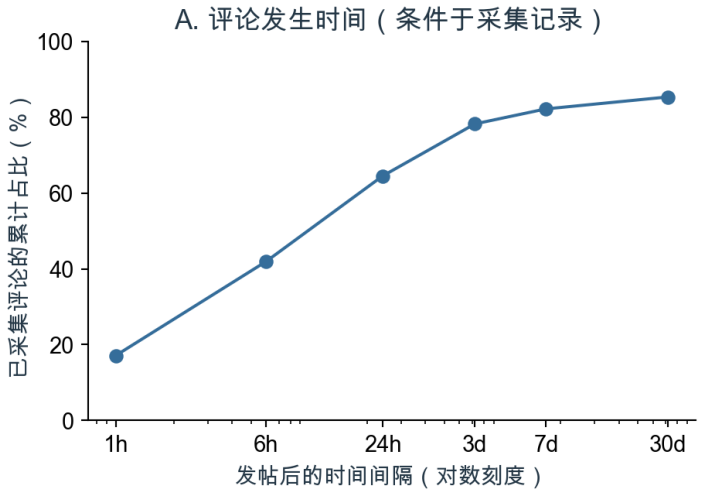


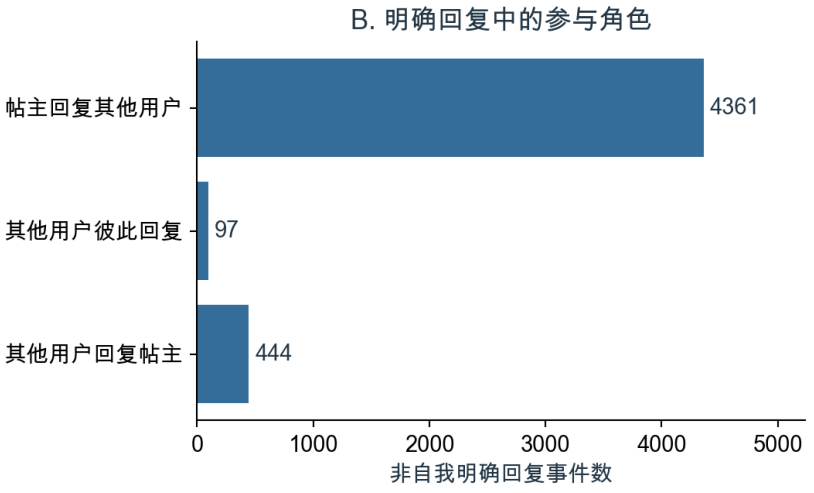
前10位接收者获得54.0%互动；第一位12.0%。

整体互惠率49.6%；仅明确回复子网络29.9%。

这是采集网络的接收事件数，不是平台影响力或独立粉丝数。

网络互惠主要体现围绕帖主的回应





已采集评论中64.5%在24小时内，82.2%在7天内。

4,902次明确回复中，89.0%由帖主发出；用户彼此回复仅2.0%。

首周互惠率74.1%，全部记录49.6%；窗口和采集边界影响结构。

建议：把表达方案交给对照实验

不承诺“加某个词就会涨赞”；先保证真实、完整且易交流的内容。

固定观察窗口、记录真实曝光；按作者随机分组评估提示文案。

关注低反馈用户与回复质量，同时验证抽样是否造成集中。

未执行的实验是后续设计，不是已证实的增长方案。

结论、局限与可复现性

词典、主题与留出评估均未提供稳定的文本增益证据。

100位作者课程样本，抽样机制不明；正文/视觉缺失；曝光和统一采集时点未知。

代码、原始Keep数据、特征表、回归结果与已执行Notebook全部随附。

数值独立复核；填好组号、成员后按课程要求打包提交。

小组分工与讨论

成员A【待填写】：研究问题与背景（1—3页）

成员B【待填写】：数据、文本与主题（4—10页）

成员C【待填写】：回归、预测与检验（11—17页）

成员D【待填写】：网络、建议与总结（18—23页）

建议分工须按真实人数和贡献修订。